

实验文档

实验数据

原定217篇文献因pdf格式问题解析出208篇，以下为缺失的文献：

- 故障率预测的稀疏直接支持向量回归机方法
- 故障预测与健康管理系统建模技术研究
- 飞机故障预测与健康管理应用模式研究
- 飞机故障预测与健康管理框架研究
- 飞机液压泵源预测与健康管理系统
- 航空发动机预测健康管理系统设计的关键技术
- 机载无线传感网络技术的发展与应用_刘恩朋
- 无人作战飞机自主控制技术研究

实验一

prompt

prompt内容如下：

```
# 实体关系抽取Prompt

## 任务描述
你的角色是一位专业的学术文献实体关系抽取专家，专精于从航空航天领域科研文献中识别和抽取实体及其关系。你的任务是通读给定文本，抽取文本中出现的核心实体，及其对应的关系，并以JSON格式输出。

## 输出格式
请严格按照以下JSON格式输出结果：
```json
{
 "entities": [
 {"type": "算法", "text": "卡尔曼滤波"},
 {"type": "模型", "text": "Paris模型"},
 {"type": "模型", "text": "LSTM网络"},
 {"type": "函数", "text": "Copula函数"},
 {"type": "性能指标", "text": "诊断准确率"},
 {"type": "研究结果", "text": "95.6%的准确率"}
],
 "relations": [
 {"type": "发展为", "head": "传统RNN", "tail": "LSTM网络"},
 {"type": "演化为", "head": "LSTM网络", "tail": "Transformer架构"},
 {"type": "提出了", "head": "Transformer架构", "tail": "自注意力机制"},
 {"type": "基于", "head": "Transformer架构", "tail": "注意力机制"},

```

```
 {"type": "评估指标是", "head": "轴承故障诊断系统", "tail": "诊断准确率"},
 {"type": "得出", "head": "轴承故障诊断系统", "tail": "95.6%的准确率"}
]
}```
```

### ## 输入数据（INPUT DATA）

现在，你将接收到用于处理的本次任务的全部输入数据。

论文全文（唯一事实来源）：

```markdown```

{full_text_placeholder}

实验一中我们仅给出了**任务描述**，给出**输出格式**的目的是：避免模型输出不同格式的结果难以进行后续指标的计算。

实验结果

解析篇数

```
提交论文：航空发动机振动监测与故障诊断技术研究进展_胡明辉_MinerU__20250913053117.md ...  
第 1/3 次尝试失败：Error code: 400 - {'error': {'message': 'Content Exists Risk', 'type': 'invalid_request_error', 'param': None, 'code': 'invalid_request_error'}}, 重试中...  
第 2/3 次尝试失败：Error code: 400 - {'error': {'message': 'Content Exists Risk', 'type': 'invalid_request_error', 'param': None, 'code': 'invalid_request_error'}}, 重试中...  
第 3/3 次尝试失败：Error code: 400 - {'error': {'message': 'Content Exists Risk', 'type': 'invalid_request_error', 'param': None, 'code': 'invalid_request_error'}} (已放弃)
```

deepseek共解析207篇文献，如图所示的文献因其判定具有风险内容未能抽取。

Gemini抽取了所有的文献


kimi抽取了195篇文献，剩下的kimi认为内容有风险

50篇论文的抽取结果


由于**实验三：动态构建few-shot模块**对于208篇文章进行了训练集和测试集的切分，为了对比，实验一考虑测试集中50篇论文的一些指标，之后的实验二、三皆是如此。

指标一：实体、实体type、关系、关系type数量


deepseek 模型实体和关系抽取数量统计 (50篇)



gemini 模型实体和关系抽取数量统计 (50篇)



kimi 模型实体和关系抽取数量统计 (50篇)



对于这些数据，我新加了一些数据处理（论文中没有这部分内容）：

论文stem	模型	原始字符数	去空白字符数	实体数量	关系数量	实体千字密	关系千字密	关系/实体比
GJB289A总	deepseek	18173	13110	23	18	1.7544	1.373	0.7826
GJB289A总	gemini	18173	13110	23	12	1.7544	0.9153	0.5217
GJB289A总	kimi	18173	13110	19	17	1.4493	1.2967	0.8947
PHM技术在	deepseek	15055	10731	19	17	1.7706	1.5842	0.8947
PHM技术在	gemini	15055	10731	33	18	3.0752	1.6774	0.5455
PHM技术在	kimi	15055	10731	21	17	1.9569	1.5842	0.8095
后人工智能	deepseek	1334	964	32	26	33.195	26.971	0.8125
后人工智能	gemini	1334	964	29	19	30.083	19.7095	0.6552
后人工智能	kimi	1334	964	25	25	25.9336	25.9336	1
基于AFDXI	deepseek	13356	9654	18	14	1.8645	1.4502	0.7778
基于AFDXI	gemini	13356	9654	20	14	2.0717	1.4502	0.7
基于AFDXI	kimi	13356	9654	21	14	2.1753	1.4502	0.6667

我们统计了如上所示20篇论文的一些信息，以下是一些属性列的解释：

原始字符数：md格式论文的所有字符（含md ~）

去空白字符数量：- 先依次剥离：代码块 ...，行内代码 ...，图片，链接，标题行(#...), 引用行(> ...), HTML 标签, 强调符号(* _ ~) 然后删除所有空白（空格/换行/制表符等）

实体千字密度：相对于去空白字符数量，每千字的实体数量

实体千字密度 = 实体数量 / 去空白字符数 × 1000

关系千字密度：相对于去空白字符数量，每千字的关系数量

关系千字密度** = 关系数量 / 去空白字符数 × 1000

所以我们是相当于去空白字符数量进行计算，所得的密度会更大。

*值得注意的是：对于所有的模型和所有的文章，关系和实体的比例超过1的寥寥无几

模型	未加权实体	未加权关系	加权实体	加权关系	篇数	总实体	总关系	去空白字符
deepseek	3.0065	2.0946	2.2014	1.4399	50	1405	919	638239
gemini	3.0641	1.9439	2.1512	1.3208	50	1373	843	638239
kimi	2.2534	2.0175	1.3960	1.2096	50	891	772	638239

我们的到如上所示的表格，可以注意到的是kimi的表现一般。

指标二：模型打分

我们使用Gemini-2.5-pro来对我们所得到的json结果进行判断，以下是使用的prompt

```
# 任务说明：实体与关系合理性评估

你是信息抽取评估专家。给定一篇文章由某个模型抽取到的实体列表与关系列表（JSON 格式），你的任务是逐条判断这些实体与关系是否与原文事实一致、类型标注是否正确、是否存在冗余或错误。请严格依据事实，不要臆造。

## 输入格式
- 一个 JSON 对象，包含字段：
  - `entities`：实体数组，元素形如 `{ "type": string, "text": string }`
  - `relations`：关系列表，元素形如 `{ "type": string, "head": string, "tail": string }`
- 文本内容已在抽取时使用，你只需根据抽取得到的 `text`、`head`、`tail` 与类型是否匹配事实进行判定。

## 评估要求
1. 对每个实体，给出 `evaluation` 字段：`"正确"`、`"错误"` 或 `"不确定"`。
  - `正确`：实体文本与类型均与原文一致且类型恰当。
  - `错误`：与原文不符、类型明显不当、或为无关/重复内容。
  - `不确定`：缺少关键信息无法判断。
2. 对每条关系，给出 `evaluation` 字段：`"正确"`、`"错误"` 或 `"不确定"`。
  - `正确`：关系三元组类型与两端实体含义和上下文匹配。
  - `错误`：关系类型不当、主体/客体错误、或与事实不符。
  - `不确定`：上下文不足以判断。
3. 不要更改原有的实体或关系顺序与字段；仅在每个对象中新增 `evaluation` 字段。
4. 输出必须是合法 JSON；不要包含额外的解释性文本。

## 输出格式（必须严格遵循）
输出一个 JSON 对象，字段为：
- `entities`：对输入 `entities` 数组逐条添加 `evaluation` 后返回。
- `relations`：对输入 `relations` 数组逐条添加 `evaluation` 后返回。

示例（片段）：
{
  "entities": [
```


```

{
  "type": "会议",
  "text": "2017预测与健康管理（PHM）研讨会",
  "evaluation": "正确"
},
{
  "type": "时间",
  "text": "2017年5月19日",
  "evaluation": "正确"
}
],
"relations": [
  {
    "type": "举办于",
    "head": "2017预测与健康管理（PHM）研讨会",
    "tail": "西安",
    "evaluation": "正确"
  }
]
}

```

重要约束

- 仅按输入对象添加 `evaluation` 字段，不新增、不删除、不修改已有字段值。
- 输出必须是 UTF-8 编码 JSON，且不包含注释或 Markdown。
- 如果输入为空数组，也要返回相同结构的空数组并保持字段名一致。



三个模型的模型的实体和关系准确率如上图所示。

依存句法分析构建规则库

实体对的抽取

prompt

角色 (Role)

你是一名顶尖的自然语言处理 (NLP) 专家，尤其擅长处理特定技术领域（如航空航天、PHM）的信息抽取任务。你的任务是将非结构化的实体列表转换为结构化的知识三元组，并能自主归纳实体的类别。

背景 (Background)

我正在进行一项针对飞机健康管理 (PHM) 领域的知识图谱构建工作。我已经使用依存句法分析工具从技术文档中初步提取了一批实体，但结果包含了大量噪音、碎片和不规范的表达。我需要你将这些原始实体数据，直接处理并转换为一个标准的JSON文件，其中每个JSON对象代表一个有意义的（主语-关系-宾语）三元组。

核心任务与执行步骤 (Core Task & Execution Steps)

你的核心任务是接收一个包含“脏”实体列表的输入JSON，并输出一个包含知识三元组的JSON数组。请严格遵循以下内部处理逻辑：

内部实体清洗与规范化 (Internal Entity Cleaning & Canonicalization):

首先，在你的处理流程中，对输入的实体列表进行静默的清洗。这意味着你需要过滤掉无效和不完整的条目，合并同义实体（如“滑油系统”与“发动机滑油系统”应统一），并整合实体碎片。

这一步是你的内部思考过程，不要在最终输出中展示清洗后的实体列表。

实体分类 (Entity Typing):

为你内部识别出的每一个核心实体，基于其在上下文中的作用和你的领域知识，分配一个最贴切、最简洁的类别名称。这个类别将用于填充输出JSON中的 `subject_type` 和 `object_type` 字段。

请在不同文献的处理中，对相同或相似概念的实体，尽可能保持类别名称的一致性。

关系识别与三元组构建 (Relation Identification & Triplet Construction):

基于你识别出的核心实体，分析并确定它们之间存在的、有意义的二元关系。

将每一对相关的实体及其关系，构造成一个（主语，关系，宾语）的三元组。其中，“关系”应是一个简洁、明确的动词或动词短语（例如：解决，包含，用于，优化，监测，具有等）。

输出格式要求 (Output Format Requirement)

最终的输出必须且只能是一个单一的、格式完全正确的JSON数组 [...]。

不允许在JSON数组前后包含任何Markdown标记、注释、解释性文字或任何其他非JSON内容。

数组中的每一个元素都必须是一个JSON对象，且严格遵循以下键值结构：

JSON

```
{
  "subject": "实体1的文本内容",
  "subject_type": "实体1的类别",
  "relation": "实体1和实体2之间的关系动词",
  "object": "实体2的文本内容",
  "object_type": "实体2的类别"
}
```

输入数据

现在，你将接收到用于处理的本次任务的全部输入数据。

论文全文（唯一事实来源）：

```markdown```

{full\_text\_placeholder}

Gemini-2.5-pro模型用于实体对的抽取，其数据基于HanLp的分词结果。

## 路径提取算法

### 数学证明跨距依存路径完备性

待完成，有了一点思路。

我觉得可以等我看完图论写一些（虽然可能没有什么太大的必要，从结果看来，应该是所有的实体对都找到了依存路径）


### 算法描述

这个算法先对每篇文章的每一句构建依存树（句内用无向边连接 token 与其 head），再把所有句子的根节点统一挂接到一个虚拟的 SUPER\_ROOT 上形成一棵大的“增广树”；给定一对实体，它先在各句中用规范化匹配找到实体的连续 token span，并从 span 内挑选一个锚点 token（优先 head 脱离 span 的 token）作为路径端点：若两个实体在同一句，就在该句依存图里用**BFS**找最短依存路径并补齐两端实体 span 的所有 token；若在不同句，则在跨句增广树上从一端锚点到另一端锚点做 BFS 得到唯一最短路径，去除中间的 SUPER\_ROOT，再同样扩展覆盖实体完整 span，最终输出包含依存关系标签的 token 序列及路径类型（句内或跨句），并统计匹配与路径成功情况。

### 统计



统计基于实体对之间的关系，以下是实体对中频率最高的关系：



其中最理想的是：方法->解决->问题这一路径的频率最高，符合我们的直觉。

# schema文件

## ## Schema参考模式

以下是从历史文献中提取的语义模式，请优先参考但不必严格限制。每个模式包含语义模板、实体类型约束、关系类型和历史频次：

### ### 高置信度模式（频次≥20）

- \*\*模式1：方法 → 解决 → 问题\*\***
- **\*\*语义模板\*\***: "方法 → 解决 → 问题"
  - **\*\*主语类型\*\***: 方法
  - **\*\*关系\*\***: 解决
  - **\*\*宾语类型\*\***: 问题
  - **\*\*频次\*\***: 26
  - **\*\*示例\*\***:
    - "基于CNN和LSTM的剩余寿命预估方法" → "航空发动机剩余寿命预估问题"
    - "MFOP参数分解方法" → "MFOP指标无法分解和落实的问题"
    - "基于Copula相似性的RUL预测方法" → "性能退化特征众多问题"
  - **\*\*语义说明\*\***: 用于解决指定的问题或难题

### ### 中等置信度模式（频次11-19）

- \*\*模式2：技术 → 应用于 → 应用领域\*\***
- **\*\*语义模板\*\***: "技术 → 应用于 → 应用领域"
  - **\*\*主语类型\*\***: 技术
  - **\*\*关系\*\***: 应用于
  - **\*\*宾语类型\*\***: 应用领域
  - **\*\*频次\*\***: 15
  - **\*\*示例\*\***:
    - "故障诊断技术" → "船舶"

- "综合诊断、预测与健康(PHM)技术" → "军事领域"
- "综合诊断、预测与健康(PHM)技术" → "民用领域"
- **\*\*语义说明\*\***: 在具体的应用场景或对象上使用

**\*\*模式3: 技术 → 提高 → Performance Metric\*\***

- **\*\*语义模板\*\***: "技术 → 提高 → Performance Metric"
- **\*\*主语类型\*\***: 技术
- **\*\*关系\*\***: 提高
- **\*\*宾语类型\*\***: Performance Metric
- **\*\*频次\*\***: 13
- **\*\*示例\*\***:
  - "综合运载器健康管理(IVHM)技术" → "可靠性"
  - "故障预测与管理技术(PHM)" → "任务成功率"
  - "综合运载器健康管理(IVHM)技术" → "可维护性"
- **\*\*语义说明\*\***: 对性能指标或能力的提升

**\*\*模式4: 方法 → 基于 → Model\*\***

- **\*\*语义模板\*\***: "方法 → 基于 → Model"
- **\*\*主语类型\*\***: 方法
- **\*\*关系\*\***: 基于
- **\*\*宾语类型\*\***: Model
- **\*\*频次\*\***: 12
- **\*\*示例\*\***:
  - "疲劳寿命预测方法" → "失效物理模型"
  - "故障分析方法" → "ARIMA模型"
  - "故障时间序列预测方法" → "LSTM循环神经网络"
- **\*\*语义说明\*\***: 在某种理论/方法/数据的基础上开展

**\*\*模式5: Model → 应用于 → 应用领域\*\***

- **\*\*语义模板\*\***: "Model → 应用于 → 应用领域"
- **\*\*主语类型\*\***: Model
- **\*\*关系\*\***: 应用于
- **\*\*宾语类型\*\***: 应用领域
- **\*\*频次\*\***: 12
- **\*\*示例\*\***:
  - "数字孪生五维模型" → "医疗"
  - "LSTM预测模型" → "故障时间序列分析"
  - "粗糙神经网络" → "航空电子设备的维护保障"
- **\*\*语义说明\*\***: 在具体的应用场景或对象上使用

**\*\*模式6: 方法 → 提高 → Performance Metric\*\***

- **\*\*语义模板\*\***: "方法 → 提高 → Performance Metric"
- **\*\*主语类型\*\***: 方法
- **\*\*关系\*\***: 提高
- **\*\*宾语类型\*\***: Performance Metric
- **\*\*频次\*\***: 12
- **\*\*示例\*\***:
  - "基于EMD和RVM-AR的预测方法" → "Si元素的预测精度"
  - "基于静电互相关灵敏度加权的气路碎片监测方法" → "PHM系统的稳定性"
  - "基于KPCA和DBN的建模方法" → "模型精度"

- **\*\*语义说明\*\***: 对性能指标或能力的提升

**\*\*模式7: 技术领域 → 包括 → 技术\*\***

- **\*\*语义模板\*\***: "技术领域 → 包括 → 技术"
- **\*\*主语类型\*\***: 技术领域
- **\*\*关系\*\***: 包括
- **\*\*宾语类型\*\***: 技术
- **\*\*频次\*\***: 11
- **\*\*示例\*\***:
  - "强度设计技术" → "结构故障预测与健康管理系统设计"
  - "强度设计技术" → "全机内力分析技术"
  - "强度设计技术" → "复合材料整体化结构分析技术"

**\*\*模式8: 技术 → 降低 → 成本\*\***

- **\*\*语义模板\*\***: "技术 → 降低 → 成本"
- **\*\*主语类型\*\***: 技术
- **\*\*关系\*\***: 降低
- **\*\*宾语类型\*\***: 成本
- **\*\*频次\*\***: 11
- **\*\*示例\*\***:
  - "综合运载器健康管理(IVHM)技术" → "成本"
  - "PHM技术" → "使用和保障费用"
  - "气路故障诊断技术" → "视情维修成本"
- **\*\*语义说明\*\***: 降低风险或某类不良指标

### ## 模式使用指导

1. **\*\*优先匹配\*\***: 当识别到符合上述模式的实体组合时, 优先考虑对应的关系类型
2. **\*\*类型约束\*\***: 严格遵守主语类型和宾语类型的约束条件
3. **\*\*频次权重\*\***: 频次越高的模式, 置信度越高
4. **\*\*灵活扩展\*\***: 如发现新的合理关系, 可以抽取但需标注为新模式
5. **\*\*上下文验证\*\***: 始终结合具体的文本上下文判断关系的合理性

schema文件如上所示, 我们选取了频次大于10的模式供模型参考。

## 实验二

### prompt

# 实体关系抽取Prompt

## 任务描述

你的角色是一位专业的学术文献实体关系抽取专家, 专精于从航空航天领域科研文献中识别和抽取实体及其关系。你的任务是通读给定文本, 抽取文本中出现的核心实体, 及其对应的关系, 并以JSON格式输出。

## 实体定义

文献中出现的核心概念、技术、方法、模型、系统、故障、指标或实验结果都可视为实体。实体可以是：

- **\*\*手段/工具\*\***：研究中使用的方法、技术、算法、模型
- **\*\*研究对象\*\***：系统、组件、问题、故障
- **\*\*研究结果\*\***：结论、数据、指标、观察结果

实体代表文本中具有独立意义、可被识别和引用的核心信息单元。

### ### 航空PHM领域特色实体（文献中常见）

- **\*\*航空设备术语\*\***：发动机、轴承、齿轮箱、叶片等（当文献涉及时）
- **\*\*故障相关概念\*\***：故障模式、失效机理、退化过程、健康状态
- **\*\*监测诊断技术\*\***：信号处理、特征提取、模式识别、智能诊断
- **\*\*预测方法\*\***：寿命预测、趋势预测、健康预测、风险评估
- **\*\*PHM系统概念\*\***：健康管理、状态监测、预测维护、决策支持

### ### 实体抽取指导原则

1. **\*\*最大化原则\*\***：当不确定是否为实体时，倾向于抽取
2. **\*\*语义独立性\*\***：具有独立含义的词汇或短语都可作为实体
3. **\*\*上下文敏感\*\***：同一词汇在不同上下文中可能是不同类型的实体
4. **\*\*层次包容\*\***：既抽取上位概念也抽取下位概念（如：机器学习 + 深度学习）
5. **\*\*组合概念\*\***：复合概念可拆分为多个实体，也可作为整体实体
6. **\*\*隐含实体\*\***：文中隐含但语义明确的概念也应抽取
7. **\*\*创新优先\*\***：特别关注新提出的概念、方法、发现
8. **\*\*无类型限制\*\***：不预设实体类型，根据实际内容灵活分类
9. **\*\*精细粒度\*\***：优先抽取具体的技术名称、精确的数值、详细的组件名称
10. **\*\*完整覆盖\*\***：确保技术链条中每个关键环节都有对应实体
11. **\*\*上下位词理论应用\*\***：运用语言学上下位词关系进行精确分类
  - **\*\*下位词优先原则\*\***：当实体具有明确的专业术语特征时，使用最具体的下位词作为类型
  - **\*\*词汇形态学指导\*\***：利用词汇的构词特征判断类型（如：含"模型"→模型类型；含"算法"→算法类型；含"函数"→函数类型）
  - **\*\*语义层次识别\*\***：识别概念的语义层次，避免将具体概念泛化为上位概念
  - **\*\*专业术语敏感性\*\***：对学术领域的专业术语保持高敏感度，使用领域内的精确分类

### ## 关系定义

文献中的实体之间通常存在逻辑、功能或因果联系。关系类型包括但不限于：

- **\*\*演进关系\*\***：发展为、演化为、改进了、基于、衍生自
- **\*\*创新关系\*\***：提出了、引入了、创新了、突破了
- **\*\*比较关系\*\***：优于、劣于、相似于、区别于、对比
- **\*\*依赖关系\*\***：依据、建立在、借鉴了
- **\*\*功能关系\*\***：应用于、作用于、处理、解决
- **\*\*因果关系\*\***：导致、产生、引起、影响
- **\*\*组成关系\*\***：包含、包括、由...组成
- **\*\*结合关系\*\***：结合、融合、集成

关系只需反映实体间实际存在的语义联系，具体类型无需严格限定，允许根据上下文灵活判断。

### ## PHM领域特色关系

#### ### PHM技术演进关系

- **\*\*算法发展\*\***：传统方法→机器学习→深度学习、基于模型→数据驱动→混合方法
- **\*\*监测技术进步\*\***：接触式→非接触式、单参数→多参数→多传感器融合
- **\*\*系统架构演化\*\***：离线分析→在线监测→实时预警→智能决策

### ### 故障机理关系

- **\*\*因果链条\*\***: 载荷→应力→损伤→裂纹→失效、磨损→间隙增大→振动异常→故障
- **\*\*故障传播\*\***: 局部故障→系统故障、单点失效→级联失效、初期故障→发展→严重故障
- **\*\*退化过程\*\***: 正常→轻微退化→明显退化→严重退化→失效

### ### 监测诊断关系

- **\*\*信号-故障映射\*\***: 振动信号反映轴承状态、温度变化指示润滑问题、油液分析检测磨损
- **\*\*特征-健康关系\*\***: 特征提取→健康评估、多特征融合→综合诊断
- **\*\*传感器-监测对象\*\***: 加速度传感器监测振动、温度传感器监测热状态

### ### 预测决策关系

- **\*\*数据-模型-预测\*\***: 历史数据训练模型→模型预测RUL→决策维修时机
- **\*\*健康状态-维修策略\*\***: 健康良好→正常运行、轻微退化→加强监测、严重退化→计划维修
- **\*\*预测精度-决策可靠性\*\***: 高精度预测→可靠决策、预测不确定性→风险评估

### ### 系统集成关系

- **\*\*多传感器融合\*\***: 振动+温度+油液→综合健康评估
- **\*\*多尺度集成\*\***: 部件级+系统级+机队级健康管理
- **\*\*多学科协同\*\***: 机械+电子+材料+控制→综合PHM解决方案

### ### 工程应用关系

- **\*\*实验室-工程应用\*\***: 算法验证→工程化→产业化应用
- **\*\*仿真-实际\*\***: 数值仿真→台架试验→实际飞行验证
- **\*\*标准-实施\*\***: 标准规范→工程实践→效果评估

### ### 性能评估关系

- **\*\*算法性能比较\*\***: 准确率对比、计算复杂度比较、实时性评估
- **\*\*系统效益评估\*\***: 成本效益分析、安全性提升、维修效率改进
- **\*\*技术成熟度\*\***: 实验室阶段→工程样机→产品化→规模应用

### ### 关系抽取指导原则

1. **\*\*全面性\*\***: 不遗漏任何有意义的实体间联系
2. **\*\*创新性\*\***: 特别关注学术文献中的创新关系和技术演进
3. **\*\*灵活性\*\***: 关系类型不限于上述分类, 可根据实际语义创建新关系
4. **\*\*层次性\*\***: 既抽取直接关系也抽取间接关系
5. **\*\*动态性\*\***: 关注时间维度上的变化和发展关系
6. **\*\*隐含性\*\***: 挖掘文本中隐含但语义明确的关系

## ## 关系发现策略

### ### 策略1: 动词挖掘法

- 仔细识别文中所有动词和动词短语, 将其作为潜在关系类型
- 特别关注表示行为、过程、变化的动词
- 例: 文中出现"验证了"→关系类型"验证了"; "显著提升"→关系类型"显著提升"

### ### 策略2: 句式模式识别

- 识别"A通过B实现C"→关系"通过...实现"
- 识别"A在B基础上发展出C"→关系"在...基础上发展出"
- 识别"A相比B提高了X%"→关系"相比...提高了X%"

### ### 策略3：学术表达捕捉

- 寻找学术论文特有的表达方式：首次、显著、有效、成功、创新性、突破性等修饰词
- 将这些修饰词与基础关系结合形成更精确的关系类型

### ### 策略4：上下文语义分析

- 分析实体间在特定上下文中的确切关系
- 避免使用过于宽泛的通用关系，追求语义的精确性

## ## 领域知识完整性要求

### ### 技术知识链条完整性

确保抽取以下技术演进的完整链条，不遗漏关键环节：

- **\*\*算法演进\*\***：从传统方法到先进方法的完整发展路径
- **\*\*系统架构\*\***：从部件到子系统到整体系统的层次关系
- **\*\*性能提升\*\***：具体的性能改进数据 and 对比结果
- **\*\*工程应用\*\***：从理论到实践的转化过程

### ### 关键实体覆盖检查

必须抽取的核心实体类型：

- **\*\*技术方法的具体名称\*\***：包括算法名、模型名、方法名
- **\*\*性能指标的具体数值\*\***：准确率、误差率、提升幅度等
- **\*\*系统组件的详细分类\*\***：传感器、处理器、算法模块等
- **\*\*故障模式的具体类型\*\***：具体的故障名称和特征
- **\*\*评估标准和数据集\*\***：具体的标准名称和数据集名称

### ### 隐含知识挖掘要求

主动识别和抽取文中隐含但重要的知识：

- **\*\*技术局限性\*\***：每种方法的适用条件和限制
- **\*\*性能权衡关系\*\***：不同指标之间的平衡关系
- **\*\*工程约束条件\*\***：实际应用中的限制因素
- **\*\*未来发展方向\*\***：文中暗示的技术发展趋势

## ## schema 定义

{schema\_placeholder}

## ## 抽取指令

### ### 步骤1：实体识别

1. 仔细阅读给定文本
2. 识别所有符合实体定义的核心概念
3. 为每个实体标注类型

### ### 步骤2：关系抽取

1. 分析实体间的语义联系
2. 匹配对应的关系，确保语义合理且符合逻辑

### ### 步骤3：结果验证

1. 检查抽取的关系是否符合常识和领域知识
2. 确保实体边界准确，避免过度分割或合并

## ## 输出格式

请严格按照以下JSON格式输出结果：

```
```json
{
  "entities": [
    {"type": "算法", "text": "卡尔曼滤波"},
    {"type": "模型", "text": "Paris模型"},
    {"type": "模型", "text": "LSTM网络"},
    {"type": "函数", "text": "Copula函数"},
    {"type": "网络", "text": "生成对抗网络"},
    {"type": "技术", "text": "注意力机制"},
    {"type": "研究方法", "text": "数据驱动方法"},
    {"type": "系统/部件", "text": "轴承故障诊断系统"},
    {"type": "数据集", "text": "CWRU数据集"},
    {"type": "性能指标", "text": "诊断准确率"},
    {"type": "研究结果", "text": "95.6%的准确率"}
  ],
  "relations": [
    {"type": "发展为", "head": "传统RNN", "tail": "LSTM网络"},
    {"type": "演化为", "head": "LSTM网络", "tail": "Transformer架构"},
    {"type": "提出了", "head": "Transformer架构", "tail": "自注意力机制"},
    {"type": "基于", "head": "Transformer架构", "tail": "注意力机制"},
    {"type": "引入了", "head": "Transformer架构", "tail": "多头注意力"},
    {"type": "结合", "head": "Transformer架构", "tail": "残差连接"},
    {"type": "优于", "head": "Transformer架构", "tail": "LSTM网络"},
    {"type": "应用于", "head": "Transformer架构", "tail": "轴承故障诊断系统"},
    {"type": "训练于", "head": "Transformer架构", "tail": "CWRU数据集"},
    {"type": "评估指标是", "head": "轴承故障诊断系统", "tail": "诊断准确率"},
    {"type": "得出", "head": "轴承故障诊断系统", "tail": "95.6%的准确率"}
  ]
}```
```

实体类型精确化要求:

- ****下位词优先策略****: 优先使用最具体、最精确的实体类型，避免过度泛化
- ****形态学分类法****: 当实体名称包含"模型"、"算法"、"函数"、"网络"、"方法"等专业术语时，使用对应的具体类型而非泛化的"研究方法"
- ****语义层次感知****: 运用上下位词关系，识别概念的精确语义层次（如："卡尔曼滤波"是"算法"的下位概念，而非泛化的"研究方法"）
- ****专业术语保真****: 保持学术领域专业术语的精确性，使用领域内认可的分类体系

关系类型拓展指导:

以上示例展示了常见的优质关系类型，但请不要局限于此。在实际抽取时：

- ****强制创新要求****: 主动寻找并创造文本中体现的独特语义关系，避免过度依赖示例关系
- ****精确语义捕捉****: 直接使用文本中的动词、动词短语或完整的关系表述作为关系类型名称
- ****学术特色关系****: 特别关注学术文献特有的关系，如：
 - 量化比较关系: 如"提升了X%"、"降低了Y倍"、"达到了Z水平"

- 时间演进关系：如"在X基础上发展出"、"逐步演化为"、"最终实现"
- 条件依赖关系：如"在X条件下适用于"、"当X时表现为"、"针对X问题使用"
- 创新程度关系：如"首次提出"、"显著改进"、"突破性解决"、"创新性实现"
- ****原文表述优先****：当文本中有明确的关系描述时，直接使用该表述而非泛化为通用关系
- ****语义精细化****：将宽泛关系细分为更具体的子关系，如将"应用于"细分为"首次应用于"、"成功应用于"、"广泛应用于"等

注意事项

1. ****不受schema限制****：给定的schema和示例仅作参考，实体类型和关系类型均不仅限于此
2. ****语义理解优先****：基于文本实际语义内容进行抽取，而非机械匹配已知模式
3. ****重点关注创新关系****：特别关注学术文献中的：
 - 技术演进关系（"基于"、"改进"、"发展"、"演化"）
 - 模型/方法间的进展关系（如：循环神经网络 → 卷积神经网络）
 - 比较关系（"优于"、"相似"、"区别"）
 - 应用关系（"适用于"、"解决"、"处理"）
4. ****完整概念抽取****：选择最有意义的完整概念作为实体
5. ****保持输出格式一致性****

输入数据（INPUT DATA）

现在，你将接收到用于处理的本次任务的全部输入数据。

论文全文（唯一事实来源）：

```markdown```

{full\_text\_placeholder}

这个prompt后续可以再精简。

对比实验一的prompt，我们添加了**实体和关系定义**，**规则约束**，**思考链**，**静态few-shot**，**验证指令**。

## 实验结果


### 解析篇数

本次分析仅对Gemini抽取的测试集50篇文献的抽取结果进行评估。

### 50论文的抽取结果

#### 指标一：实体、实体type、关系、关系type数量






同时我们也计算了，Gemini的实体密度和关系密度，计算方法同实验一不再赘述。

模型	实体千字密度_未加权均值	关系千字密度_未加权均值	实体千字密度_加权	关系千字密度_加权	覆盖论文数	总实体数	总关系数	总去空白字符数
gemini	5.8558	4.2793	4.2069	2.9346	50	2685	1873	638239

指标二：模型打分



指标	关系
总数	1873
正确/错误	1546 / 327
正确率	82.54%
错误率	17.46%
覆盖率	100.00%

以下为GPT的分析：该图显示 Gemini 在当前全量评估中实体正确率约 99.1%（覆盖率 100%，说明全部实体都有评价），而关系正确率为 82.5%（1873 条关系中 1546 条判为正确，错误 327 条，覆盖率同样 100%），两者近 17 个百分点的落差表明整体信息抽取的主要性能瓶颈已经从实体识别转移到关系抽取阶段：实体阶段几乎达到上限，后续提升空间主要在关系抽取的语义判别（如角色方向、关系类型细粒度区分、跨句/长距离依赖）以及潜在的冗余或边界不一致问题；由于评估覆盖率已达 100%，优化无需首先补标，而应聚焦于错误关系的类型分布与常见误差模式（例如同义关系混淆、参与实体配对错误、重复/伪关系），针对高频误差设计规则或微调提示模板，预期能较快把关系准确率再提升数个百分点。

### 实验三

# 主题聚类

我们将文献分为158篇作为主题聚类的语料训练集，50篇作为测试集。

以下为个人的主观臆断没有严谨的证明：

我个人认为这种主题聚类仍然是较为经典的机器学习方法，认为与线性分类器，knn等类似。从训练和测试的角度来看，主题聚类具有和经典的机器学习类似的训练时间较短，测试时间较长的特点。与之对比明显的是一些deep learning的测试时间远小于训练时间。

## 第一步 构建词向量库

第一步旨在将原始标注文档（Markdown格式）中的文本内容转化为高维语义向量，为后续主题聚类、可视化等任务提供基础数据。

输入文件夹：有标注原文（如 EXP-4/主题聚类/有标注原文）

### 主要流程

#### 1. 加载预训练中文文本嵌入模型

- 使用 BAAI/bge-large-zh-v1.5 （transformers库）
- 自动检测 GPU/CPU，加载模型与分词器

#### 2. 文本分段处理

- 每篇 Markdown 文档按“空行”分割为若干段落
- 过滤掉过短段落（小于10字）

#### 3. 向量化

- 每个段落前加 [CLS] ，送入模型
- 取输出的 CLS token 向量作为段落语义表示
- \*实际上，我对于此步并没有太多的认识，不太明白这一步的必要性。不过根据文档和 ai 的答案，我可以确定这一步是有先例的做法。

#### 4. 结果保存

- 每个段落保存：文件名、段落索引、原文、embedding向量
- 所有结果合并为一个 JSON 文件（如 数据结果/embedding\_vectors.json ）

## 第二步 构建词向量库

第二步将第一步得到的段落语义向量进行降维和聚类，并融合人工标注信息，实现段落级主题聚类与标注映射，为后续分析和可视化提供结构化数据。

输入数据：段落向量库： embedding\_vectors.json （第一步输出）

### 主要流程

#### 1. 加载段落向量与标注

- 读取所有段落的 embedding、原文、文件名等信息
- 加载所有标注 JSON，合并实体与关系，按文件名建立映射

#### 2. 向量降维（UMAP）

- 使用 UMAP 算法将高维向量降至 5 维
- 保存降维模型（便于后续可视化或新数据映射）

### 3. 聚类 (HDBSCAN)

- 对降维后的向量进行 HDBSCAN 聚类
- 每个段落分配一个聚类标签 (cluster)

### 4. 段落级标注融合与去重

- 对每个段落，筛选出与该段落文本相关的实体/关系标注
  - 实体：标注 [text](#) 字段需出现在段落文本中
  - 关系：[head](#) 和 [tail](#) 均需出现在段落文本中
- 对筛选出的标注去重（同一 type+text 或 type+head+tail 只保留一次）

## 第三步：Few-Shot动态抽取与S模块生成

第三步本步针对“无标注原文”中的每篇文档，自动检索与其语义最相关的已标注段落，动态生成 few-shot 示例（S模块），为后续信息抽取任务提供高质量上下文参考。

## 输入数据

- 无标注原文目录：无标注原文（每篇为 .md 文件）
- 已聚类标注库：embedding\_clusters\_with\_paragraph\_annots.json（第二步输出，含段落聚类、降维、标注）
- UMAP降维模型：[umap\\_model.joblib](#)
- 预训练嵌入模型：BAAI/bge-large-zh-v1.5

## 主要流程

### 1. 加载数据与模型

- 读取所有已标注段落及其聚类标签、降维向量
- 加载 UMAP 模型和文本嵌入模型

### 2. 每篇无标注文档处理

- 读取全文，生成嵌入向量
- 用 UMAP 模型降维到 5D
- 计算与所有已标注段落的语义相似度 (cosine similarity)

### 3. few-shot示例检索与筛选

- 首先在最相关的聚类中，按相似度排序，优先选取有标注（实体或关系）的段落
- 若不足指定数量（如 TOP\_K=3），则在所有段落中补充最相关且有标注的段落
- 保证每个示例都包含有效的实体或关系标注
- 若实体或关系为空则剔除这部分，取下一部分。

### 4. S模块内容生成

- 按顺序拼接 few-shot 示例，每个示例包含：
  - 段落原文
  - 标注（实体/关系，JSON格式，自动分类）

- 以结构化文本格式输出，便于后续 prompt 构建或 LLM 采样


## 实验结果

### 解析篇数

本次分析仅对Gemini抽取的测试集50篇文献的抽取结果进行评估。

### 50论文的抽取结果

#### 指标一：实体、实体type、关系、关系type数量



大致数据如上


论文stem	模型	原始字符数	去空白字符	实体数量	关系数量	实体千字密	关系千字密	关系/实体比
GJB289A总	gemini	18173	13110	28	22	2.1358	1.6781	0.7857
PHM技术在	gemini	15055	10731	38	30	3.5411	2.7956	0.7895
后人工智能	gemini	1334	964	51	46	52.9046	47.7178	0.902
基于AFDX的	gemini	13356	9654	32	21	3.3147	2.1753	0.6562
基于ARIMA的	gemini	16049	10982	43	24	3.9155	2.1854	0.5581
基于Caps-Net	gemini	30275	21464	44	30	2.0499	1.3977	0.6818
基于Copula的	gemini	25342	15953	30	22	1.8805	1.3791	0.7333
基于EMD和	gemini	14997	11295	31	24	2.7446	2.1248	0.7742
基于Ensemble	gemini	30722	18514	61	34	3.2948	1.8364	0.5574
基于KPCA的	gemini	16863	13135	37	23	2.8169	1.751	0.6216
基于LSSVM的	gemini	11561	9559	33	22	3.4522	2.3015	0.6667
基于LSTM的	gemini	35271	16090	28	18	1.7402	1.1187	0.6429
基于PHM的	gemini	24838	20937	33	24	1.5762	1.1463	0.7273
基于PHM的	gemini	16282	13642	57	40	4.1783	2.9321	0.7018
基于QAR的	gemini	21460	17794	87	51	4.8893	2.8661	0.5862
基于SVM的	gemini	17800	12737	28	23	2.1983	1.8058	0.8214
机载航电系统	gemini	14789	11984	78	53	6.5087	4.4226	0.6795
机载预测与	gemini	7012	5963	41	40	6.8757	6.708	0.9756
航天飞机为	gemini	11475	9194	57	27	6.1997	2.9367	0.4737
航空发动机	gemini	13212	11663	51	40	4.3728	3.4296	0.7843
航空发动机	gemini	9471	7487	48	32	6.4111	4.2741	0.6667
航空发动机	gemini	26695	20655	79	59	3.8247	2.8565	0.7468

实体密度如上

模型	论文数	总实体	总关系	总去空白字符数	实体千字密度(加权)	关系千字密度(加权)	实体千字密度(简单均值)	关系千字密度(简单均值)	关系/实体比(加权)
gemini	50	2491	1669	638239	3.9029	2.6150	5.4716	3.9098	0.67

实体和关系的密度如上所示

指标二：模型打分



指标	总数	有评估	正确	正确率	评估覆盖率
实体	2491	2491	2475	99.36%	100.00%
关系	1669	1669	1440	86.28%	100.00%