

DOI: 10.19650/j.cnki.cjsi.J2006238

面向飞机辅助动力装置在翼剩余寿命预测的 性能参数扩增方法^{*}

刘连胜¹, 张晗星², 刘晓磊¹, 王璐璐³, 梁 军¹

(1. 哈尔滨工业大学测控工程系 哈尔滨 150080; 2. 哈尔滨工业大学自动化测试与控制研究所 哈尔滨 150080;
3. 中国南方航空股份有限公司沈阳维修基地 沈阳 110043)

摘 要: 为解决飞机辅助动力装置(APU)在翼性能参数维度低而无法获得较高准确故障预测结果的问题,提出了一种基于生成对抗网络(GAN)性能参数的扩增方法。首先,在研究GAN原理的基础上,通过网格搜索算法确定生成器与判别器的优化参数;其次,研究面向APU性能退化参数的扩增方法,为APU的剩余寿命预测提供输入参数;最后,基于中国南方航空股份有限公司机队的APU在翼监测参数,全面验证和评估所提方法的性能。基于GAN生成10维的排气温度参数通过欧几里得距离、皮尔森相关系数和KL散度度量方法进行处理,结果表明生成参数与原始参数具有较好的一致性。基于3种寿命预测方法开展的对比实验中,将生成的10维参数与原始参数共同用于APU剩余寿命预测,与仅将原始性能参数用于APU剩余寿命预测相比,平均绝对误差和均方根误差表征的预测结果准确性至少提升了8.55%和3.62%。

关键词: 辅助动力装置; 生成对抗网络; 参数扩增; 故障预测; 在翼寿命

中图分类号: TP391.9 TH39 **文献标识码:** A **国家标准学科分类代码:** 413.30

Performance parameter augment method for on-wing remaining useful life prediction of aircraft auxiliary power unit

Liu Liansheng¹, Zhang Hanxing², Liu Xiaolei¹, Wang Lulu³, Liang Jun¹

(1. Department of Test and Control Engineering, Harbin Institute of Technology, Harbin 150080, China;
2. Automatic Test and Control Institute, Harbin Institute of Technology, Harbin 150080, China;
3. Shenyang Maintenance Base, China Southern Airlines Co., Ltd., Shenyang 110043, China)

Abstract: The dimension of on-wing performance parameters of the aircraft auxiliary power unit (APU) is low, it is difficult to obtain high accuracy fault prognostics result. To solve this problem, a performance parameter augment method is proposed, which is based on the generative adversarial networks (GAN). Firstly, the principle of GAN is studied, based on which the optimization parameters of the generator and discriminator are determined through the grid search algorithm. Then, the augment method facing to APU performance degradation parameter is studied, which provides the input parameters for remaining useful life (RUL) prediction of APU. Finally, the proposed method was verified and evaluated by utilizing the real on-wing monitoring data of APU from China Southern Airlines fleet. The generated 10 D exhaust temperature parameters based on GAN were processed with Euclidean distance, Pearson correlation coefficient and Kullback-Leibler divergence methods, the results show that the generated data and original data have good consistency. In the comparison experiments based on the three RUL prediction methods, the generated data and original data are both utilized for the RUL prediction, the prediction result accuracies characterized with the mean absolute error and root mean square error are improved by 8.55% and 3.62% at least compared with those using only the original performance parameters for the RUL prediction.

Keywords: auxiliary power unit; generative adversarial network; parameter augment; fault prognostics; on-wing life

收稿日期: 2020-04-02 Received Date: 2020-04-02

^{*} 基金项目: 国家自然科学基金(61803121)、中国博士后科学基金(2019M651277)项目资助

0 引言

飞机辅助动力装置(auxiliary power unit, APU)是一个小型燃气涡轮发动机,除无法为飞机提供推力外,可替代发动机的全部功能^[1]。当飞机在空中发生紧急情况时,APU可为飞机提供必要的电源和气源,使飞机维持飞行姿态、航向等,以便在有效时间内降落备降机场,保障旅客与飞机的安全。在辅助启动主发动机方面,APU为其提供必需的电源和气源,从而摆脱对地面电源车、气源车等辅助设备的依赖;飞机降落后,由APU供应电源和气源,主发动机提早关闭,从而节省燃油、降低噪声污染及延长主发动机的使用寿命^[2]。因此,开展APU的在翼状态评估,为视情维护维修提供支撑信息,具有重要的工程应用价值。

在APU状态评估相关研究中,APU厂商霍尼韦尔公司提出了降低启动过程中的温度,有利于延长APU的寿命^[3]。为及时发现APU启动机的性能退化,可采用基于粒子滤波的方法,通过分析飞机通信寻址与报告系统(aircraft communications addressing and reporting system, ACARS)中记录的启动参数,获得启动机的性能评估结果^[4-5]。通过改进启动机的工作策略,结合瞬态变化的流体动态模型,调节启动机的燃料供给,可有效提升启动机性能,达到快速启动APU的效果^[6]。此外,有部分可靠性方法开展APU的状态评估。文献[7]通过统计分析维修维护数据中APU部件与某一失效模式之间的关系,获得了不同部件对失效模式的量化指标,包括失效比例、严重等级、失效模式概率、平均失效时间等。更进一步,依据的失效模式量化指标,可更新排故手册的故障隔离与识别^[8-9]。文献[10]提出了一种基于Weibull分布广义更新过程,用于预测APU的故障概率。

依据航空领域的专家知识,排气温度(exhaust gas temperature, EGT)在一定程度上能够反映APU的性能衰退情况^[11-12]。EGT是指在航空发动机中燃气从燃烧室排出,通过高速旋转的涡轮后,在发动机涡轮出口截面上的温度,通常由K型热电偶测得,且在APU的寿命周期内一般呈现逐渐上升趋势。EGT作为监测APU工作状态及性能的重要参数,如果超过规定阈值,有可能损坏燃烧室、涡轮叶片、尾喷管等部件。因此,根据EGT的变化趋势预测APU的潜在故障,具有一定的可行性。然而,数据驱动方法对于数据具有较强的依赖性,较少的数据往往难以获得较好的预测结果^[13-14]。

参数扩增为解决较少参数问题提供了一种途径,其典型方法是基于虚拟参数生成技术。在原始数据概率分布未知的条件下,结合领域的先验知识和已有数据,研究如何生成合理的虚拟参数^[15]。在图像生成研究方面,已

有学者提出基于特征不变法生成虚拟参数^[16]、基于混合整体趋势扩散方法生成虚拟参数^[17]。Bishop^[18]研究发现,通过在原始参数中添加噪声,可有效提升参数生成方法的泛化能力,此类方法属于基于扰动的思想构造虚拟参数。在不考虑领域先验知识的前提下,有学者提出了基于分布函数构造虚拟参数技术,例如利用间隔核密度估计方法,来生成符合该函数的虚拟参数^[19]。Goodfellow等^[20]于2014年提出的生成对抗网络(generative adversarial networks, GAN)方法,在图像生成方面获得了广泛关注。目前,已有相关研究基于GAN实现了复杂对象的故障检测和诊断研究^[21-22]。

本文在上述研究的基础上,探索基于GAN扩增APU性能参数的方法,即通过生成多维虚拟的EGT参数,为开展故障预测提供相对丰富的输入支撑,以提升APU在翼故障预测结果的准确性。通过对来源于实际应用中的EGT扩增,并经过多种故障预测方法的实验,验证了本文提出的基于GAN扩增参数可有效提高预测结果的准确性,为解决类似应用场景的复杂对象故障预测问题,提供了一种切实可行的参考方法,具有实际的工程应用价值。

1 基础理论研究

1.1 生成对抗网络(GAN)原理

GAN的思想启发自博弈论中二人零和博弈,博弈双方分别由一个生成器(generator, G)和一个判别器(discriminator, D)构成^[20],基本框架如图1所示。




图1 生成对抗网络计算流程

Fig.1 Flowchart of GAN calculation

图1中, D 和 G 通常为非线性映射函数,一般由神经网络或多层感知器等网络结构来形式化,其核心损失函数如式(1)所示。

$$\min_G \max_D \{ L(D, G) = E_{x \sim P_{\text{data}}} [\log D(x^m)] + E_{z \sim P_z} [\log(1 - D(G(z^k)))] \} \quad (1)$$

式中: $\{x^m\}_{m=1}^M$ 为原始参数集; $\{z^k\}_{k=1}^K$ 为随机噪声变量集; z^k 采样于某种噪声分布 $P_z(z)$ (例如均匀分布噪声)。生成器 G 通过将 z^k 映射为 $G(z^k)$ 隐式地定义了一个生成

分布 P_g 来拟合原始参数分布 P_{data} 。判别器 D 作为一个二分类判别器, 以原始参数 x^m 和生成参数 $G(z^k)$ 为输入, 判别当前输入来自原参数还是生成参数, 以此来判断当前 G 的生成质量。当输入为原参数 x^m 时, $D(x^m)$ 期望输出为真; 当输入为生成参数 $G(z^k)$ 时, 其在 D 上的表现 $D(G(z^k))$ 期望输出为假, 而对于 G 需要尽可能使 $D(G(z^k))$ 期望输出为真, 使它和原参数 x^m 的表现一致, 从而形成对抗竞争关系。两个模型相互交替训练的优化过程, 可以视为一个极大极小博弈的问题。

通过相互对抗学习机制, 使得判别器 D 和生成器 G 的性能不断提升。当 $P_g = P_{\text{data}}$ 时, 即生成器生成的新参数完美地拟合原始参数分布, 此时损失函数(即式(1))收敛, GAN 达到纳什均衡。在 GAN 训练完成后, G 可以很好地估测到原始参数的分布, 生成符合原始参数分布的新参数, 达到扩增参数的目的。

1.2 生成对抗网络结构设计及优化

为生成高质量的 APU 性能退化趋势参数样本, 本文设计了一种基于 GAN 框架的网络模型, 其中使用反向传播神经网络(back propagation neural network, BPNN) 作为生成器与判别器的实体构建生成对抗网络模型。本文设计的 GAN 网络以 3 层 BPNN 作为生成模型的生成器与判别器, 以交叉熵作为损失函数, 具体的网络结构与训练过程如下。

1) 生成器生成参数

从均匀分布噪声中随机采样得到的随机向量 $\{z^k\}_{k=1}^K$, 输入至生成器, 映射为隐含层矢量 h_z^k , 再生成新参数 $\{x_{\text{fake}}^k\}_{k=1}^K$, 表达式如下。

$$h_z^k = f_{\theta_z}(W_z z^k + b_z) \quad (2)$$

$$x_{\text{fake}}^k = f_{\theta'_z}(W'_z h_z^k + b'_z) \quad (3)$$

式中: θ_z, θ'_z 分别为神经网络输入层到隐含层以及隐含层到输出层的参数集合, 且 $\theta_z = \{W_z, b_z\}$, $\theta'_z = \{W'_z, b'_z\}$; W_z 和 W'_z 是权重矩阵; b_z 和 b'_z 是偏置矩阵; 激活函数 $f(\cdot)$ 为 Sigmoid 函数。

2) 判别器训练

将生成的新参数 $\{x_{\text{fake}}^k\}_{k=1}^K$ 标注为 0, 原参数 $\{x^m\}_{m=1}^M$ 标注为 1。生成新参数和原参数被共同输入至判别器进行真伪判别, 判别器输出对应的真伪标签 d_{real}^m 和 d_{fake}^k 。

通过最小化真伪标签的误差, 完成判别器网络的训练。真伪标签的误差如式(4)所示, 交叉熵损失函数如式(5)所示。

$$L_d = -\frac{1}{M} \sum_{m=1}^M \ln d_{\text{real}}^m - \frac{1}{K} \sum_{k=1}^K \ln(1 - d_{\text{fake}}^k) \quad (4)$$

$$L_D = \arg\min_{\Theta} (L_d) \quad (5)$$

式中: L_d 为判别器真伪标签交叉熵损失误差; L_D 为 GAN 中判别器的损失函数; Θ 为参数集。

3) 生成器训练

为了训练生成器, 将 $\{x_{\text{fake}}^k\}_{k=1}^K$ 标注为 1, 输入至判别器。当输出真伪标签为 0(判别为生成参数)时, 说明生成器生成的新参数未能成功骗过判别器, 再通过最小化式(6)反馈调节训练。

$$L_g = -\frac{1}{K} \sum_{k=1}^K \ln d_{\text{fake}}^k \quad (6)$$

$$L_G = \arg\min_{\Theta} (L_g) \quad (7)$$

式中: L_g 为生成器真伪标签交叉熵损失误差; L_G 为 GAN 中生成器的损失函数; Θ 为其参数集。

4) 对抗学习机制

当输入原参数 $\{x^m\}_{m=1}^M$ 至 GAN 时, 判别器的目标是使输出值 d_{real}^m 尽量为 1, 当输入为新参数 $\{x_{\text{fake}}^k\}_{k=1}^K$ 时, 判别器的目标是使输出值 d_{fake}^k 尽量为 0, 即判别器可以正确判断新参数为假。而生成器的目标是使 d_{fake}^k 趋近于 1, 即生成参数成功欺骗了判别器, 两者形成对抗与竞争。通过这种对抗学习机制, 交替优化判别器和生成器: 先固定生成器, 利用随机梯度下降法优化判别器, 使得判别器的判别准确率最大化; 然后固定判别器, 同样利用随机梯度下降法优化生成器, 使得判别器的判别准确率最小化。训练过程中, 两者不断优化, 提高各自的模型的故障识别与参数生成能力, 直至判别器和生成器达到纳什均衡, 最终完成 GAN 的训练。

在 GAN 的训练中, 参数的设置是一个重要环节, 隐含层节点的个数是影响 BPNN 性能的重要参数。隐含层神经元的个数过少会导致 BPNN 模拟效果差, 神经元个数过多会大大增加训练时间。生成器 G 与判别器 D 的隐含层节点数的选择会影响各自的性能, 进而影响生成参数的质量和训练时间。同时, 二者相互牵制相互影响。若判别器的判别能力过差, 生成器没有生成优秀的假参数也可以轻松骗过判别器以至于过早达到训练平衡; 若判别器判别能力过强, 可能会使判别器的损失函数在训练一开始就降到特别低, 导致后续对抗无法进行, 生成器无法从判别器的反馈中学习或训练出的生成器性能较差。所以合理选择二者的节点数可以对模型起到优化作用, 而节点数的选择与参数规模、长度、参数内在分布特征的复杂度有着紧密的关系, 不同的节点数选择将适用于不同的参数。采用网格搜索法寻找较优的生成器和判别器节点数设置, 通过对生成参数的质量评价确定网络节点数。

2 基于参数扩增的剩余寿命预测方法

2.1 方法框架

为提高 APU 剩余寿命(remaining useful life, RUL)

预测的准确性,解决可用监测参数维数过少,RUL 预测模型泛化能力不足的问题,开展基于生成对抗网络的性能

参数扩增的 APU 在翼剩余寿命预测研究,总体方案如图 2 所示。




图2 总体方案

Fig.2 Block diagram of overall scheme

图2所示的总体方案主要步骤如下。首先,通过飞机通信寻址报文获得APU的状态监测参数,选择能够表征APU退化信息的排气温度参数。然后,对数据进行预处理,使用修正公式将参数修正到标准工况(海平面标准气压:101.325 kPa,环境温度:15℃)下,并对数据进行归一化与平滑处理。然后使用生成对抗网络对预处理后的数据进行维度上的扩增,采用质量评价指标,定量比较生成参数与原始参数间的相似性、相关性与概率分布差异,实现全面对生成参数的质量进行评价。根据评价指标调整网络参数,优化生成器和判别器两个模型。确定模型参数后,获取优化模型下扩增的参数用于RUL预测实验。最后,通过对比实验验证参数维度的扩增是否可以提高APU剩余寿命预测结果的准确性。

2.2 扩增参数性能评价指标

ACARS在飞机每次飞行结束下传两条报文数据,即每个APU退化性能参数两个数据点,累计获得寿命周期参数。对于GAN生成的参数,采用欧几里得距离(Euclidean distance, ED)、皮尔森相关系数(Pearson correlation coefficient, PCC)和KL散度(Kullback-Leibler divergence)3种方法统计生成参数与真实参数间的相似性,从而进行生成参数的质量评估^[23]。

1) ED

$$ED = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (8)$$

式中: n 为参数 x, y 的参数点数; x_i, y_i 为第 i 个数据; ED 为 n 维空间中两点之间的真实距离,其值越小,表明参数间越相似。

2) PCC

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (9)$$

式中: n 为参数 x, y 的参数点数; x_i, y_i 为第 i 个数据; $\bar{x}, \bar{y}$ 为参数均值; r 为 $[-1, 1]$ 之间的数,正值表示正相关,负值表示负相关, r 的绝对值越大表明相关性越强,0 表示二者线性不相关。

3) KL 散度

$$KL(P \parallel Q) = \sum_{x \in \mathcal{X}} P(x) \log \frac{1}{Q(x)} \quad (10)$$

式中: $P(x)$ 和 $Q(x)$ 是随机变量 X 的真实概率分布和理论概率分布。KL散度又称相对熵(relative entropy),等价于两个概率分布的信息熵的差值,评估两个概率分布间的差异。KL散度越小,表明参数间的概率分布越相似。

2.3 剩余寿命预测结果评价

在评价 APU 剩余寿命预测结果方面,本文采用平均绝对误差(mean absolute error, MAE)和均方根误差(root mean square error, RMSE)对预测结果的准确性进行定量评价^[11, 24]。

1) MAE

$$MAE = \frac{1}{N} \sum_{i=1}^N |y(i) - p(i)| \quad (11)$$

2) RMSE

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y(i) - p(i))^2} \quad (12)$$

式中: $y(i)$ 为 RUL 的真实值; $p(i)$ 为 RUL 的预测值; N 表示预测 RUL 的次数。MAE 和 RMSE 数值越小,表示预测结果的准确性越好;相反,两者数值越大,表示预测结果的准确性较差。

3 实验验证与分析

3.1 实验数据描述

APU 装备于飞机后,一次典型工作过程主要包括:启动、无负载状态、空调模式(客舱环境控制)和辅助启动主发动机。记录 APU 在翼状态时,是由 APU 控制器根据其工作过程中满足的触发条件,分别记录启动、辅助启动主发动机和空闲时的工作状态,并汇总形成一条 A13 报文,由 ACARS 传输至航空公司的数据中心。一条 A13 报文代表了 APU 工作一个循环(Cycle)的状态信息,其中重要的监测参数如表 1 所示。

表 1 APU 在翼监测参数

Table 1 On-wing monitoring parameters of APU

符号	描述	单位
NA	APU 转速	%
IGV	进口导向叶片	°
EGT	排气温度	°C
LCIT	进气温度	°C
PT	引气压力	bar
P2A	进气压力	bar
WB	引气流量	kg/s
OT	滑油温度	°C
GLA	发电机载荷	%
STA	APU 启动时间	s

根据航空领域的专家知识,大多依据气路参数反映 APU 的退化性能。其中,排气温度 EGT 为 APU 在翼的关键性能参数。随着 APU 的性能逐渐下降,在翼剩余寿命减少,EGT 呈现上升的趋势。本文开展的实验验证,使用中国南方航空股份有限公司机队的实际监测 EGT 数据。

3.2 性能参数生成与讨论

1) 数据预处理

在实际应用中,EGT 数据由热电偶传感器采集,参数趋势受环境温度和 APU 性能退化的影响。实验中使用的 APU 寿命周期 EGT 原始数据如图 3 所示。




图 3 原始 EGT 参数

Fig.3 The original EGT parameters

为了消除环境温度的影响,需将不同外部环境下采集的 EGT 数据修正到国际标准大气条件下,国际标准大气条件下的温度如下。

$$T_0 = 288.15 \text{ K} (15^\circ\text{C}) \quad (13)$$

排气温度的修正公式如下:

$$EGT_{\text{cor}} = EGT_{\text{raw}} \times \frac{T_0}{T_1} \quad (14)$$

式中: T_1 为压气机进气温度 LCIT; EGT_{raw} 为原始 EGT 数据; EGT_{cor} 为修正后的 EGT 数据。修正后的 EGT 数据如图 4 所示。




图 4 修正后的 EGT 参数

Fig.4 The corrected EGT parameters

由于 EGT 数据是从实际应用场景中采集获取的,所以在采集和传输过程中不可避免会存在一些异常值。根

据专家经验剔除这些异常值将其替换为附近值的平均值,并对修正后的 EGT 数据进行归一化处理,归一化后的 EGT 数据如图 5 所示。




图 5 归一化后的 EGT 参数

Fig.5 The normalized EGT parameters

为了全面利用 EGT 数据的变化趋势信息,提高寿命预测的准确性,将归一化后的 EGT 数据进行平滑处理。本文采用相邻 3 个数据取均值的方式进行数据的平滑滤波,在一定程度上去除噪声的影响,较好地保持原始数据中蕴含的 APU 退化特征信息。平滑后的 EGT 参数如图 6 所示。




图 6 平滑后的 EGT 参数

Fig.6 The smoothed EGT parameters

2) 开发环境介绍

参数生成开发程序的软件工具为 PyCharm 3.7,选用 Python 作为编程语言,Tensorflow 1.13.1 作为深度学习算法的编程框架,实验条件如下所述。

(1) 实验使用 R2014a 版本的 MATLAB;

(2) 实验使用的计算机配置如下: CPU 为 i7-4510 的四核处理器,内存为 8 GB,操作系统为 64 bit 的 Windows 7。

3) 参数生成与讨论

完成数据的预处理后,构建生成对抗网络模型生成参数,应用 3 种评价指标定量分析生成参数的质量,根据评估结果调整网络结构,获得优化的模型。在训练 GAN 的判别器 D 时,生成器 G 是固定的,训练过程需要利用具有随机性的数据支撑,因此实验中引入具有均匀分布的随机噪声,其维度数值为 100,用于支撑 GAN 的训练。

为获得较优的生成器和判别器节点数,使用网格搜索法。首先,设定判别器 D 的节点数为 100,令生成器 G 的节点数分别为 100~1 000(步长为 100) 训练模型生成参数,生成参数维度设置为 10 个,计算每个生成参数与原始参数间的 ED、PCC 和 KL 散度,取 10 个参数计算结果的均值作为该参数设置下本次实验的实验结果。为减小实验的随机误差,每组参数设置下均进行 10 组实验,最后取 ED、PCC、KL 散度和训练时间,记录上述实验结果和模型训练时间。综合考虑参数评估结果与模型训练时间,选择生成器 G 节点数为 400。

确定生成器 G 的节点数后,对判别器 D 的节点数进行选择。设定生成器 G 的节点数为 400,令判别器 D 的节点数分别为 100~1 000(步长为 100) 训练模型生成参数,生成参数维度、实验组数设置、实验步骤及结果记录均同上。最终,确定生成对抗网络的网络结构选择生成器 G 节点数为 400,判别器 D 节点数为 500。

在生成器节点数 400 和判别器节点数 500 的参数设置下,应用生成对抗网络生成 10 组参数,部分生成的 EGT 参数如图 7 所示。生成参数质量评估结果如表 2 所示。




图 7 EGT 生成参数

Fig.7 The generated EGT parameters

表2 EGT生成参数质量评估

Table 2 Quality assessment of the generated EGT parameters

生成参数序号	ED	PCC	KL
1	1.178 4	0.981 6	0.005 4
2	1.027 5	0.985 9	0.004 1
3	1.025 6	0.986 0	0.004 1
4	1.144 8	0.982 9	0.005 3

由表2可以看出,PCC均为0.98以上,即生成参数与原始参数均呈现高度相关关系,生成对抗网络能够生成与原始排气温度参数较为相似的参数。ED与KL散度为相对值,其数值大小受参数幅值影响,故没有明确的范围标准,二者越小,表明参数间越相似。

3.3 在翼剩余寿命预测与讨论

为了验证本文方法的有效性,本文首先选择在RUL预测中得到广泛应用的支持向量回归(support vector regression, SVR)算法^[25],共包括以下4个步骤。

- 1) 将原始数据分为训练数据和测试数据;
- 2) 初始化SVR模型,使用训练数据训练SVR;
- 3) 将测试数据输入已完成训练的SVR模型,得到SVR的预测结果;
- 4) 利用评价指标评估RUL预测结果和RUL真实值之间的差异。

实验中,设计3组对比实验进行验证。3组对比实验分别为:1)仅使用预处理后的EGT作为寿命预测模型输入;2)将预处理后的EGT复制11维作为模型输入;3)将预处理后的EGT与10维生成参数共同作为模型输入。

本次实验采用APU在翼864个Cycles的状态监测数据,即从APU装备于飞机服役开始,至寿命结束过程中的全部监测数据。实验中,将APU的前784个参数点作为训练参数,后80个参数作为测试参数,仅使用预处理后的EGT参数作为SVR的输入获得预测结果如图8所示。

图8中圈直线代表APU真实剩余寿命,星折线代表预测的APU剩余寿命,采用两个评价指标定量评价RUL预测结果:MAE=63.51, RMSE=72.52。因此,图8中RUL预测结果严重偏离真实RUL,且多数结果大于真实RUL。第2组对比实验将修正后的EGT数据复制成11维数据,作为SVR模型输入进行APU寿命预测,实验结果如图9所示。

由图9可以看出,RUL预测结果普遍低于真实RUL,采用两个评价指标定量评价RUL预测结果:MAE=49.80, RMSE=52.53。虽然与图8中的预测结果相比,MAE和RMSE值变小,但图9中多数预测结果为负值,实际应用中的参考价值较小。第3组对比实验将修正后的1维EGT数据与10维基于GAN生成的EGT数据作




图8 仅利用修正EGT参数基于SVR的RUL预测结果
Fig.8 RUL prediction results based on SVR only using the corrected EGT parameters




图9 基于SVR利用11维修正EGT参数的RUL预测结果
Fig.9 RUL prediction results based on SVR using the 11 D corrected EGT parameters

为SVR模型的输入,对APU进行寿命预测,实验结果如图10所示。




图10 基于SVR利用修正EGT参数与10维生成参数的RUL预测结果

Fig.10 RUL prediction results based on SVR using the corrected EGT parameters and 10 D generated parameters

由图 10 可以看出,本次实验的 RUL 预测结果与前两个实验相比能更好的预测 RUL 结果,采用两个评价指标定量评价 RUL 预测结果: $MAE = 13.87$, $RMSE = 17.95$, 预测结果明显优于前两个实验。

上述 3 组对比实验的评价指标如表 3 所示。对比以上 3 个实验的评价指标,使用复制训练参数的方式并没有明显提高 RUL 预测效果,其主要原因是将单一参数复制成多维参数,并没有丰富参数的多样性,而使用原始参数与生成参数作为预测模型的输入,有效降低了 MAE 与 RMSE,预测结果分别提升了 78.16% 和 75.25%。实验结果表明,所生成的参数有助于增强 RUL 的预测结果。

表 3 基于 SVR 的 RUL 预测结果评价

Table 3 RUL prediction result evaluation based on SVR

序号	输入参数	MAE	RMSE
1	1 维修正 EGT 参数	63.51	72.52
2	11 维修正 EGT 参数	49.80	52.53
3	1 维修正 EGT 参数与 10 维生成参数	13.87	17.95

此外,为进一步验证本文提出方法的应用效果,在实验条件设置与 SVR 方法相同的条件下,采用基于高斯过程回归(Gaussian process regression, GPR)方法、受限玻尔兹曼机与极限学习机(restricted Boltzmann machine-extreme learning machine, RBM-ELM)融合方法开展实验验证^[26-28],结果如表 4 和 5 所示。

表 4 基于 GPR 的 RUL 预测结果评价

Table 4 RUL prediction result evaluation based on GPR

序号	输入参数	MAE	RMSE
1	1 维修正 EGT 参数	11.72	13.53
2	11 维修正 EGT 参数	253.41	262.75
3	1 维修正 EGT 参数与 10 维生成参数	5.72	6.94

表 5 基于 RBM-ELM 的 RUL 预测结果评价

Table 5 RUL prediction result evaluation based on RBM-ELM

序号	输入参数	MAE	RMSE
1	1 维修正 EGT 参数	143.11	158.01
2	11 维修正 EGT 参数	143.11	158.01
3	1 维修正 EGT 参数与 10 维生成参数	130.80	152.29

表 4 所示实验结果中,使用 1 维修正 EGT 参数与 10 维生成参数获得 RUL 预测结果的 MAE 和 RMSE,相比于仅用 1 维修正参数提升了 51.19% 和 48.71%,较使用 11 维相同的修正参数提升了 97.74% 和 97.34%。表 5 所示的实验结果是一种典型深度学习方法的实验结果,其中

仅采用 1 维修正参数获得的预测结果与采用复制的 11 份修正参数预测结果一样,说明了与其他两种传统方法相比,深度学习方法更加需要输入参数的多样性,才能获得较好的 RUL 预测结果。相比而言,RBM-ELM 采用 1 维修正参数与 10 维生成参数,可将预测结果的 MAE 和 RMSE 提升了 8.55% 和 3.62%。

上述基于 SVR、GPR 和 RBM-ELM 3 种方法开展的 RUL 预测对比实验结果表明,利用基于 GAN 生成的多维参数,可有效提升 APU 在翼故障预测结果的准确性。GAN 网络中的生成器不断训练,可使得生成的数据特征更加符合原始数据的特征;判别器不断训练,是为了区分生成的数据和原始数据。最终,生成器能模拟原始数据,判别器已无力区分生成数据与原始数据。本文研究过程中,采用生成的 10 维生成参数,验证了提出的参数扩增方法的有效性。随着参数维度的增加,预测效果会有一定程度上有所改进,但并不会无限制的提升预测结果的准确性,过多的相似参数也会对数据驱动方法产生一定的负作用,基于 RBM-ELM 采用 11 维相同参数的预测结果与 1 维参数结果相同,与基于 SVR 和 GPR 方法存在明显的区别,在一定程度上也验证了过多的参数具有局限性。此外,过多的参数也会对实际工程应用带来挑战,例如需要较高的计算资源实现大量数据的计算和分析。

4 结 论

本文针对飞机辅助动力装置因缺少退化表征参数而难以获得较好剩余寿命预测结果的问题,提出了一种基于生成对抗网络的参数扩增方法。生成对抗网络中的生成器与判别器的参数采用网格搜索法确定。采用中国南方航空股份有限公司机队的实际监测数据,通过 3 种故障预测方法开展了基于原始参数、原始参数复制多维、以及共同利用原始参数与扩增参数的对比实验。实验结果表明,本文提出性能参数扩增方法,可有效提升飞机辅助动力装置故障预测结果的准确性。

本文方法在一定程度上解决了由于退化参数较少而导致的剩余寿命预测结果较差的问题,虽然通过实际数据进行了方法验证,后续在实际工程应用推广中,需要更进一步考虑生成 EGT 的维度。此外,在建立辅助动力装置物理模型可行的条件下,可考虑数据驱动方法与物理模型的融合型方法,进一步提升故障预测结果的准确性。

参考文献

- [1] 黄国平, 梁德旺, 何志强. 大型飞机辅助动力装置与微型涡轮发动机技术特点对比 [J]. 航空动力学报, 2008, 23(2): 383-388.
- HUANG G P, LIANG D W, HE ZH Q. Comparison of technical characteristics of APU and microturbine engines

- for large aircraft [J]. *Journal of Aerospace Power*, 2008, 23(2): 383-388.
- [2] TAM C K W, PARRISH S A, XU J, et al. Indirect combustion noise of auxiliary power units [J]. *Journal of Sound and Vibration*, 2013, 332(17): 4004-4020.
- [3] ANGHEL C. A novel start system for an aircraft auxiliary power unit [J]. *Energy Conversion Engineering Conference and Exhibit*, 2000: 7-11.
- [4] LETOURNEAU S, YANG C SH, LIU Z K. Improving preciseness of time to failure predictions: Application to APU starter [C]. *IEEE International Conference on Prognostics and Health Management*, 2008: 1-7.
- [5] YANG C SH, LOU Q F, LIU J, et al. Particle filter-based method for prognostics with application to auxiliary power unit. *modern advances in applied intelligence* [J]. Springer International Publishing, 2014: 198-207.
- [6] SAMSUN R C, KRUPP C, TSCHAUDER A, et al. Electrical start-up for diesel fuel processing in a fuel-cell-based auxiliary power unit [J]. *Journal of Power Sources*, 2016, 302: 315-323.
- [7] YANG C SH, LETOURNEAU S, ZALUSKI M, et al. APU FMEA validation and its application to fault identification [C]. *International Design Engineering Technical Conferences and Computers and Information in Engineering Conference*, 2010: 959-967.
- [8] YANG C SH, LETOURNEAU S, YANG Y B, et al. Data mining based fault isolation with FMEA rank: A case study of APU fault identification [C]. *IEEE Prognostics and Health Management*, 2013: 1-6.
- [9] YANG C SH, LETOURNEAU S, ZALUSKI M. Using the validated FMEA to update trouble shooting manuals: A case study of APU TSM revision [C]. *Annual Conference of the Prognostics and Health Management Society*, 2011: 1-11.
- [10] AN D, KIM N H, CHOI J H. Practical options for selecting data-driven or physics-based prognostics algorithms with reviews [C]. *Reliability Engineering & System Safety*, 2015, 133: 223-236.
- [11] LIU X L, LIU L SH, LIU D T, et al. A hybrid method of remaining useful life prediction for aircraft auxiliary power unit [J]. *IEEE Sensors Journal*, 2020, DOI: 10.1109/JSEN.2020.2979797.
- [12] LIU L SH, PENG Y, WANG L L, et al. Improving EGT sensing data anomaly detection of Aircraft Auxiliary Power Unit [J]. *Chinese Journal of Aeronautics*, 2020, 33(2): 448-455.
- [13] 彭宇, 刘大同. 数据驱动故障预测和健康管理综述 [J]. *仪器仪表学报*, 2014, 33(3): 481-495.
- PENG Y, LIU D T. Data-driven prognostics and health management: A review of recent advances [J]. *Chinese Journal of Scientific Instrument*, 2014, 33(3): 481-495.
- [14] 刘大同, 周建宝, 郭力萌, 等. 锂离子电池健康评估和寿命预测综述 [J]. *仪器仪表学报*, 2015, 36(1): 1-16.
- LIU D T, ZHOU J B, GUO L M, et al. Survey on lithium-ion battery health assessment and cycle life estimation [J]. *Chinese Journal of Scientific Instrument*, 2015, 36(1): 1-16.
- [15] POGGIO T, VETTER T. Recognition and structure from one 2D model view: Observations on prototypes, object classes and symmetries [J]. *Massachusetts Institute of Technology Artificial Intelligence Laboratory*, 1992, 1347: 1-25.
- [16] 温津伟, 罗四维, 赵嘉莉, 等. 通过创建虚拟样本的小样本人脸识别统计学习方法 [J]. *计算机研究与发展*, 2002, 39(7): 814-818.
- WEN J W, LUO S W, ZHAO J L, et al. A small sample face recognition statistical learning method based on virtual samples [J]. *Journal of Computer Research and Development*, 2002, 39(7): 814-818.
- [17] 高克铨, 李志刚, 徐长明, 等. 混合整体趋势扩散的虚拟样本构建及其血液光谱分析应用 [J]. *仪器仪表学报*, 2019, 40(8): 167-175.
- GAO K X, LI ZH G, X CH M, et al. Virtual sample establishment of Hybrid-MTD and its application in blood spectrum analysis [J]. *Chinese Journal of Scientific Instrument*, 2019, 40(8): 167-175.
- [18] BISHOP C M. Training with noise is equivalent to Tikhonov regularization [J]. *Neural Computation*, 1995, 7(1): 108-116.
- [19] LI D CH, LIN Y S. Using virtual sample generation to build up management knowledge in the early manufacturing stages [J]. *European Journal of Operational Research*, 2006, 175(1): 413-434.
- [20] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets [C]. *Advances in Neural Information Processing Systems*, 2014: 2672-2680.
- [21] LEE Y O, JO J, HWANG J. Application of deep neural network and generative adversarial network to industrial maintenance: A case study of induction motor fault detection [C]. *IEEE International Conference on Big Data*, 2017: 3248-3253.
- [22] WANG Z R, WANG J, WANG Y R. An intelligent diagnosis scheme based on generative adversarial learning deep neural networks and its application to planetary gearbox fault pattern recognition [J]. *Neurocomputing*,

- 2018, 310(10) : 213–222.
- [23] SHAO S Y, WANG P, YAN R Q. Generative adversarial networks for data augmentation in machine fault diagnosis [J]. Computers in Industry, 2019, 106: 85–93.
- [24] LI Q, GAO Z B, TANG D Y, et al. Remaining useful life estimation for deteriorating systems with time-varying operational conditions and condition-specific failure zones [J]. Chinese Journal of Aeronautics, 2016, 29(3) : 662–674.
- [25] TRAN V T, PHAM H T, YANG B S, et al. Machine performance degradation assessment and remaining useful life prediction using proportional hazard model and support vector machine [J]. Mechanical Systems and Signal Processing, 2012, 32: 320–330.
- [26] LIU L SH, WANG SH J, LIU D T, et al. Quantitative selection of sensor data based on improved permutation entropy for system remaining useful life prediction [J]. Microelectronics Reliability, 2017, 75: 264–270.
- [27] LIU L SH, GUO Q, LIU D T, et al. Data-driven remaining useful life prediction considering sensor anomaly detection and data recovery [J]. IEEE Access, 2019, 7: 58336–58345.
- [28] LIU X L, LIU L SH, WANG L L, et al. Performance sensing data prediction for an aircraft auxiliary power unit using the optimized extreme learning machine [J]. Sensors, 2019, 19, 3935.

作者简介



刘连胜, 2006 年、2008 年和 2017 年于哈尔滨工业大学分别获得学士、硕士和博士学位, 现为哈尔滨工业大学副教授, 主要研究方向为信息物理系统、无人系统感知技术、故障预测与健康管理等。

E-mail: lianshengliu@hit.edu.cn

Liu Liansheng received his B.Sc., M.Sc. and Ph.D. degrees all from Harbin Institute of Technology in 2006, 2008 and 2017, respectively. He is currently an associate professor at Harbin Institute of Technology. His main research interests include cyber physical system, unmanned system sensing technology, fault prognostics and health management, etc.



王璐璐, 2000 年于南京航空航天大学获得学士学位, 2009 年于东北大学获得硕士学位, 现为中国南方航空股份有限公司沈阳维修基地 APU 中心主任, 主要研究方向为飞机辅助动力装置维修技术、工程管理和机队可靠性管理等。

E-mail: wanglulu@csair.com

Wang Lulu received her B.Sc. degree from Nanjing University of Aeronautics and Astronautics in 2000 and received her M.Sc. degree from Northeastern University in 2009. She is currently the director of the APU center at Shenyang Maintenance Base, China Southern Airlines Company Limited. Her main research interests include aircraft auxiliary power unit repair technique, engineering management and fleet reliability management, etc.



梁军(通信作者), 1993 年于重庆大学获得学士学位, 2001 年和 2009 年于哈尔滨工业大学分别获得硕士和博士学位, 现为哈尔滨工业大学副教授, 主要研究方向为统计信号处理和故障预测与健康管理等。

E-mail: hitliangjun2012@126.com

Liang Jun (Corresponding author) received his B.Sc. degree from Chongqing University in 1993, received his M.Sc. and Ph.D. degrees both from Harbin Institute of Technology in 2001 and 2009, respectively. He is currently an associate professor at Harbin Institute of Technology. His main research interests include statistical signal processing, fault prognostics and health management, etc.