

# 双向 LSTM 神经网络的航空发动机故障预测

曾慧洁, 郭建胜

(空军工程大学大学装备管理与无人机工程学院, 西安, 710051)

**摘要** 准确的航空发动机故障预测能够为维修决策提供依据, 提高装备完好率, 避免灾难性故障并最小化经济损失。根据航空发动机传感器数据特点, 提出一种基于双向长短期记忆(LSTM)神经网络的故障预测方法, 建立故障预测模型, 包括数据预处理、网络模型设计、训练与测试, 得到在多种工作条件和故障下具有较强泛化能力的神经网络预测模型。使用 C-MAPSS 数据集对模型进行仿真验证, 所提出的双向 LSTM 故障预测模型通过与 RNN、GRU、LSTM 时间序列模型对比, 误差下降 33.58%, 得到更高的预测精度, 非对称评分下降 71.22%, 具有更好的适应性。

**关键词** 故障预测; 时间序列; 双向 LSTM 神经网络

**DOI** 10.3969/j.issn.1009-3516.2019.04.004

**中图分类号** V23; TP183 **文献标志码** A **文章编号** 1009-3516(2019)04-0026-07

## Fault Prognostic of Aeroengine Using Bidirectional LSTM Neural Network

ZENG Huijie, GUO Jiansheng

(Equipment Management and UAV Engineering College, Air Force Engineering University, Xi'an 710051, China)

**Abstract:** Aeroengine fault prognostic can provide basis for maintenance decision-making which can help to avoid catastrophic failures and minimize economic losses. According to the characteristics of aeroengine sensor data, a fault prognostic method based on bidirectional long short-term memory (LSTM) neural network is proposed. A fault prognostic model is established, including data preprocessing, network design, training and testing. The model structure has strong generalization ability under various working conditions and faults is obtained. The model was validated using the C-MAPSS data set. Compared with the RNN, GRU and LSTM time series models, the results show that the proposed Bidirectional LSTM fault prognostic model has an average error of 33.58%, which has better adaptability. The asymmetric score decreased by 71.22%, resulting in higher prediction accuracy.

**Key words:** fault prognostic; time sequence; bidirectional LSTM neural network

随着航空发动机向集成化、复杂化的发展, 其性能水平不断提高, 可能发生的故障越发多样, 导致维修难度和成本大幅增加。有效预测发动机可能出现

的故障, 提前采取预防措施, 从而节约经济成本, 提高航空发动机可靠性。为实现有效预测, 应充分运用各类传感器数据, 通过采集分析, 建立模型预测故

收稿日期: 2019-05-07

作者简介: 曾慧洁(1995—), 女, 北京人, 硕士生, 主要从事装备系统工程与管理决策、数据挖掘、机器学习研究。E-mail: bonnie1995@126.com

引用格式: 曾慧洁, 郭建胜. 双向 LSTM 神经网络的航空发动机故障预测[J]. 空军工程大学学报(自然科学版), 2019, 20(4): 26-32. ZENG Huijie, GUO Jiansheng. Fault Prognostic of Aeroengine using Bidirectional LSTM Neural Network[J]. Journal of Air Force Engineering University (Natural Science Edition), 2019, 20(4): 26-32.

障。由于传感器采集的发动机状态监控数据具有多种类、多样化的特点,需要挖掘数据之间的关联性为故障预测提供支持。因此,基于传感器数据对航空发动机进行准确的故障预测成为当前重要的研究内容。

对于航空发动机这类复杂度高的系统,传统的基于物理模型的故障预测方法难以构建准确的退化模型,预测精度不高,在应用上具有局限性<sup>[1-3]</sup>。数据驱动的预测方法则不需要广泛的先验知识,可根据采集到的数据直接进行预测,在处理系统变化与监测数据的非线性关系更有优势。

在数据驱动方法中,神经网络是解决复杂系统预测问题有效的模型,可以直接对高度非线性、复杂、多维系统进行建模,挖掘数据与预测目标的映射关系。利用航空发动机在工作运行过程中产生的状态监测数据<sup>[4-5]</sup>,剩余使用寿命(Remaining Useful Life, RUL)能够显示航空发动机未来的健康状态趋势,航空发动机故障预测通常使用 RUL 进行表征。Tian<sup>[6]</sup>提出了一种人工神经网络方法估计设备的剩余寿命,Peel<sup>[7]</sup>等使用径向基网络对航空发动机进行故障预测。为克服径向基网络的方法不能直接得到剩余寿命估计的置信界限这一缺点,Khawaja<sup>[8]</sup>等引入了一种带有置信分布节点的神经网络预测方法。马里<sup>[9]</sup>等提出了一种利用循环神经网络(Recurrent Neural Network, RNN)进行机器健康状态长期预测的基于竞争学习的方法,郭亮<sup>[10]</sup>等提出一种基于 RNN 的滚动轴承健康指标预测方法。然而 RNN 的权重参数经过多阶段传播后出现梯度消失或者梯度爆炸,导致无法更新网络。Yuan<sup>[11]</sup>等提出了一种基于长短期记忆(Long Short-Term Memory, LSTM)神经网络的方法用于噪声情况下航空发动机的剩余使用寿命估计,LSTM 模型可以有效解决梯度弥散的问题。

在进行模型构建时,LSTM 模型只能访问每个特定时间步骤,无法关注到未来时刻与当前时刻的相关关系。然而在航空发动机故障预测中,对于临近的监控数据都可以评价当前时刻发动机健康状态。双向 LSTM 不仅解决了长期依赖的问题,实现时间序列的长期记忆,并能够在正向和反向同时处理序列数据<sup>[12]</sup>,为序列中每个时刻提供过去和未来的序列信息,发现更多数据特征,得到更准确充分的预测规律。目前该方法已经成功应用于语音识别<sup>[13]</sup>、序列标记<sup>[14]</sup>、自然语言处理<sup>[15]</sup>等多个领域。虽然双向 LSTM 已经显示出强大时间序列预测能力,但是在故障预测问题上的应用研究非常有限。

为捕捉更多局部特征以实现更准确的预测,本

文针对航空发动机时间序列数据特点,建立基于双向 LSTM 的故障预测模型,包括数据预处理、模型详细设计和模型评价指标。使用 C-MAPSS 数据集进行仿真验证,并与 RNN、LSTM 等神经网络序列模型对比。

## 1 双向 LSTM 循环神经网络

### 1.1 LSTM 循环神经网络

LSTM 循环神经网络通过门结构学习长时间窗中的依赖关系,网络中的激活函数实现短期记忆,权重的更新用于长时记忆。其单元结构见图 1,其中  $C_{t-1}$  为上一步的细胞状态,  $h_{t-1}$  为先前隐藏状态的输出值,  $x_t$  为当前 LSTM 单元的输入。  $C_t$  为更新后的细胞状态,  $h_t$  为当前隐藏状态的输出值。LSTM 单元的核心是细胞状态,细胞状态沿时间序列传输相关信息,实现其状态的更新由遗忘门、输入门和输出门决定。

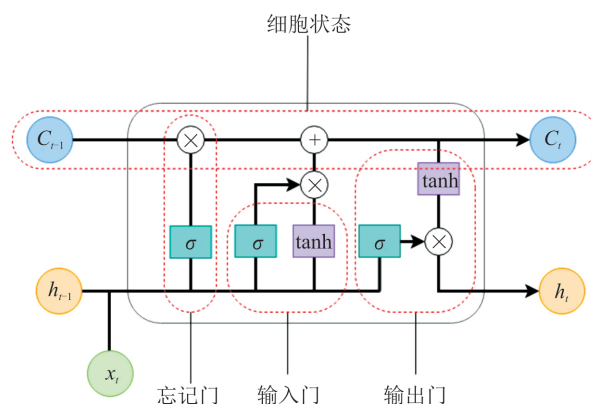


图 1 LSTM 单元

遗忘门  $f_t$  决定应该丢弃或保留信息的多少,可以表示为:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1)$$

式中:  $f_t$  由先前隐藏状态信息和当前输入信息传递给 sigmoid 函数;  $W_f$  为权重项;  $b_f$  为偏置项。

输入门  $i_t$  确定如何更新细胞状态,即将新的信息选择性记录到细胞状态中。可以表示为:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (3)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (4)$$

式中:  $h_{t-1}$  和  $x_t$  传递给 sigmoid 函数,同时将其传入 tanh 激活函数,得到细胞状态候选值  $\tilde{C}_t$ ,两者共同决定新的细胞状态  $C_t$ 。

输出门  $o_t$  决定当前隐藏状态的输出,与输入门类似,  $h_t$  由  $o_t$  和  $C_t$  确定携带的信息。可以表示为:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (5)$$

$$h_t = o_t * \tanh(C_t) \quad (6)$$

## 1.2 双向 LSTM 循环神经网络

基于时间序列的预测,当前时间点临近过去和未来的序列信息都可用于评估当前时刻,且不依赖预定义参数。然而 LSTM 神经网络只能使用某一时刻之前的输入信息来预测结果。双向 LSTM 则基于整个时间序列对输出进行预测,首先将隐藏层神经元分成正时间方向和负时间方向 2 个部分,具有 2 个独立的隐藏层,然后前馈到相同的输出层,同时包括过去和未来的序列信息。双向 LSTM 结构见图 2。第 1 层 LSTM 计算当前时间点顺序信息,第 2 层 LSTM 反向读取相同的序列,添加逆序信息,每层 LSTM 具有不同参数。LSTM 层之间的隐藏输出不仅传递到相邻单元,还作用于下一 LSTM 层的输入。在进行训练时,由于 2 种状态神经元之间无相互作用,因此可以展开为一个通用的前馈网络。通过对输出神经元的正向和反向传播,完成对网络权重的更新。

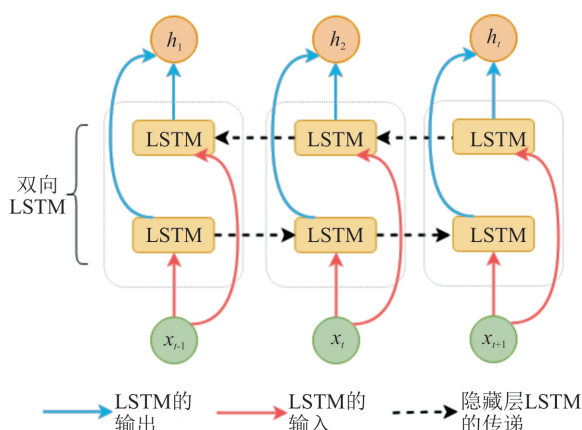


图 2 双向 LSTM 结构

## 2 基于双向 LSTM 的故障预测模型

基于双向 LSTM 的故障预测模型流程见图 3。首先,对数据集进行预处理,并为训练集和测试集添加 RUL 标签。该网络的输入为时间序列长度和特征数,并设置相应的时间窗大小。根据时间窗大小,对每台发动机的时间序列进行划分,以二维格式的归一化数据直接用作模型输入。根据每个 batch 的平均损失函数,调整神经网络权重参数,最小化损失函数值。接下来,设置全连接层的输出为标签的维度、激活函数和 Dropout 概率。重复以上步骤,当损失函数值达到阈值或到达最大迭代次数,结束模型训练。训练样本标记的剩余寿命值作为模型的目标输出。将测试集输入该模型,通过评价指标判断模型训练效果。由前述分析可知,RUL 与航空发动机故障预测有着紧密联系,因此在这里以及后续的仿真验证中使用 RUL 作为判别标准。

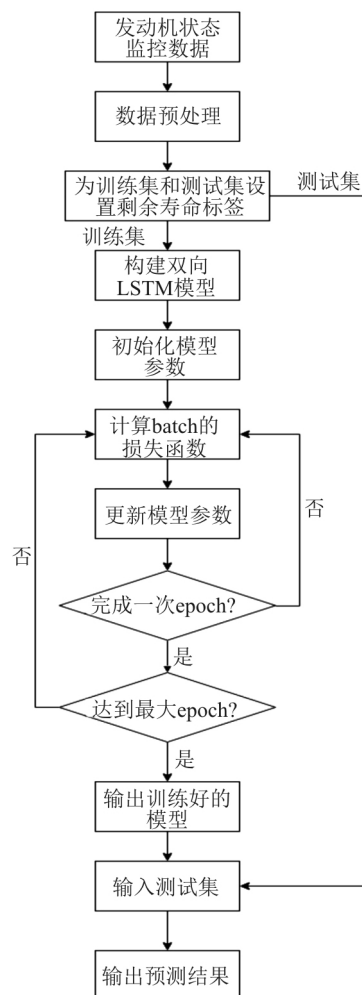


图 3 双向 LSTM 神经网络故障预测模型流程图

### 2.1 数据预处理

首先设置样本标签。为使模型在训练时呈现真实值与预测值的对比,需要对数据添加 RUL 标签。由于系统的退化有一个发展的过程,通常在运行一段时间内可忽略不计,因此在系统开始退化之前估计 RUL 是不合理的。为解决这类问题,使用 Ramas-so<sup>[16]</sup>提出的分段线性退化模型进行预测,见图 4。




图 4 分段线性退化模型

循环代表完成 1 次飞行,在实际变化过程中,RUL 与循环数始终保持线性关系。该模型假设航空发动机在早期循环中有 1 个常值,在某一次循环后开始线性退化,直到达到 0。通过多次实验,当 RUL 值设定为 120 时,测试集具有较好的预测效果。

不同传感器读数范围是不同的,直接使用无法在一定的迭代次数中训练出最好的模型。为提高模型的收敛速度和精度,本模型使用 Min-Max 方法对数

据归一化,保证测量数据都在 $[-1,1]$ 的范围内。

## 2.2 故障预测模型

故障预测模型结构见图 5。

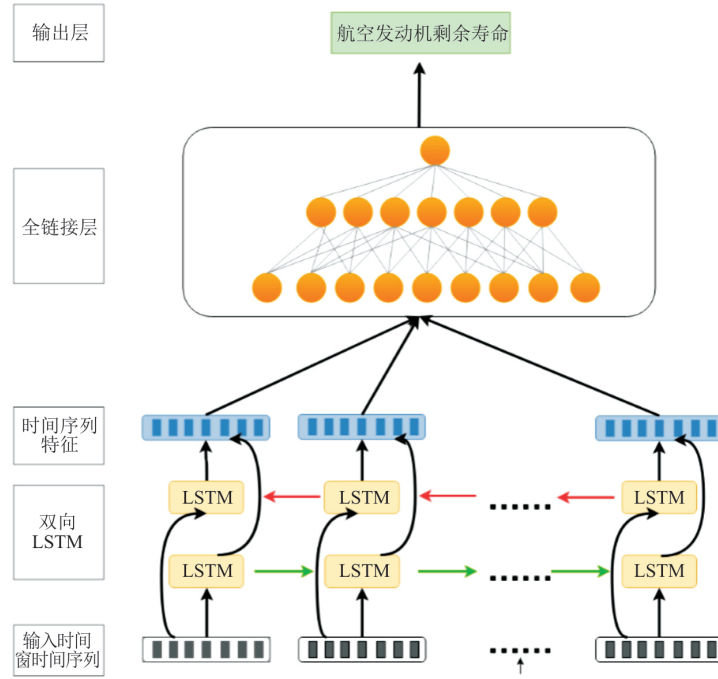


图 5 故障预测模型

对于第  $l$  台航空发动机,包含  $n$  条数据,每条数据有  $m$  个传感器读数。设置时间窗大小为  $s$ 。则每次模型输入矩阵表示为  $x_t$ :

$$x_t = \begin{bmatrix} x_t^1 & x_t^2 & \cdots & x_t^m \\ x_{t+1}^1 & x_{t+1}^2 & \cdots & x_{t+1}^m \\ \vdots & \vdots & & \vdots \\ x_{t+s-1}^1 & x_{t+s-1}^2 & \cdots & x_{t+s-1}^m \end{bmatrix} \quad (7)$$

每个时间窗对应的真实 RUL 可以表示为:

$$y_t = f(x_t, y_{t-1}, y_{t-2}, \cdots, y_{t-ts}) \quad (8)$$

RUL 预测值  $\hat{y}_t$  通过传感器数据的变化和时间窗内的 RUL 值得到相关关系:

$$\hat{y}_t = \hat{f}(x_t, \hat{y}_{t-1}, \hat{y}_{t-2}, \cdots, \hat{y}_{t-ts}) \quad (9)$$

式中:预先定义故障阈值  $y_{\text{threshold}}$ ,当预测值最接近阈值时,保留该值记为  $\text{pred}_t$ (简记为  $p_t$ ),其关系为:

$$p_t = \inf\{\hat{f}_t : \hat{y}_t \leq y_{\text{threshold}}\} \quad (10)$$

在双向 LSTM 的网络中,通过向前隐藏层状态  $\vec{h}_t$  和向后隐藏层状态  $\overleftarrow{h}_t$  得到输出  $p_t$ 。在  $t=1$  到  $T$  方向上,  $W_{x\vec{h}_t}$  为当前神经元的输入  $x$  到此刻隐藏层  $\vec{h}_t$  的权重,  $W_{\vec{h}_t\overleftarrow{h}_t}$  为上一时刻状态量到当前状态量的权重,  $\vec{h}_{t-1}$  为上一时刻隐藏层状态输出值,  $b_{\vec{h}_t}$  为偏移项,可表示为:

$$\vec{h}_t = \sigma(W_{x\vec{h}_t} x_t + W_{\vec{h}_t\overleftarrow{h}_t} \overleftarrow{h}_{t-1} + b_{\vec{h}_t}) \quad (11)$$

在  $t=T$  到 1 方向上与正序计算方法一致:

$$\overleftarrow{h}_t = \sigma(W_{x\overleftarrow{h}_t} x_t + W_{\overleftarrow{h}_t\vec{h}_t} \vec{h}_{t-1} + b_{\overleftarrow{h}_t}) \quad (12)$$

双向 LSTM 在 2 个方向同时迭代,将隐藏层状态加权计算得到预测值  $p_t$ ,表示为:

$$p_t = W_{\vec{h}_p} \vec{h}_t + W_{\overleftarrow{h}_p} \overleftarrow{h}_t + b_p \quad (13)$$

为防止过拟合,本模型在双向 LSTM 层与全连接层中添加一个 Dropout 层,按照一定的概率将隐藏层输出值丢弃,保证神经元在训练过程中不会影响正向传播。将每个步长采集到的时间序列特征传入全连接层,设置激活函数为 ReLU,输出故障预测结果  $p_t$ ,每个样本最终输出为  $\{p_1, p_2, \cdots, p_{n-ts}\}$ 。对于模型的训练,使用均方误差 (Mean Squared Error, MSE) 作为模型损失函数。

## 2.3 评价标准

为评估故障预测模型的性能,本文使用均方根误差 (Root Mean Square Error, RMSE) 和非对称评分函数<sup>[17]</sup>作为评价指标。非对称评分标准能够对提前和延后预测产生不同的惩罚结果,评分与误差成正比,相同误差下延后预测的惩罚高于提前预测。其函数形式为:

$$S = \frac{1}{N} \sum_{i=1}^N s_i \quad (14)$$

$$s_i = \begin{cases} e^{-\frac{d_i}{13}} - 1, & d_i < 0 \\ e^{\frac{d_i}{10}} - 1, & d_i \geq 0 \end{cases} \quad (15)$$

式中:  $N$  为测试集中的样本总数;  $d_i = p_i - y_i$  为剩余寿命预测值  $p_i$  和真实值  $y_i$  的误差。




### 3 仿真验证

#### 3.1 C-MAPSS 数据集

本模型使用 C-MAPSS 数据集进行仿真验证。C-MAPSS 数据集包含航空发动机从正常使用到发生系统故障的全过程。数据集可划分为 4 个子集,包括 6 种不同的工作条件和 4 种故障模式。C-MAPSS 数据集基本信息见表 1。

表 1 C-MAPSS 数据集基本信息

数据集	训练集	测试集	工作条件	故障模式
FD001	100	100	1	1
FD002	260	259	6	1
FD003	100	100	1	2
FD004	248	248	6	2



以子集 FD004 为例,训练集中包含 248 台发动机在 6 种工作条件下从正常到发生不同故障的所有飞行循环状态监控数据,测试集中包含 248 台发动机正常使用时的飞行循环状态监控数据用于模型验证。子集 FD001、FD002、FD003 分别对应单一工作条件单个故障、多种工作条件单个故障和单一工作条件多个故障的情况。

每条数据是由发动机编号、飞行循环数、3 个操作条件和 21 个传感器读数组成的多变量时间序列。图 6 展示了 FD001 数据集中 1 号发动机风扇进口总温  $T_2$ 、低压涡轮出口总温  $T_{50}$ 、高压压气机出口总压  $P_{30}$  和核心机物理转速  $N_c$  的传感器读数,不同传感器在使用中变化方式有所差异。




图 6 FD001 中 1 号发动机传感器读数变化曲线

#### 3.2 仿真条件

仿真的软硬件环境为 NVIDIA GeForce GTX 1070、Intel Core i7-8750h CPU、16G RAM、Windows 10、Python3.6 和 Keras2.2.4,后端为 TensorFlow。

模型的各层参数设置如表 2 所示。时间窗  $s$  设置为 30,双向 LSTM 包含 2 个 LSTM 层,每个 LSTM 层的输出单元数量为 100。经过多次测试,Dropout 层输入单元的丢弃比率设置为 0.5 时具有最好的效果。全连接层输出维度为 1,即预测 RUL 值。

表 2 模型参数设置

网络层	输出维度	参数个数
双向 LSTM	(30, 200)	100 800
Dropout	(30, 200)	0
全连接层	1	31
激活层	1	0

#### 3.3 仿真验证

图 7 展示了本方法在 4 个子集中的剩余寿命预测效果。纵坐标为真实 RUL 值,横坐标为飞行循环数。由图所示,发动机预测值分布在真实值附近。在前期,RUL 预测值接近常数。若干个飞行循环之后,预测值呈线性递减,预测未来状态和实际未来状态变化趋势始终保持一致。特别地,当发动机临近故障时,预测准确性仍保持较高水平。因此本模型更易捕捉到提前预测的数据特征,具有较强的泛化能力和较高的可行性,有助于提高发动机的可靠性,提升装备完好率。

表 3 总结了本文提出的方法与 LSTM、GRU (Gated Recurrent Unit)、RNN 种序列预测方法进行对比的结果。在 4 个子集中,本模型 RMSE 的结

果优于所有对比模型。在 FD002 数据集中,本模型非对称评分的结果与 GRU 结果接近,但不是最优,其余数据集表现得明显优于所有对比模型。此外,RNN 模型在 FD001 数据集上与本文结果接近,但是本模型的计算效率有明显优势,在面对复杂的工作状况和故障下,具有更高的预测准确程度。同时,当模型复杂度不改变时,对于退化过程复杂的数据集预测精确度都保持在 70% 以上。因此,双向 LSTM 模型通用性强,且具有识别和学习多种工作状况和混合故障的能力。




图 7 各数据集的预测结果对比图

表 3 序列模型结果对比

模型	标准	FD001	FD002	FD003	FD004
LSTM	RMSE	17.17	26.92	28.91	38.80
	SCORE	23.95	1 153.86	1 986.79	5 421.15
GRU	RMSE	36.43	26.70	52.89	29.46
	SCORE	114.79	222.71	1 095.88	3 367.71
RNN	RMSE	15.44	24.48	24.90	28.83
	SCORE	339.2	14 245	475.10	1 3931
双向 LSTM	RMSE	13.79	24.03	13.36	24.02
	SCORE	20.14	224.21	315.70	1 211.93

4 结语

本文提出了一种基于双向 LSTM 的故障预测模型,根据传感器数据特点进行数据预处理,使用 C-MAPSS 数据集进行仿真并验证了模型的有效性。该模型取得了较好的预测效果,预测结果与实际的剩余寿命值误差较小。通过与常用神经网络结构比较,证明了所提出的双向 LSTM 模型适合于航空发动机故障预测问题。在不同评价指标下,该模型都有较高预测精度,具有良好的应用前景。

未来的工作将尝试对模型中间层的输出进行解释,并进一步研究与双向 LSTM 组合的深度神经网络对不同应用的有效性。

参考文献(References):

[1] 杨延飞,雷倩倩,王春兰. 基于边界扫描技术的 FPGA 延时故障检测[J]. 纺织高校基础科学学报,2017,30(3):396-401.  
YANG Y F,LEI Q Q,WANG C L. The Detection of Delay Defects in FPGA Based on Boundary Scan[J]. Basic Sciences Journal of Textile Universities,2017,30(3):396-401. (in Chinese)

[2] 师少达,宋玉琴,刘西川. BFOA-EEMD 在轴承故障诊断中的应用[J]. 西安工程大学学报,2019,33(3):290-295.  
SHI S D,SONG Y Q,LIU X C. Application of BFOA-EEMD in Bearing Fault Diagnosis[J]. Journal of Xi'an Polytechnic University,2019,33(3):290-295. (in Chinese)

[3] 朱玉斌,方中祥,侯朝焕,等. 基于部件参数估计的航空发动机故障预测技术研究[J]. 测控技术,2012,31(1):128-131.  
ZHU Y B,FANG Z X,HOU C H, et al. A Health Prognostics Approach Research for Turbofan Engine [J]. Measurement & Control Technology, 2012, 31(1):128-131. (in Chinese)

[4] 张马兰. 基于空地数据链的航空发动机剩余寿命预测研究[D]. 南京:南京航空航天大学,2015.

- ZHANG M L . Research on Remaining Useful Life Prognostics for Aero-Engine Based on ACARS[D]. Nanjing: Nanjing University of Aeronautics and Astronautics, 2015. (in Chinese)
- [5] 黄亮, 刘君强, 贡英杰. 基于一致性检验的航空发动机剩余寿命预测[J]. 系统工程与电子技术, 2018, 40(12): 2736-2742.
- HUANG L, LIU J Q, GONG Y J. Residual Lifetime Prediction of Aeroengines Based on the Consistency Test[J]. Systems Engineering and Electronics, 2018, 40(12): 2736-2742. (in Chinese)
- [6] TIAN Z G. An Artificial Neural Network Approach for Remaining Useful Life Prediction of Equipments Subject to Condition Monitoring[C]//2009 8th International Conference on Reliability, Maintainability and Safety. Chengdu, China; ICRMS, 2009: 143-148
- [7] PEEL L . Data Driven Prognostics Using a Kalman Filter Ensemble of Neural Network Models[C]//2008 International Conference on Prognostics and Health Management. Denver, CO, USA; ICPHM, 2008: 1-6.
- [8] KHAWAJA T , VACHTSEVANOS G , WU B . Reasoning about Uncertainty in Prognosis: A Confidence Prediction Neural Network Approach [C]//NAFIPS 2005 Annual Meeting of the North American Fuzzy Information Processing Society. Detroit, MI, USA; NAFIPS, 2005: 7-12.
- [9] MALHI A , YAN R , GAO R X . Prognosis of Defect Propagation Based on Recurrent Neural Networks [J]. IEEE Transactions on Instrumentation & Measurement, 2011, 60(3):703-711.
- [10] GUO L, LI N, JIA F, et al. A Recurrent Neural Network Based Health Indicator for Remaining Useful Life Prediction of Bearings [J]. Neurocomputing, 2017, 240:98-109.
- [11] YUAN M , WU Y , LIN L . Fault Diagnosis and Remaining Useful Life Estimation of Aero Engine Using LSTM Neural Network[C]//2016 IEEE International Conference on Aircraft Utility Systems (AUS). Beijing: IEEE, 2016: 135-140.
- [12] SCHUSTER M, PALIWAL K K. Bidirectional Recurrent Neural Networks[J]. IEEE Transactions on Signal Processing, 1997, 45(11):2673-2681.
- [13] LIPTON Z C, BERKOWITZ J, ELKAN C. A Critical Review of Recurrent Neural Networks for Sequence Learning [J]. Computer Science, 2015: arXiv: 1506.00019.
- [14] GRAVES A, JAITLY N, MOHAMED A R . Hybrid Speech Recognition with Deep Bidirectional LSTM [C]//2013 IEEE Workshop on Automatic Speech Recognition and Understanding. Olomouc, Czech Republic; IEEE, 2013: 273-278.
- [15] LIU Y, SUN C J, LIN L , et al. Learning Natural Language Inference Using Bidirectional LSTM Model and Inner-Attention[EB/OL]. (2016-05-30)(2019-05-01). <https://arxiv.org/pdf/1605.09090.pdf>.
- [16] RAMASSO E . Investigating Computational Geometry for Failure Prognostics in Presence of Imprecise Health Indicator : Results and Comparisons on C-MAPSS Datasets[J]. Phmsociety Org, 2014, 5:1-18.
- [17] SAXENA A, GOEBEL K, SIMON D, et al. Damage Propagation Modeling for Aircraft Engine Run-to-failure Simulation[C]//2008 International Conference on Prognostics and Health Management. Denver, CO, USA; IEEE, 2008: 1-9.

(编辑: 姚树峰)