

基于 SVM 方法的 APU 故障预测方法

蔡坤烨 蔡 景 周 迪 泽 山

(南京航空航天大学民航学院,南京,211106)

摘要:针对辅助动力装置(Auxiliary power unit, APU)故障预测时,仅基于快速存取记录器(Quick access recorder, QAR)数据存在实时性欠缺或精度不足的问题,提出了基于实时报文数据的 APU 故障预测方法。首先,对报文所采集的数据进行预处理,将每次航班的报文数据规整为一条数据集;其次,从参数阈值、维修记录及 APU 序列号变化情况的角度对数据集进行标注工作;随后,针对特征选择算法具有较差解释性的缺点,提出通过相关性分析选取能够表征 APU 运行性能的参数;最后,建立基于支持向量机(Support vector machine, SVM)的多参数故障预测模型并优化。经验证,该模型提高了预测正确率,为 APU 视情维修策略的制定提供参考。

关键词:辅助动力装置(APU);报文系统;数据分析;故障预测;支持向量机

中图分类号:V267

文献标志码:A

文章编号:1005-2615(2019)04-0466-08

APU Fault Prediction Based on SVM Method

CAI Kunye, CAI Jing, ZHOU Di, ZE Shan

(College of Civil Aviation, Nanjing University of Aeronautics & Astronautics, Nanjing, 211106, China)

Abstract: Since in auxiliary power unit (APU) fault prediction quick access recorder (QAR) data cannot meet the requirement of real-time or accuracy, an APU fault prediction based on real-time message data is proposed. First, the data collected by the message is preprocessed, and the message data of each flight is organized and put into one data set. Second, the data set is marked from the perspectives of parameter threshold, maintenance record and changes of APU sequence number. Third, aiming at the poor interpretation of the feature selection algorithm, we select parameters that can characterize APU performance through correlation analysis. Finally, a multi-parameter fault prediction model based on support vector machine (SVM) is established and optimized. It is proved that this model can improve the prediction accuracy and provide reference for APU maintenance strategy.

Key words: auxiliary power unit (APU); report system; data analysis; fault prediction; support vector machine

辅助动力装置(Auxiliary power unit, APU)为地面上的飞机提供电源和气源并用于启动主发动机。APU 作为最低放行设备清单(MEL)中的保留故障项目,飞机在缺少地面电源和气源保障的情况下,APU 的失效或故障将导致飞机无法运行。因此,在目前航空公司越来越重视签派可靠度和经济性的情况下,如何提前预测 APU 故障以减少飞

机停机时间是一个受到普遍关注的问题。

通过对 APU 的 QAR 数据分析可知,APU 故障的发生是一个渐进过程,因此,可以通过分析 APU 的 QAR 历史数据,提前预判 APU 的潜在故障状态。目前这方面已开展相关研究,譬如高飞鹏等^[1]与李海然^[2]提出的基于 QAR 译码数据的 APU 故障诊断技术,用于检测 APU 启动电门故障与启

收稿日期:2018-10-10;修订日期:2019-05-10

通信作者:蔡景,男,博士,副教授,E-mail: caijing@nuaa.edu.cn。

引用格式:蔡坤烨,蔡景,周迪,等. 基于 SVM 方法的 APU 故障预测方法[J]. 南京航空航天大学学报,2019,51(4):466-473. CAI Kunye, CAI Jing, ZHOU Di, et al. APU Fault Prediction Based on SVM Method[J]. Journal of Nanjing University of Aeronautics & Astronautics, 2019, 51(4):466-473.

动时间异常。但实际中QAR数据在几个航班后才能获取,另外工程人员通常只在APU出现异常后才会查阅APU的QAR数据。因此,从实际工程角度,实时获取APU数据并将潜在故障的判断推送给工程人员更符合工程需求。Gruyer等^[3]介绍了飞机通信寻址与报告系统(ACARS)的应用前景,实现报文的实时传输。在报文研究工作中,Zhai等^[4]对波音747的巡航报文进行解析研究,验证ACARS的可靠性。

而在APU的数据分析中,顾祝平等^[5]通过获取不同时间点的EGT转速等信息,求得给定时间范围内均值以此确定APU涡轮效率的衰退程度。唐敏杰^[6]通过APU的性能状态运行参数,基于统计分析的方法建立APU的监测模型。丁慧锋^[7]分析优化了APU性能参数阈值,用于评定APU的性能状态。徐爽等^[8]运用客户化报文,设置合理的温度阈值作为触发报文条件,实现对引气故障的监控。而由于只基于EGT这一参数用于判断而实际APU的状态更加复杂,往往不能取得良好的效果。报文数据为解决APU故障预测的实时性和多参数提供了基础。

在故障预测模型发展中,García-Nieto等^[9]采用混合PSO-SVM的模型预测飞机发动机的剩余使用寿命。Jiang等^[10]采用SVM方法对发动机润滑系统的异常状态进行识别。Zhang等^[11]将SVM方法和神经网络算法应用到飞机整体结构损伤的评估系统中进行对比,结果表明SVM优于神经网络算法。SVM算法广泛应用于飞机发动机的各种故障模式诊断,Zhan等^[12]提出了基于混合PSO-SVM模型,用于预测飞机轮胎与涂层之间的摩擦系数。Chen等^[13]以集成经验模式分解和高斯过程回归基础提出预测APU性能退化的方法。文献^[14]利用核函数主成分分析方法在众多检测参数上提出综合性能指标,由层次聚类验证异常识别的准确性。Yang等^[15]提出基于数据挖掘并使用经验证的故障模式与影响分析模型(FMEA)排名的故障隔离方法,得到对某一故障模式贡献大小的组件列表。Brian等^[16]提出了基于机器学习的大数据分析框架,用以提高APU健康监测的性能与质量。在这些故障预测模型研究中,仅以特征选择或特征提取手段进行降维,无法解释参数选择与故障间的内在联系。根据上述问题,为提高实时性并通过选取代表性参数建立的故障预测模型对APU进行故障诊断具有重要意义。

1 数据特征提取

1.1 报文系统

报文系统是通过数据管理组件(DMU)实时收集和处理来自飞机各系统的QAR数据,在DMU内编译客户化的飞机状态监控系统报文;经过收集参数、设定报告及相关的触发逻辑;最后通过ACARS建立的空地数据链对地面基站实时发送报文以实现对飞机的在线监控。因此,可以说报文是QAR数据获取的另一种渠道。与传统QAR数据相比,它有以下两个优点:

(1)数据获取的灵活性。通过设置参数获取条件,报文可以获取到同一参数在不同状态下的数据,这一特点大大减少了后期数据处理不必要的麻烦。

(2)数据获取的实时性。报文可通过ACARS实时传输到地面基站。触发相关逻辑下发的报文可直接用于故障诊断,为视情维修打下基础。本文从报文入手,挖掘报文的潜在价值。

如图1,以A13号报文的实时QAR数据为研究对象。A13号报文为APU的启动/慢车报。报文一共由4部分组成:报头,APU的履历信息,启动飞机发动机运行参数及APU自启动参数。

(1)报头为CC至CE段,主要记录了飞机的航班信息,报文产生的航段,引气活门状态及开口角度和总温。

(2)E1段记录的APU的履历信息,内容包括了APU序号及运行的循环小时。

(3)飞机发动机启动时,N1至S3段记录其APU运行参数,其中N1、S1记录了第1台发动机

000000000111111111222222222333333334
1234567890123456789012345678901234567890
01 3 Lines
02 free programmable
03 per report
04
05
06
07 A3XX APU MES/IDLE REPORT <13>
08
09 A/C ID DATE UTC FROM TO FLT
10 CC XXXXXX AAA99 999999 AAAA AAAA 9999
11
12 PH CNT CODE BLEED STATUS APU
13 C1 99 99999 9999 99 1111 1 1111 99 1
14
15 TAT ALT CAS MN GW CG DMU
16 CE X999 X9999 999 999 9999 999 XXXXXX
17
18 ASN AHRs ACYC PFAD
19 E1 9999 99999 99999 XXXXX
20
21 ESN ACW1 ACW2 NA EGTA IGV
22 N1 999999 XXXXX XXXXX 9999 X999 X99
23 N2 999999 XXXXX XXXXX 9999 X999 X99
24 N3 000000 XXXXX XXXXX 9999 X999 X99
25
26 P2A LCIT WB PT LCDT OTA GLA
27 S1 9999 X999 999 999 X999 X99 999
28 S2 9999 X999 999 999 X999 X99 999
29 S3 9999 X999 999 999 X999 X99 999
30
31 PREVIOUS APU START
32
33 STA EGTP NPA OTA LCIT
34 V1 999 X999 9999 X99 X999

图1 A13号报文

Fig.1 A13 report

启动时 APU 的运行参数;N2、S2 记录了第 2 台发动机启动时 APU 运行参数;N3、S3 记录了 APU 在慢车情况下的运行参数。

(4)V1 记录了 APU 自启动时的参数。

从图 1 中得出可获得的详细参数,具体参数如表 1 所示。

表 1 13 号报文参数详情

Tab. 1 No. 13 message parameters

参数	单位	参数	单位
APU 序号 (ASN)		引气压力 (PT)	Bar
使用循环 (ACYC)		引气流量 (WB)	kg/s
使用小时 (AHRs)	H	负载排气温度 (GLA)	°C
APU 转速 (NA)	%	油槽温度 (OTA)	°C
排气温度 (EGTA)	°C	发电机负载 (GLA)	%
IGV 角度 (IGV)	°	启动时间 (STA)	s
进口压力 (P2A)	Bar	排气温度峰值 (EGTP)	°C
载荷压气机进口温度 (LCIT)	°C	峰值排气温度下 APU 转速 (NPA)	%

1.2 数据预处理

收集国内某航空公司近 3 年内 6 架飞机的 A13 号报文数据,并进行整理。根据报文参数记录的格式,一次航班下发的报文有 4 条数据集:N1、N2、N3、V1。每条数据集都各有意义,但由于实际用于模型训练时只能放入一条数据集,因此需要将其合并。根据 1.1 节所述,N1、N2 分别记录了双发启动时 APU 的性能参数。由于 N1、N2 数据记录的时间点由主发动机启动快慢决定,不同航班之间主发动机性能表现不同,因此 N1、N2 参数记录时机存在差异。N3 为 APU 慢车状态下的性能参数,其记录时机只与自身性能相关,选择将其保留。V1 在 APU 启动时记录了启动时间、排气温度峰值、峰值转速而其他数据行并没有记录,选择将 N3、V1 行数据合并。同时考虑到 APU 作为一个恒速的离心式发动机,其转速受 ECB 控制不发生改变,以及在特定飞行状态下 IGV 开口角度固定,这些参数不发生改变对整个模型预测没有任何贡献,因此将其删除。这样可以得到一条能够代表这次航班 APU 运行状态且适用于模型训练的特征集合。

1.3 特征提取

在记录的 APU 特征参数有多达 11 种,参数之间不可避免的存在一些高相关性,而两个或两个以上具有高相关性的特征用于机器学习模型训练时,会加重该参数的抉择比重,导致预测效果与实际相违背;同时部分参数并不能表征 APU 运行状态,在参与故障预测中并不起任何作用。因此,需要对特征集进行特征提取,剔除无关以及高相关性的参数。丁慧锋等^[17]通过参数相关性剔除无关数据对 APU 性能指数建模实现对 APU 的趋势监控。

APU 作为离心式发动机,能够反应其性能的主要指标有两个:使用时间和 EGT。使用统计分

析软件 SPSS 的偏相关性分析模块,从报文中提取有价值的信息。在使用偏相关分析时需要剔除外界环境的影响,例如海拔、环境温度、引气流量、进口压力、负载压气机进口温度,以统一每次航班的运行质量。对输入的使用时间、启动时间、排气温度、IGV 角度、排气温度、油槽温度等 9 600 项 APU 数据进行分析,得到的结果如表 2 所示。

每个参数与其他参数都有一个对应相关性的值即 r 值,相关性一般可按 3 级划分: $|r| < 0.4$ 为低度线性相关; $0.4 < |r| < 0.7$ 为显著性相关; $0.7 < |r| < 1$ 为高度线性相关。参数与自身的相关性为 1。可以从表 2 中看出引气压力、排气温度、启动时间、使用时间之间是相互弱相关,其 $|r|$ 均小于 0.4,但进口导向叶片角度和滑油温度与引气压力、排气温度、启动时间、使用时间为强相关。由此可知 APU 的进口导向叶片角度与滑油温度可以由使用时间、启动时间、发动机排气温度、引气压力来表征;同时可以说明启动时间、引气压力、排气温度、使用时间参数相对较独立,各代表了 APU 的运行特性。这 4 个参数特性可以反映 APU 的整体性能情况。

2 故障预测模型建模

由 Cortes 和 Vapnik 提出的 SVM 方法^[18],由于其收敛速度快等优点,适用于模式识别、分类以及预测;同时 SVM 在处理小数据集中具有良好的表现,但在面对大规模训练样本时,存在训练时间过长,对缺失数据敏感的缺点。因此,本文采用 SVM 算法,对故障数据与健康数据进行识别和分类,以达到实时故障预测效果。

SVM 作为有监督的机器学习,需要对数据进行标注标签,还需要将历史数据放入模型中进行模

表 2 APU 数据相关性分析结果
Tab. 2 Correlation analysis results of APU data

参数	相关性	TSR	STA	EGTA	PT	IGV	OTA
TSR	相关	1.000	0.240	0.310	−0.020	−0.620	0.290
	显著性(双尾)		0.000	0.000	0.0120	0.0260	0.000
	df	0	9 600	9 600	9 600	9 600	9 600
STA	相关	0.240	1.000	0.330	−0.010	−0.430	0.320
	显著性(双尾)	0.000		0.000	0.062	0.000	0.000
	df	9600	0	9 600	9 600	9 600	9 600
EGTA	相关	−0.310	0.330	1.000	0.200	−0.510	−0.010
	显著性(双尾)	0.000	0.000		0.000	0.966	0.190
	df	9 600	9 600	0	9 600	9 600	9 600
PT	相关	−0.020	−0.100	0.200	1.000	−0.400	−0.210
	显著性(双尾)	0.012	0.062	0.000		0.000	0.000
	df	9 600	9 600	9 600	0	9 600	9 600
IGV	相关	−0.620	−0.430	−0.510	−0.400	1.000	0.550
	显著性(双尾)	0.026	0.000	0.966	0.000		0.000
	df	9600	9 600	9 600	9 600	0	9 600
OTA	相关	0.290	0.320	−0.010	−0.210	0.550	1.000
	显著性(双尾)	0.000	0.000	0.190	0.000	0.000	
	df	9 600	9 600	9 600	9 600	9 600	0.0

型训练。往往投入的数据越多,模型对未来的数据进行预测就更准确。

2.1 SVM模型介绍

SVM 的核心思想是构建一个最大间隔的分类超平面,使两类样本分布于分类面两边。标准 SVM 是对线性可分的两类样本,寻找一个既能使两类样本正确分开,又保证分类间隔最大的最优分类面。两类样本为

$$\begin{aligned} & (x_1,y_1),(x_2,y_2),\cdots,(x_i,y_i) \\ & x_i \in R^n,y_i \in \{-1,1\} \\ & i=1,2,\cdots,l \end{aligned}$$

(1)

式中: R 为训练样本总数; n 为样本空间的维数; x_i 为样本空间向量; y_i 为样本的类别标志。分类超平面为 $w \cdot x + b = 0$,如图 2 所示,其中 w 为最优超平面的法向量; b 为偏置; R_1 和 R_2 分别为 x 的第一维和第二维的取值。

对于线性可分的情况,最优超平面的求解问题归结为式(2)的约束优化问题

$$\begin{aligned} \min_{w,b} \quad & \varphi(w) = \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & y_i(w \cdot x_i + b) \geq 1 \\ & i=1,2,\cdots,l \end{aligned}$$

(2)

式(2)的求解通过定义 Lagrange 函数,把构建最优超平面的问题转化为如式(3)对偶二次规划问题




图 2 最优超平面
Fig.2 Optimal hyperplane

$$\begin{aligned} \max L(\alpha_i) = & \sum_{i=1}^l \alpha_i - \\ & \frac{1}{2} \sum_i \sum_i \alpha_i \alpha_j y_i y_j (\varphi(x_i) \cdot \varphi(x_j)) \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C \\ & \sum_{i=1}^l \alpha_i y_i = 0 \\ & \alpha_i \geq 0; i=1,2,\cdots \end{aligned}$$

(3)

最终的最优分类面函数表示为

$$f(x) = \text{sgn} \left\{ \sum_i^n \alpha_i^* y_i (x_i \cdot x) + b^* \right\}$$

(4)

2.2 设置标签

SVM 作为一个有监督的学习模型,需要给数

数据集设置标签。将数据集分为两类:APU的健康状态和故障状态,并通过多种途径对数据进行设置标签。

首先,观察得到报文记录的APU序号(ASN)出现变化情况,初步判断为飞机进行了换发作业,并通过机务人员验证确认其APU部件发生故障,替换备用部件。因此,将换发前的数据定义为故障数据。

其次,以报文数据中单个特征参数阈值为依据设置标签,例如当APU的启动时间超过65 s或APU稳定运行时排气温度不在380~420℃之间时作为故障数据。根据参数阈值设置故障标签会带来以下问题:分类器可能会以某参数大于一定值时将APU判定为故障状态,而实际情况是该参数出现阶跃性突变,只是暂时的数值突增,而实际并未故障。其解释是:本次通过多种手段设置故障标签,且多维的特征用于模型训练,因此会稀释单个参数阈值设置标签时带来的影响,将大大降低上述情况的发生。

最后,根据APU的维修记录再设置标签,在维修记录中机载的APU常见故障有:APU自动停车,启动失败,低滑油故障。根据故障记录时间,将故障发生前五天记录的报文数据作为故障状态。

通过以上标签设置,得到可用于SVM模型训练的数据集。

2.3 特征提取验证

1.3节中通过相关性分析得到能够表征APU运行状态的特征参数,这些特征参数集合在共同的数值变化状态下可用于判断APU是否发生故障,这和根据标签进行分类的有监督机器学习存在一定共性。因此,将通过算法验证特征在模型预测中是否表现良好。

递归特征消除是一种寻找原特征集的最优特征子集的贪婪算法,用于将原始的 d 维空间压缩到一个 k 维特征子空间,其中 $k < d$ 。使用该算法可以剔除不相关特征或噪声,自动选出与问题相关的特征子集,从而提高计算效率或降低模型的泛化误差。用于递归特征消除进行特征选择的有以下检测参数:EGT、进口压力、引气压力、引气流量、压气机进口温度、启动时间、IGV角度、峰值转速、使用时间、滑油温度、发电机载荷。递归特征消除对每个参数的重要程度进行评分得到以下情况:

由图3可以看出,EGT、引气压力、启动时间、使用时间的得分情况在模型预测中占比较高。

再对特征提取前后故障预测正确率进行比较,如图4所示。结果证明通过相关性分析筛选出的参数适用于模型训练后预测正确率有明显提高,效果显著。




图3 递归特征消除得分情况

Fig.3 Recursive feature elimination score




图4 特征提取前后预测正确率对比

Fig.4 Comparison of prediction accuracies before and after feature extraction

2.4 模型优化

对于SVM模型有2个非常重要的参数 C 与 γ ,其中 C 是对损失值的惩罚系数,即相对误差的宽容度。 C 值越高,说明SVM划出的分类间隔越不允许出现分类误差,容易过拟合。但同时 C 越小,容易发生欠拟合的现象。 C 值无论过大过小,都会影响到模型的泛化能力。而一个模型是否可用,往往由模型的泛化能力来决定。 γ 是SVM选择RBF为核函数时,该函数自带的一个参数。该参数的大小决定了数据在映射到高位空间后的分布情况, γ 越大,支持向量越少, γ 值越小,支持向量越多。支持向量的个数影响训练与预测的速度。将 γ 值设置为200是一个适当的值,通过调整 C 值获得学习曲线(Learning curve)与验证曲线(Validation curve)之间的关系,如图5所示。通过观察得到,随着 C 值的增大训练准确率与验证准确率逐渐疏远,出现过拟合现象,而 C 值越小,两者相近但预测正确率呈下降趋势。因此选取 C 值为0.1时具有较高的预测正确率且模型的拟合程度较高。




图5 预测准确率曲线随参数C变化曲线图

Fig.5 Curves of prediction accuracy changing with parameter C

由此,该模型具有较高的预测正确率与良好的泛化性,可用于实际故障预测。

3 案例验证与模型评价

3.1 案例验证

模型的预测准确性一直是评估模型性能的数量化指标,而在本文中故障数据远远少于健康数据,仅以预测准确性作为模型优劣的评判标准并不合适。这里将通过引进混淆矩阵衡量模型的预测效果。

混淆矩阵是一个简单的方阵,用于展示分类器的预测结果——真正(TP)、真负(FN)、假正(FP)、假负(FN)的数量。对于类别数量不均衡的分类问题来说,真正率(TPR)与假正率(FPR)是非常有用的性能指标

$$FPR = \frac{FP}{N} = \frac{FP}{FP + TN}$$

$$PRE = TPR = \frac{TP}{P} = \frac{TP}{FN + TP}$$

以APU故障检测为例,通常更关注是否能检测出APU的故障状态。因此,将故障类别错误的划分为健康类别的数量,即假正数,就变得非常重要。选取144条未被用于模型训练的数据并在SVM、K近邻(KNN)、逻辑回归(Logistic regression)及决策树(Decision tree)模型下进行案例验证,通过实际的数据绘制出的混淆矩阵如图6所示。

本文选取114条飞机在运行过程中下发的APU报文,并依据上文进行数据处理,将其输入模型中进行预测。从图6中可以看出,使用SVM训练出的模型正确预测了71个属于类别0的样本(真负),以及40个属于类别1的样本(真正)。不过,模型也错误的将两个属于类别0的样本划分到类别1(假负)。另外一个属于假正。因此SVM模型在对114条数据进行预测中存在一次将APU故障状




图6 各算法下的混淆矩阵

Fig.6 Confusion matrix under each algorithm

态误判为健康状态的情况。而其他3种算法中,KNN具有相同的预警率,与SVM一样只存在一次将故障状态误判断为健康状态,但存在多次误报率。而逻辑回归与决策树预测准确度较之SVM明显逊色。

3.2 模型评价

在Pei等^[19]计算分类模型的评价指标F-score以及T检验比较各模型的优劣。通过绘制受试者工作特征曲线(ROC)来比较SVM与逻辑回归、决策树及KNN这3种模型的优异以验证本文选择SVM模型的合理性。ROC曲线是基于模型假正率和真正率等性能指标进行分类模型选择的有用工具。ROC曲线优点在于当测试集中的正负样本分布变化时,其曲线能保持不变的特性。因此在实际的数据集中出现正负样本分布变化情况时,而ROC能提供较好的评估稳定性。

将多个诊断算法的ROC曲线绘制到同一坐标中,用于比较模型的优劣,越接近左上角的ROC曲线所代表的算法,越精确。同时,也可以通过计算各算法的ROC曲线下的面积(AUC)进行比较。图7的左下角以给出AUC值,哪种模型试验的AUC最大,表明其诊断价值越佳。图7共有5条曲线,其中4条曲线分别表示用于比较的分类模型预测效果,另一条灰色虚线代表的是随机猜测,此时AUC值为0.5,即有一半概率预测正确。对于ROC曲线在该线以下的预测模型表明其没有预测价值,图上的4种分类模型均在随机猜测曲线以上,其中SVM最接近左上方,计算得到的AUC值为0.94。可以得出选择SVM模型用作故障诊断模




图7 各算法的ROC曲线图

Fig.7 ROC curves of each algorithm

型比其他分类算法更具有优越性。

4 结 论

本文提出了一种新的特征提取思路,即排除算法筛选导致解释性差的特点,从发动机特性出发选择特征,再以算法验证其正确性。通过模型预测准确率为依据加以验证,提高特征选择的可解释性。并且在数据预处理步骤中,分析选取报文中有价值的数据用于模型训练。通过对SVM模型进行优化,获得一个泛化效果更好的模型并选择合适的评价指标对模型进行评估。

结果证明,基于SVM模型以A13号报文为数据源进行故障识别时,比其他分类模型有较高的优越性;同时,用于模型训练的特征参数均来自于ACARS发送到地面基站的A13号报文。通过实时传输的A13号报文,能够实现故障的在线监测,能及时安排地勤维修人员及时排故,避免非计划维修,在一定程度上实现APU的视情维修。

参 考 文 献:

[1] 高飞鹏,黄加阳,陈新霞.基于航后QAR数据译码的APU故障诊断技术[J].计算机测量与控制,2016,24(1):42-45.
GAO Feipeng, HUANG Jiayang, CHEN Xinxia. APU fault diagnosis technology based on post-flight QAR data decoding [J]. Computer Measurement & Control, 2016, 24(1): 42-45.

[2] 李海然.排故中的QAR数据使用[J].航空维修与工程,2010(2):47-48.
LI Hairan. QAR data used in troubleshooting [J]. Aviation Maintenance and Engineering, 2010 (2): 47-48.

[3] GRUYER P, ROSE D, SERVIERES-BORDES C. Hybrid ACARS communication system: US, US8195813 B2[P]. 2012.

[4] ZHAI Hongchun, HUANG Yuanqiang, ZHANG

Xingchuan. Analysis of cruise message of Boeing 747-400 aircraft based on QAR data[J]. Machine tool and Hydraulics, 2015, 43(24): 20-24.

[5] 顾祝平,张弛,黄磊,等.飞机辅助动力单元涡轮效率监控方法和装置:CN201310313879.0[P].2015-02-11.
GU Zhuping, ZHANG Chi, HUANG Lei. Methods and devices for turbine efficiency monitoring of aircraft auxiliary power units: CN201310313879.0 [P]. 2015-02-11.

[6] 唐敏杰.基于状态维修的APU起动机监控模型的建模与实现[J].航空维修与工程,2014(3):73-75.
TANG Minjie. Modeling and implementation of APU starter monitoring model based on state maintenance [J]. Aviation maintenance and Engineering, 2014(3): 73-75.

[7] 丁慧锋.基于预防性维修的APU性能评估建模与监控方法[J].航空维修与工程,2012(6):52-54.
DING Hui Feng. APU performance evaluation modeling and monitoring method based on preventive maintenance [J]. Aviation Maintenance and Engineering, 2012(6): 52-54.

[8] 徐爽,王尔宝,张希第.客户化ACMS报告在引气系统上的应用[J].航空维修与工程,2013(3):57-58.
XU Shuang, WANG Erbao, ZHANG Xidi. Application of customized ACMS report on air intake system [J]. Aviation Maintenance and Engineering, 2013(3): 57-58.

[9] GARCÍA-NIETO P J, GARCÍA-GONZALO E, SÁNCHEZ LASHERAS F, et al. Hybrid PSO-SVM-based method for forecasting of the remaining useful life for aircraft engines and evaluation of its reliability[J]. Reliability Engineering & System Safety, 2015, 138: 219-231.

[10] JIANG Liying, XUE Changan, CUI Jianguo, et al. Research recognition of aircraft engine abnormal state [C]//Control and Decision Conference, 2015 27th Chinese. [S.l.]: IEEE, 2015.

[11] ZHANG Ye, de VISSER C C, CHU Q. Online aircraft damage case identification and classification for database information retrieval[C]//2018 AIAA Atmospheric Flight Mechanics Conference. [S. l.]: AIAA, 2018.

[12] ZHAN L, LI C. A hybrid PSO-SVM-based method for predicting the friction coefficient between aircraft tire and coating[J]. Measurement Science and Technology, 2017, 28(2): 025004.

[13] CHEN X, WANG H, HUANG J, et al. APU degradation prediction based on EEMD and gaussian

- process regression [C]// 2017 International Conference on Sensing, Diagnostics, Prognostics, and Control (SDPC). Shanghai, China: SDPC, 2017.
- [14] CHEN X, LYU Z, REN H, et al. APU feature integration based on multi-variant flight data analysis [C]// 2016 IEEE International Conference on Prognostics and Health Management (ICPHM). Ottawa, USA: IEEE, 2016.
- [15] YANG C, ZOU Y, LAI P, et al. Data mining-based methods for fault isolation with validated FMEA model ranking[J]. Applied Intelligence, 2015, 43(4): 913-923.
- [16] BRIAN X, KUMAR S A. Big data analytics framework for system health monitoring [C]// 2015 IEEE International Congress on Big Data. New York, USA: IEEE, 2015.
- [17] 丁慧锋, 王炳正, 黄磊. 面向CBM维修策略的飞机APU系统监控建模与实现[C]// 2011航空维修理论及技术发展学术交流会议论文集. [S.l.]: 中国知网, 2011.
- DING Huifeng, WANG Bingzheng, HUANG Lei. CBM maintenance strategy oriented aircraft APU system monitoring modeling and implementation [C]// 2011 aviation maintenance theory research and technology development academic exchange proceedings. [S.l.]: CNKI, 2011.
- [18] CORTES C, VAPNIK V. Support-vector networks [J]. Machine Learning, 1995, 20(3): 73-297.
- [19] PEI Yun, ZHANG Sheng, SHU Meng, et al. An online fault detection model and strategies based on svm-grid in clouds[J]. IEEE/CAA Journal of Automatica Sinica, 2018, 5(2): 445-456.

(编辑:张蓓)