

基于多因子高阶模糊变动的飞机操纵面故障趋势预测

董磊, 任章, 李清东

(北京航空航天大学 飞行器控制一体化技术重点实验室, 北京, 100191)

摘要: 针对飞机操纵面故障趋势预测问题, 结合系统可测状态参量能间接表现操纵面故障情况的特点, 提出一种基于多因子高阶模糊变动的方法。将传统的模糊时间序列预测方法进行扩展, 利用多元时间序列的变动值构建多辅助因子模糊逻辑关系。采用自组织映射(SOM)方法将整个论域划分为不等长度的多个论域区间, 并重新设定所属论域区间的隶属度。根据时间序列的周期性特点, 建立多因子高阶模糊变动预测模型。为了验证算法的有效性, 针对飞机转弯时左副翼损伤故障趋势进行预测和分析, 并与传统模糊时间序列预测方法进行对比, 用两种方法得到的预测结果通过建立好的故障映射模型进行故障类型和故障程度的判别, 仿真结果充分表明了多因子高阶模糊变动预测模型具有更好的故障趋势预测能力。

关键词: 模糊时间序列; 故障预测; 自组织映射; 区间长度; 操纵面

中图分类号: TP 206+.3

文献标志码: A

文章编号: 1672-7207(2013)S1-0232-06

Fault prediction for aircraft control surface damage based on multi-factor high-order fuzzy variation

DONG Lei, REN Zhang, LI Qingdong

(Science and Technology on Aircraft Control Laboratory, Beihang University, Beijing 100191, China)

Abstract: The trends of aircraft control system state parameters which can be measured are indirect manifestations of surface damage. In order to improve prediction accuracy, a method based on multi-factor high-order fuzzy variation is proposed. The proposed method constructs multi-cofactor fuzzy logical relationship with the variation of multivariate time series and extends the conventional fuzzy prediction method. The universe of discourse is divided into unequal interval length using self-organizing map (SOM) and its membership is reset. According to the periodic feature, a multi-factor high-order fuzzy variation model is built. In order to verify the validity of the method, the prediction and analysis of aileron fault trend was performed. The identification of fault type and fault degree is obtained by fault mapping model with the prediction results. Compared with the traditional method, the simulation result demonstrates the proposed prediction model has a better predictive ability.

Key words: fuzzy time series; fault prediction; self-organizing map; interval length; control surface

对于飞机这种复杂、快变不确定性非线性系统来说, 如果操纵面发生故障, 会使飞机偏离正常运行状态, 进而影响到飞机的操纵性和安全性。操纵面常见的故障有松浮、卡死和损伤。对于操纵面损伤故障来说, 其故障程度是随时间的发展而变化的, 属于“软故

障”。因此, 可通过时间序列预测方法捕捉系统状态参数的变化趋势, 以判断在未来一段时间内操纵面的损伤情况。

模糊时间序列预测模型是从经济学中发展起来的, 最早由 Song 和 Chissom 提出的^[1], 并应用于 Alabama

收稿日期: 2013-03-01; 修回日期: 2013-05-02

基金项目: 国家自然科学基金资助项目(60874117, 61101004)

通信作者: 董磊(1983-), 男, 天津人, 博士研究生, 从事故障诊断、预测与健康管理研究; 电话: 010-82314573; E-mail: jack19830108@sina.com

大学新生入学人数的预测。Chen^[2]在 1996 年针对 Song 和 Chissom 方法计算比较复杂的问题, 提出了利用数学运算代替预测模型中的 max-min 算子, 提高了运算效率, 但该模型只是利用单因子建立模糊关系。Lee 等^[3]在 2006 年提出了双因子高阶模糊时间序列预测模型, 并用于温度和股票价格的预测中。该方法虽然考虑了辅助因子对预测精度的影响, 但并没有考虑论域区间划分长度及其隶属度大小等因素对预测精度的影响。

针对上述问题, 本文作者利用强相关性分析, 从采集得到的多元时间序列中选取多个辅助因子, 并利用主因子和辅助因子的变动值构建多辅助因子模糊逻辑关系。采用自组织映射(SOM)方法将整个论域划分为不等长度的多个论域区间, 并重新设定了所属论域区间的隶属度。根据时间序列的周期性特点, 将多元时间序列划分为多个周期, 建立高阶模糊变动预测模型。最后, 将所建立的多因子高阶模糊变动模型用于飞机左副翼损伤故障趋势预测中, 并利用启发式规则建立的故障映射模型对故障类型和故障程度进行判别, 同时与 Lee 提出的预测方法进行对比, 验证了该模型具有更好的故障趋势预测性能。

1 模糊时间序列的相关定义

与其他的预测方法相比, 模糊时间序列方法的主要优势在于能够处理时间序列中的模糊化数据。其核心思想是利用时变或非时变的模糊关系来描述时间序列的动态过程^[4]。

定义 1: 设 $\{X(t) \in R, t=1, 2, \dots, n\}$ 为一个时间序列, U 为其论域。给定 U 的一个次序分割集合 $\{P_1, P_2, \dots, P_r\}$, 每个分割区间对应的语言变量为 L_j , 其中 $j=1, 2, \dots, r$ 。本文记 $F_i(t)$ 的集合为分布于 $X(t)$ 上的一个模糊时间序列:

$$F_i(t) = \frac{\mu_{i1}(X(t))}{L_1} + \frac{\mu_{i2}(X(t))}{L_2} + \dots + \frac{\mu_{ir}(X(t))}{L_r} \quad (1)$$

式中: $\mu_{ij}(X(t))/L_j$ 表示 $X(t)$ 相对于语言变量 L_j 及其隶属度 $\mu_{ij}(X(t))$ 的对应关系, $0 \leq \mu_{ij} \leq 1$ 。这里将 $F_i(t)$ 简写成 $F_i(t) = (\mu_{i1}, \mu_{i2}, \dots, \mu_{ir})$ 。

定义 2: 若在论域 U 上的模糊集合 G 和 H 分别为 $G = (\mu_1, \mu_2, \dots, \mu_r)$ 和 $H = (v_1, v_2, \dots, v_r)$, μ_i 和 v_i 分别为 G 和 H 各自的隶属度, 则 G 和 H 之间的模糊关系记为:

$$R = G^t \circ H = [R_{ij}]_{r \times r} \quad (2)$$

其中: \circ 表示模糊合成运算。

定义 3: 设 $R(t, t-1)$ 是一阶模糊自回归 FAR(1) 的模糊关系矩阵。若对任何时间点 t , $R(t, t-1)$ 与 t 无关, 即 $R(t, t-1) = R(t-1, t-2)$, 则称 FAR(1) 具有非时变性质; 否则, 具有时变性质。

2 多因子高阶模糊变动预测

在 Lee 等^[3]提出的双因子高阶模糊时间序列预测方法的基础上, 考虑论域区间划分长度及其隶属度大小等因素对预测精度的影响, 并对原方法进行扩展和改进, 从而提出多因子高阶模糊变动预测方法。

2.1 区间长度的划分及其隶属度的设定

据分析, 论域区间长度的划分及其隶属度的设定也会影响到预测精度。通常有效的论域区间长度不能太大也不能太小。如果太大, 模糊时间序列的波动变化会变得不明显; 如果太小, 模糊时间序列潜藏的信息就会减少。因此, 采用 SOM 的方法将整个论域划分为不等长度的多个论域区间, 并细化了所属论域区间的隶属度。

SOM 是一种聚类方法, 最早由 Kohonen 提出^[5]。该方法通过对输入数据的自组织学习, 可以使聚类中心空间分布密度与输入数据的概率分布趋于一致。首先, 利用相似度测量方法计算每个初始聚类中心 $C_i (i=1, 2, \dots, m)$ 与输入数据 D_j 之间的欧式距离。

$$d(C_{il}, D_{jl}) = \sqrt{\sum_{l=1}^n (C_{il} - D_{jl})^2} \quad (3)$$

式中: n 为输入数据的维数。然后, 寻找与输入数据之间欧式距离最小的聚类中心 C^* , 利用式(4)更新所有 C^* 的邻域值 $C_v (v=1, 2, \dots, n)$ 。

$$C_v(t+1) = C_v(t) + \Theta(t)\alpha(t)(D(t) - C_v(t)) \quad (4)$$

其中: $\Theta(t)$ 是与 C^* 之间距离的约束; $\alpha(t)$ 为时间的学习约束。利用 SOM 方法得到聚类中心 (c_1, c_2, \dots, c_m) 后, 按照以下方法将论域分为多个长度不等的区间:

$$\begin{aligned} u_1 &= \left[D_{\min} - D_1, \frac{(c_1 + c_2)}{2} \right] = [d_1, d_2) \\ u_2 &= \left[\frac{(c_1 + c_2)}{2}, \frac{(c_2 + c_3)}{2} \right] = [d_2, d_3) \\ &\vdots \\ u_m &= \left[\frac{(c_{m-1} + c_m)}{2}, D_{\max} + D_2 \right] = [d_m, d_{m+1}] \end{aligned}$$

则模糊集合 A_i 可以改写为:

$$A_i = \frac{\mu_i(x)}{[d_1, d_2)} + \dots + \frac{\mu_i(x)}{[d_{i-1}, d_i)} + \frac{\mu_i(x)}{[d_i, d_{i+1})} + \frac{\mu_i(x)}{[d_{i+1}, d_{i+2})} + \dots + \frac{\mu_i(x)}{[d_m, d_{m+1}]} \quad (5)$$

式中: $\mu_i(x)$ 为梯形函数, $1 \leq i \leq m$ 。在此, 用 $\mu_i(x)$ 代替 $(0.5, 1, 0.5)$, 则模糊集合 A_i 可表示为 $A_i = (d_{i-1}, d_i, d_{i+1}, d_{i+2}, \mu_i)$ 。当 $A_i = A_1$ 时, 去掉 d_{i-1} ; 当 $A_i = A_m$ 时, 去掉 d_{i+2} 。 $\mu_i(x)$ 如式(6)所示:

$$\mu_i(x) = \begin{cases} 0, [d_1, d_{i-1}) \\ \frac{d_{i+1}-x}{d_{i+1}-d_i}, [d_{i-1}, d_i) \\ 1, [d_i, d_{i+1}) \\ \frac{x-d_i}{d_{i+1}-d_i}, [d_{i+1}, d_{i+2}) \\ 0, [d_{i+2}, d_{m+1}] \end{cases} \quad (6)$$

2.2 多因子高阶模糊变动预测方法

对于复杂系统来说, 某一个参量的变化往往是跟其他多个参量息息相关的。因此, 将待预测参量作为主因子, 其他多个相关参量作为辅助因子来完成主因子的预测。定义 $A_i (1 \leq i \leq m)$ 为主因子模糊集合, $B_i^k (1 \leq i \leq m)$ 为多辅助因子模糊集合, k 为辅助因子的个数, 描述为如下形式:

$$\begin{aligned} A_1 &= \frac{\mu_{A1}(x_A)}{u_1} + \frac{\mu_{A1}(x_A)}{u_2} + \dots + \frac{\mu_{A1}(x_A)}{u_m} \\ A_2 &= \frac{\mu_{A2}(x_A)}{u_1} + \frac{\mu_{A2}(x_A)}{u_2} + \dots + \frac{\mu_{A2}(x_A)}{u_m} \\ &\vdots \\ A_m &= \frac{\mu_{Am}(x_A)}{u_1} + \frac{\mu_{Am}(x_A)}{u_2} + \dots + \frac{\mu_{Am}(x_A)}{u_m} \\ B_1^k &= \frac{\mu_{B1}^k(x_B^k)}{v_1^k} + \frac{\mu_{B1}^k(x_B^k)}{v_2^k} + \dots + \frac{\mu_{B1}^k(x_B^k)}{v_m^k} \\ B_2^k &= \frac{\mu_{B2}^k(x_B^k)}{v_1^k} + \frac{\mu_{B2}^k(x_B^k)}{v_2^k} + \dots + \frac{\mu_{B2}^k(x_B^k)}{v_m^k} \\ &\vdots \\ B_m^k &= \frac{\mu_{Bm}^k(x_B^k)}{v_1^k} + \frac{\mu_{Bm}^k(x_B^k)}{v_2^k} + \dots + \frac{\mu_{Bm}^k(x_B^k)}{v_m^k} \end{aligned}$$

要预测 t 时刻的输出, 必须选择合适的窗宽 w , 然后由 $t-1$ 时刻的模糊集组成的标准向量 $C(t)$ 和过去 w 个时刻的模糊集组成的操作矩阵 $O^w(t)$ 来计算 t 时刻

的输出。 $C(t)$ 和 $O^w(t)$ 的表达式如下所示:

$$C(t) = f(t-1) = [C_1 \ C_2 \ \dots \ C_m]$$

$$O^w(t) = \begin{bmatrix} f(t-2) \\ f(t-3) \\ \vdots \\ f(t-w-1) \end{bmatrix} = \begin{bmatrix} O_{11} & O_{12} & \dots & O_{1m} \\ O_{21} & O_{22} & \dots & O_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ O_{w1} & O_{w2} & \dots & O_{wm} \end{bmatrix} \quad (7)$$

同标准向量 $C(t)$ 相似, 可以选择多辅助因子向量 $S^k(t)$ 的形式为:

$$S^k(t) = g^k(t-1) = [S_1^k \ S_2^k \ \dots \ S_m^k] \quad (8)$$

其中: $g^k(t-1)$ 是多辅助因子模糊时间序列在 $(t-1)$ 时刻的模糊化数据。则 $(t-1)$ 时刻和过去 w 个时刻之间的模糊关系矩阵 $R(t)$ 为:

$$R(t) = Q^w(t) \otimes S^k(t) \otimes C(t) =$$

$$\begin{bmatrix} O_{11} \times S_1^1 \dots S_1^k \times C_1 & \dots & O_{1m} \times S_m^1 \dots S_m^k \times C_m \\ O_{21} \times S_1^1 \dots S_1^k \times C_1 & \dots & O_{2m} \times S_m^1 \dots S_m^k \times C_m \\ \vdots & \vdots & \vdots \\ O_{w1} \times S_1^1 \dots S_1^k \times C_1 & \dots & O_{wm} \times S_m^1 \dots S_m^k \times C_m \end{bmatrix} = \begin{bmatrix} R_{11} & R_{12} & \dots & R_{1m} \\ R_{21} & R_{22} & \dots & R_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ R_{w1} & R_{w2} & \dots & R_{wm} \end{bmatrix} \quad (9)$$

其中: “ \times ” 为乘法算子。根据模糊关系矩阵 $R(t)$ 可得到主因子在 t 时刻的预测模糊变动 $F(t)$ 为:

$$\begin{aligned} F(t) &= [\max(R_{11} \ R_{21} \ \dots \ R_{w1}) \max \\ &\quad (R_{12} \ R_{22} \ \dots \ R_{w2}) \dots \max(R_{1m} \ R_{2m} \ \dots \ R_{wm})] \end{aligned} \quad (10)$$

如果主因子和辅助因子均为周期性时间序列, 可以构造高阶模糊逻辑关系。设主因子第 i 个周期的模糊化历史数据为 X_i , 多辅助因子第 i 个周期的模糊化历史数据为 Y_i , 则 “ $((X_{ih}, Y_{ih}^k), \dots, (X_{i2}, Y_{i2}^k), (X_{i1}, Y_{i1}^k)) \rightarrow X_i$ ”, $2 \leq k \leq n$ 。其中, $X_{ih}, \dots, X_{i2}, X_{i1}$ 表示主因子在第 $i-h$ 个周期至第 $i-1$ 个周期的模糊化值; $Y_{ih}^k, \dots, Y_{i2}^k, Y_{i1}^k$ 表示 k 个辅助因子在第 $i-h$ 个周期至第 $i-1$ 个周期的模糊化值。进而, 预测输出可根据多因子高阶模糊关系匹配得到, 匹配结果会有以下几种情况:

Case 1: 只有一个匹配的模糊推理关系, 即:

$$(X_{ih}, Y_{ih}^k), (X_{i(h-1)}, Y_{i(h-1)}^k), \dots, (X_{i1}, Y_{i1}^k) \rightarrow X_j$$

则第 i 个周期的预测变动 p_j 为:

$$p_j = \begin{cases} \frac{M_j + \mu_{j+1}(x)M_{j+1}}{1 + \mu_{j+1}(x)}, j = 1 \\ \frac{\mu_{j-1}(x)M_{j-1} + M_j + \mu_{j+1}(x)M_{j+1}}{\mu_{j-1}(x) + 1 + \mu_{j+1}(x)}, 2 \leq j \leq m-1 \\ \frac{\mu_{j-1}(x)M_{j-1} + M_j}{\mu_{j-1}(x) + 1}, j = m \end{cases} \quad (11)$$

其中: M 和 $\mu(x)$ 分别为区间 u 的中点和隶属度。

Case 2: 存在多个匹配的模糊推理关系, 即:

$$(X_{ih}, Y_{ih}^k), (X_{i(h-1)}, Y_{i(h-1)}^k), \dots, (X_{il}, Y_{il}^k) \rightarrow X_{j1}, \dots, X_{jl},$$

且 X_{j1}, \dots, X_{jl} 在模糊关系库中出现的次数分别为 n_{j1}, \dots, n_{jl} , 则第 i 个周期的预测变动为:

$$\frac{n_{j1} \times p_{j1} + n_{j2} \times p_{j2} + \dots + n_{jl} \times p_{jl}}{n_{j1} + n_{j2} + \dots + n_{jl}} \quad (12)$$

其中: $p_{j1}, p_{j2}, \dots, p_{jl}$ 为式(11)的计算结果。

Case 3: 不存在匹配的模糊推理关系, 即:

$$(X_{ih}, Y_{ih}^k), (X_{i(h-1)}, Y_{i(h-1)}^k), \dots, (X_{il}, Y_{il}^k) \rightarrow \#$$

则第 i 个周期的预测变动为:

$$\frac{1 \times p_{ih} + 2 \times p_{i(h-1)} + \dots + h \times p_{il}}{1 + 2 + \dots + h} \quad (13)$$

最后, 将去模糊化后的多因子预测变动与高阶预测变动进行加权处理, 得到最终的预测结果。

3 飞机操纵面的故障模拟与仿真分析

本研究建立了六自由度闭环飞控系统, 模拟了左副翼损伤故障, 且损伤程度随着时间的增加而增大。实际中, 能够检测到的参量是有限的, 因此设定以下参量可被采集, 副翼舵偏 δ_a 、升降舵舵偏 δ_e 、方向舵舵偏 δ_r 、滚转角速度 p 、俯仰角速度 q 、偏航角速度 r 、滚转角 ϕ 、俯仰角 θ 和偏航角 ψ 。

在加入随机噪声干扰的情况下, 假设飞机初始在 5 km 高空, 以 234.807 m/s 直线飞行, 给定方向舵舵偏为 0~0.035 rad 的周期指令, 采样周期为 0.05 s。在 22 s 时加入左副翼操纵面损伤故障, 由于参量 ϕ 和 ψ 的变化比较明显, 由此以这两个参量作为待预测的主因子, 变化曲线如图 1 所示。

根据强相关性分析方法, 确定了 r 为 ϕ 的辅助因子, q 和 θ 为 ψ 的辅助因子。利用主因子和多辅助因




图 1 故障时系统状态参量的变化趋势

Fig. 1 Trend of parameters in the case of failure

子建立多因子高阶模糊变动预测模型, 预测步骤如下:

Step 1: 计算主因子时间序列任意两个相连数据的变动, 找到最大变化量 D_{\max} 和最小变化量 D_{\min} , 定义论域 $U=[D_{\min}-D_1, D_{\max}+D_2]$, D_1 和 D_2 为合适的正实数。

Step 2: 利用 2.1 节提出的方法将论域 U 划分成不等长度的区间 $\{u_1, u_2, \dots, u_m\}$, 并根据定义的模糊集合, 将时间序列模糊化。

Step 3: 选择合适的窗宽 w , 根据标准向量 $C(t)$ 、操作矩阵 $O^w(t)$ 和辅助因子向量 $S^k(t)$ 计算模糊关系矩阵 $R(t)$, 进而求出模糊变动 $F(t)$ 。

Step 4: 将主因子和辅助因子分为多个周期, 按照存在匹配模糊关系的情况求解高阶预测变动, 将去模糊化后的多因子预测变动与高阶预测变动进行加权处理, 并利用原始时间序列计算最终的实际预测结果。

对于飞机操纵面故障预测来说, 首先, 计算时间序列任意两个相连数据的变动 $D=x_t-x_{t-1}$ 。以参量 ϕ 为例, 可以得到最小变化量 D_{\min} 为 -0.006 2, 最大变化量 D_{\max} 为 0.006 0。这里设定 D_1 为 0.000 3, D_2 为 0.000 5, 则论域 $U=[-0.006 5, 0.006 5]$ 。然后, 利用 SOM 方法将整个论域自动分为了 7 个长度不相等的子论域区间。将时间序列变动进行模糊化后, 选择窗宽 $w=6$, 根据式(9)求解模糊关系矩阵 $R(t)$, 进而得

到模糊化预测变动与原时间序列计算的预测值。最后,将该预测值与高阶模糊关系匹配得到的预测值进行加权处理得到最终预测结果。根据上述预测过程,建立每个待测参量的多因子高阶模糊变动模型,从第 25 s 到 27 s 对故障情况下状态参量 ϕ 和 ψ 的变化趋势进行滚动预测,并与 Lee 等^[3]提出的预测方法进行对比,如图 2 所示。




图 2 故障情况下状态参量变化趋势预测结果
Fig. 2 Prediction results for trend of state parameters in the case of failure

表 1 给出了两种方法的平均相对误差(MAPE)和均方差(MSE)对比,由于提出的方法是在一定程度上对包括 Lee 方法等传统模糊时间序列预测方法的扩展和改进,所以在预测性能上要比传统方法更好,并且

表 1 2 种方法的预测性能对比

Table1 Prediction performance of two methods					
模型	MAPE- ϕ	MAPE- ψ	MSE- ϕ	MSE- ψ	时间/s
Lee 等 ^[3] 模型	0.430 5	0.047 1	0.005 9	0.001 0	0.52
本模型	0.406 6	0.034 1	0.003 9	0.000 7	0.65

预测所用时间也在所能接受的范围的,保证了预测的精确性和快速性。

对于操纵面损伤这类故障,由于其发展趋势是随着时间的增加而增大的,这就需要在进行故障判别时不仅要区分发生故障的类型,而且还要判断出故障程度。由此,本研究利用正常状态和故障状态的历史数据建立了故障映射模型。这里,选择状态参量的有效值(root mean square, RMS)作为故障判别的特征向量,具体公式如下:

$$RMS = \frac{1}{N-1} \sqrt{\sum_{i=1}^N (x_i - \bar{x})^2} \tag{14}$$

其中: x_i 为状态参量时间序列; \bar{x} 为 x_i 的均值; N 为时间序列值个数。

根据 ϕ 和 ψ 的特征向量建立故障判别规则以推理出故障类型为 $i \in [1,5]$ (“1”为左副翼损伤、“2”为右副翼损伤、“3”为左平尾损伤、“4”为右平尾损伤、“5”为方向舵损伤)、损伤程度在 0~1 之间的结论。将某次预测结果经故障映射得到的判别结果,如图 3 所示,




图 3 故障类型和故障程度判别直方图
Fig. 3 Identification histogram of fault type and fault degree

图 3 所示为本方法、Lee 方法和实际故障对应的故障程度的比较。以 30%的故障程度为阈值,图 3 中虚线所示,本方法可准确判定故障类型为左副翼损伤,其故障程度为 35%,实际故障程度为 33%。而 Lee 方法判定的结果为左副翼损伤或右副翼损伤两种可能性。由此可知,状态参量预测的准确度对于故障类型和程度的判定是至关重要的。

4 结论

将传统的模糊时间序列预测方法进行了扩展和改

进,提出了一种基于多因子高阶模糊变动的预测方法,并用于飞机左副翼损伤故障趋势预测中。首先,对飞机故障进行模拟,选取主因子和其辅助预测因子。然后,利用 SOM 法确定区间长度及其隶属度,并对原时间序列进行周期划分,从而建立多因子高阶模糊变动预测模型。利用所建立的预测模型对 ϕ 和 ψ 进行预测,并判别故障类型和程度。预测结果表明,本文提出的改进方法相对于传统模糊时间序列方法预测效果更好。

参考文献:

- [1] Song Q, Chissom B S. Fuzzy time series and its models[J]. Fuzzy Sets and Systems, 1993, 54(3): 269-277.

- [2] Chen S M. Forecasting enrollments based on fuzzy time series[J]. Fuzzy Sets and System, 1996, 81(3): 311-319.
- [3] Lee L W, Wang L H, Chen S M, et al. Handling forecasting problems based on two-factors high-order fuzzy time series[J]. IEEE Transactions on Fuzzy Systems, 2006, 14(3): 468-477.
- [4] Hwang J R, Chen S M, Lee C H. Handling forecasting problems using fuzzy time series[J]. Fuzzy Sets and Systems, 1998, 100: 217-228.
- [5] 管琳, 张博, 黄冬梅. 一种改进的自组织映射算法求解旅行商问题[J]. 上海第二工业大学学报, 2012, 29(1): 48-52.
- GUAN Lin, ZHANG Bo, HUANG Dongmei. An improved self-organizing algorithm for solving the traveling salesman problem[J]. Journal of Shanghai Second Polytechnic University, 2012, 29(1): 48-52.

(编辑 杨华)