

DOI: 10. 20079/j. issn. 1001-893x. 220521001

引用格式: 文佳 梁天辰 陈擎宙 等. 基于多模型融合的航空电子产品故障预测方法[J]. 电讯技术 2023 63(8) : 1237-1242. [WEN J ,LIANG T C ,
CHEN Q Z et al. An avionics fault prognostic method based on multi-model fusion[J]. Telecommunication Engineering 2023 63(8) : 1237-1242.]

基于多模型融合的航空电子产品故障预测方法^{*}

文 佳 梁天辰 陈擎宙 钱 东

(中国西南电子技术研究所 成都 610036)

摘 要: 针对复杂机载环境应力条件下航空电子产品故障预测所面临的退化趋势差异大、训练数据样本量小等问题,提出了一种改进长短期记忆(Long Short-Term Memory ,LSTM)神经网络模型与集成学习框架相结合的故障预测方法,以满足现代综合航空电子系统智能调度管理与自主维护保障的需求。该方法在 LSTM 模型中引入 Dropout 机制,构建基于不同历史数据集的差异性 LSTM 模型组,以解决故障预测时序信息记忆问题与小样本条件下数据驱动模型训练过拟合问题;采用 Adaboosting 算法计算模型权重,并基于实时数据动态调整,以滤除复杂机载环境应力引入的预测误差,解决多模型融合的性能差异问题。最后,采用 NASA 公开的锂电池退化数据集进行仿真验证,实验结果表明,相较于传统 BP 神经网络、经典 LSTM 和 LSTM 基模型,该方法具有更高的趋势拟合度和预测精度。

关键词: 航空电子产品;故障预测;数据驱动;长短期记忆(LSTM)神经网络;多模型融合

开放科学(资源服务)标识码(OSID):



中图分类号: V215. 07 文献标志码: A 文章编号: 1001-893X(2023) 08-1237-06

An Avionics Fault Prognostic Method Based on Multi-model Fusion

WEN Jia ,LIANG Tianchen ,CHEN Qingzhou ,QIAN Dong

(Southwest China Institute of Electronic Technology ,Chengdu 610036 ,China)

Abstract: Under the complex airborne environment stress conditions ,the fault prognostic of avionics products faces such problem as large differences in degradation trends and small sample size of training data. To resolve these problems and meet the needs of intelligent scheduling and autonomous maintenance of modern integrated avionics systems ,a fault prognostic method combining the Long Short-Term Memory (LSTM) neural network model and the integrated learning framework is proposed. To solve the problem of fault prognostic time series information memory ,the Dropout mechanism is introduced into the LSTM model and a differential LSTM model group is built based on different historical data sets to solve the problem of data-driven model training over fitting under the condition of small samples. In the process of model fusion ,the Adaboosting algorithm is used to calculate the weight of a single model ,and it is dynamically adjusted based on real-time data to filter out the prognostic error caused by the complex airborne environmental stress and solve the performance difference problem of different models. Finally ,the lithium battery degradation data set published by NASA is used for simulation verification. The experimental result shows that compared with the traditional BP neural network ,the classic LSTM and the LSTM base model ,the proposed method has higher trend fitting degree and prognostic accuracy.

Key words: avionics product; fault prognostic; data-driven; long short-term memory (LSTM) neural network; multi-model fusion

* 收稿日期: 2022-05-21; 修回日期: 2022-08-11
通信作者: 文佳

0 引言

随着现代电子信息技术的高速发展与大规模集成电路和芯片的广泛应用,航空电子系统在飞机平台中扮演着越来越重要的角色,系统功能更加复杂,硬件规模更加庞大,产品故障对飞行安全与任务可靠性的潜在影响更大^[1-2]。故障预测与健康管理技术通过运用先进的传感器、智能算法(如傅里叶变换、卡尔曼滤波等)和模型(如物理模型、神经网络、专家系统)来监测、诊断及预测产品的健康状态,以解决电路模块高度集成化条件下航空电子产品 BIT (Built-in Test) 手段故障检测隔离水平有限、缺乏健康状态量化评估与预测能力的问题,是实现复杂航空电子系统故障重构与视情维修的关键技术^[3-5]。

目前,航空电子产品故障预测方法主要包括基于失效物理模型和基于数据驱动两种方法^[6-7]。基于失效物理模型的方法需要开展大量的实验来探索产品的退化过程和机理,以构建准确的失效物理模型满足故障预测的需求^[8-10]。该方法虽然在实验室验证中取得了一定的效果,但应用到航空电子产品上还存在以下问题:一是航空电子产品在运行过程中受湿热、振动、复杂电应力等多重因素耦合作用影响,退化机理难掌握,失效物理模型构建的边界条件难确定;二是航空电子产品组成结构复杂,产品差异性大,实验室构建的通用模型预测精度有限,定制模型实验周期长、成本高,难以在工程中推广。

基于数据驱动的方法优势在于无需掌握产品故障机理和构建失效模型,特别是对于航空航天领域复杂系统,很难直接构建表征其中电子产品性能退化与剩余寿命的物理模型,而这些产品却具备可用的状态监测信息和测试数据,因此,数据驱动的方法得到了美国航空航天局(National Aeronautics and Space Administration, NASA)、众多研究机构及企业的广泛重视^[11]。国内不少学者也对预测方法开展了研究:李奎等人^[12]采用 AGA-BP 模型对交流接触器的故障进行了预测;陈绍炜等人^[13]将遗传算法引入 SVM 模型,避免了外部应力变化对预测效果的影响。然而,浅层机器学习模型对长序列时序数据提取能力的不足,非线性拟合偏差大,预测精度难以满足航空产品需求。

神经网络作为一种数据驱动方法中深度学习的典型模型,已经成功应用于机械、电子和医疗等多个领域^[14-18]。长短期记忆(Long Short-Term Memory, LSTM)是在循环神经网络(Recurrent Neural Network, RNN)基础上改进的时间递归神经

网络,可有效解决循环神经网络对长期记忆的依赖和梯度消失问题,自动捕获原始数据中高质量的特征,实现性能降级趋势的高非线性拟合^[19]。相较于浅层学习模型, LSTM 具有更强的非线性特征提取能力,其结构中的记忆保留机制更适合处于处理和预测时间序列的演变趋势。王鑫等人^[20]构建了多层网格搜索的 LSTM 预测模型,并与多种典型时间序列预测模型进行对比,验证了 LSTM 在故障时间序列分析的适用性。但在实际应用过程中,真实航空数据量小、类似产品数据量大、健康与故障样本不均衡等问题成为限制方法应用效果的关键问题。

针对航空复杂工况环境条件以及数据小样本问题,本文将集成学习与改进 LSTM 模型相结合,构建含有 Dropout 机制的 LSTM 模型组对相似产品的历史数据进行学习,完成基模型训练;然后根据 Adaboosting 算法和真实产品数据将 LSTM 模型组集成成为完整的预测框架;最后将集成后的预测框架应用于实际工作场景,预测航空电子产品的剩余寿命。

1 多模型集成的预测框架

由于航空电子产品运行场景常伴随高低温、振动冲击和腐蚀,导致产品的故障模型具有较强的随机性、复杂性并与所受外部应力强耦合等特性。为满足复杂应用场景下的预测精度要求,本文提出了基于 Adaboosting 算法的多模型集成架构,如图 1 所示。

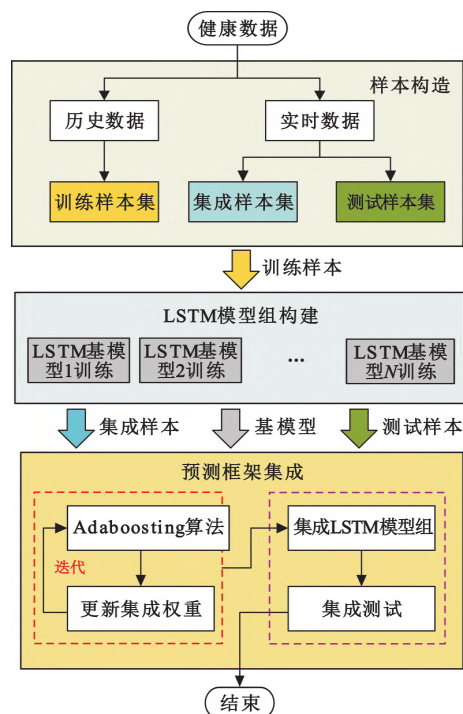


图1 集成预测架构图

多模型的集成主要包含样本构造、基模型训练和基模型集成三部分, 具体流程如下:

Step 1 对历史数据进行标准分数归一化, 按照每个样本为预测步长 $N+1$ 构造训练样本集; 对真实产品数据进行同样的归一化处理, 按照 1:2 的数据比例构造集成样本集和测试样本集。标准分数归一化公式如下:

$$y_j = \frac{x_j - \bar{x}}{\sqrt{\sum_{i=1}^N (x_i - \bar{x})^2}} \quad (1)$$

Step 2 初始化 LSTM 基模型组, 根据不同的训练参数依据 2.2 节训练流程完成 LSTM 基模型的构建。

Step 3 根据 Adaboosting 算法和集成样本集对集成权重进行计算, 完成强学习模型的训练。

Step 4 将测试样本集输入预测框架集成后的强学习模型, 得到预测结果。

2 改进 LSTM 基模型构建

2.1 改进 LSTM 基模型网络结构

长短期记忆神经网络单元的主要结构包括输入门、输出门和遗忘门三种处理结构, 相较于经典 RNN 内部节点的独立状态具有更强的控制筛选能力, 可以去除记忆中的冗余和无效信息, 使 LSTM 成为适合长期依赖问题的模型结构。然而, 在样本量较小、数据分布随机性较大的场景下, LSTM 模型容易过分依赖训练样本, 学习到的特征将失去通用性。

为了解决模型过拟合问题, 本文将 Dropout 机制引入 LSTM 单元中, 优化后的单元结构如图 2 所示。一个内部节点拥有四种状态(单元状态、输入门状态、遗忘门状态和输出门状态)和四种状态对应的 Dropout 控制器 D1~D4。在训练过程中, Dropout 控制器会根据预设比率随机使状态失效, 减少节点间的相互作用并引入类似正则化的稀疏效果。




图 2 改进 LSTM 的单元结构

LSTM 对信息中故障特征的提取主要取决于内部结构的信息状态, 实质上模型输出是对原始输入状态信息的累加结果。

第一步, 遗忘门状态 f_t 用以决定前一时刻的单元状态中要删除和保留的信息内容, 计算公式如 (2) 所示:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2)$$

式中: b_f 表示遗忘门的偏置。

第二步, 确定在当前时刻的单元状态中待存储的信息内容。首先, 输入门的 sigmoid 层决定应更新哪些信息。然后, \tanh 层创建在下一个状态下更新的新候选值向量 \tilde{c}_t 。输入门的计算公式如下:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (3)$$

$$\tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (4)$$

式中: i_t 表示输入门内信息存储比率; W_i 和 W_c 分别表示输入门的连接权重; b_i 和 b_c 分别为输入门内两个偏置量; \tanh 函数计算如公式 (5) 所示:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (5)$$

第三步, 根据遗忘门状态、前一时刻的单元状态 c_{t-1} 和输入门输出更新当前时刻 t 的单元状态 c_t 。当前时刻的候选值 t 计算公式如式 (6) 所示:

$$c_t = D3 \times (D1 \times f_t \times c_{t-1} + D2 \times i_t \times \tilde{c}_t) \quad (6)$$

最后, 确定单元当前时刻的输出, 包括两个部分: sigmoid 层在输出门中起到对单元状态的过滤作用; \tanh 层根据当前时刻的放单元状态计算输出所需的信息。输出门的计算公式如下:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (7)$$

$$h_t = D4 \times o_t \times \tanh(c_t) \quad (8)$$

2.2 基模型训练流程

改进 LSTM 基模型的训练流程如下:

Step 1 根据各个 LSTM 模型的结构参数和超参数生成各单元节点内的链接权重和偏置, 完成节点状态初始化。

Step 2 将训练样本集输入初始化后的 LSTM 模型, 前向传递得到模型的输出值和预测误差值。

Step 3 根据时间梯度下降算法和模型预测误差值, 更新单元节点内的连接权重和偏置。

Step 4 当模型训练次数达到最大循环次数或误差值小于预设值, 基模型训练结束。

3 多模型集成算法

集成学习是通过对多个基模型输出结果进行融

合, 来实现高精度、高可靠故障预测, 其原理如图 3 所示。

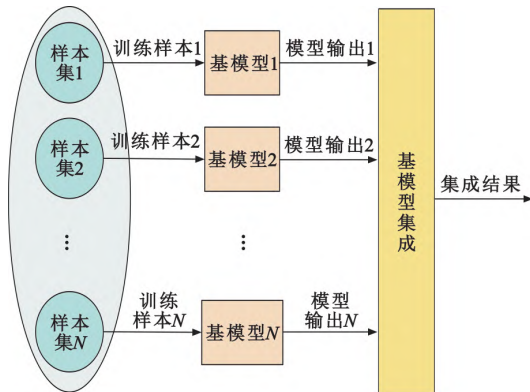


图3 集成学习原理

针对加权投票法、平均法、相对投票法等常用融合算法存在的不足——只考虑单模型性能差异来设置投票权重, 无法解决不同退化情况下不同基模型的性能差异问题, 本文选择 Adaboosting 算法对组合策略进行优化, 采用线性误差函数对 LSTM 基模型组进行循环迭代得到一系列基模型的权重系数^[21]。

该算法首先初始化验证样本集中每个样本的误差权重, 该权重是每个样本对最终误差综合的影响大小。若集成样本集 $D = \{x_i, y_i\}_{i=1}^N$, LSTM 基模型数量为 T , 集成算法流程如下:

Step 1 初始化集成样本集的误差权重 W_1 , 初始化公式如下:

$$W_1 = (w_{1,1}, w_{1,2}, \dots, w_{1,N}), w_{1,i} = \frac{1}{N}. \quad (9)$$

Step 2 LSTM 模型 1~ T 分别作为基模型进行循环迭代, 依次计算基模型的输出 h_t 、样本最大误差 E_t 、第 i 个样本的相对误差 e_{ti} 、基模型的预测误差率 ε_t 、基模型的权重系数 α_t 、泛化因子 Z_t , 更新样本集的误差权重 W_{t+1} 相关公式如下:

$$E_t = \max |y_i - h_i(x_i)|, i = 1, 2, \dots, N, \quad (10)$$

$$e_{ti} = \frac{|y_i - h_i(x_i)|}{E_t}, \quad (11)$$

$$\varepsilon_t = \sum_{i=1}^N w_{t,i} e_{ti}, \quad (12)$$

$$\alpha_t = \frac{\varepsilon_t}{1 - \varepsilon_t}, \quad (13)$$

$$Z_t = \sum_{i=1}^N w_{t,i} \alpha_t^{1-e_{ti}}, \quad (14)$$

$$w_{t+1,i} = \frac{w_{t,i}}{Z_t} \alpha_t^{1-e_{ti}}, \quad (15)$$

$$W_{t+1} = (w_{t+1,1}, w_{t+1,2}, \dots, w_{t+1,N}). \quad (16)$$

Step 3 根据 Step 2 计算出的 LSTM 基模型权重系数构建强学习模型, 强模型的输出公式如下:

$$H(x) = \sum_{t=1}^T \left(\ln \frac{1}{\alpha_t} \right) K. \quad (17)$$

式中: K 表示所有基模型输出的中位数。

4 仿真验证

航空蓄电池是飞机电源系统的核心组成, 主要在主电源异常时为机内关键系统设备供电, 目前已经作为应急电源和辅助电源广泛应用于国内外各类飞机平台^[22]。航空电子产品主要是在航空外部应力下对健康相关信息进行处理, 而航空蓄电池健康信息清晰, 故障机理典型, 因此本文选择航空蓄电池作为航空电子产品的典型代表。航空蓄电池主要包括镍镉蓄电池、铅酸蓄电池、锂离子蓄电池三类。随着锂离子蓄电池工艺技术逐渐成熟, 其寿命、质量和容量优势逐渐明显, 目前已经逐渐取代镍镉蓄电池、铅酸蓄电池成为蓄电池的主要器材。因此本文以锂离子航空蓄电池作为研究对象验证所提方法, 实验数据采为 NASA 的 4 组锂离子蓄电池数据^[23] (前三组数据作为历史数据, 第四组作为实时数据), 电池额定容量为 $2 \text{ A} \cdot \text{h}$, 实验温度为 25°C , 实验数据如图 4 所示。

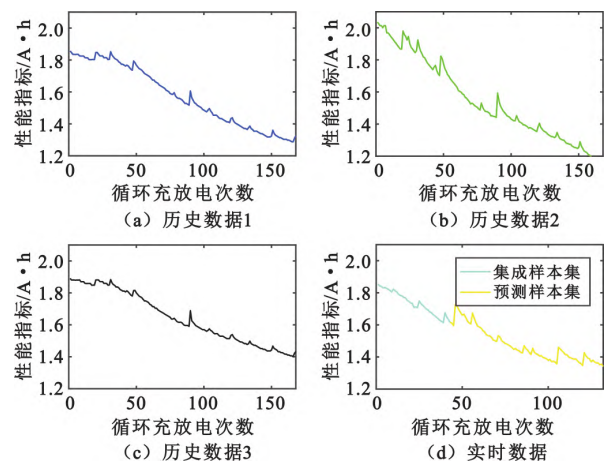


图4 实验数据

验证试验采用单步预测, 预测步长为 4。每一个样本 $\{x_1, x_2, x_3, x_4, x_5\}$ 包含 5 个数据点, $\{x_1, x_2, x_3, x_4\}$ 作为模型输入, x_5 作为预测标签。历史数据 1~3 的数据长度均 168, 因此训练样本集 $\text{TR}_1\{x_1, x_2, x_3, x_4, x_5\}$, $\text{TR}_2\{x_2, x_3, x_4, x_5, x_6\}$, \dots , $\text{TR}_{500}\{x_{500},$

$x_{501} x_{502} x_{503} x_{504}$ }。第 4 组电池数据按照 1 : 2 的比例构造集成样本集 $E_1\{x_1 x_2 x_3 x_4 x_5\}$, $E_2\{x_2 x_3 x_4 x_5 x_6\}$, \cdots , $E_{40}\{x_{40} x_{41} x_{42} x_{43} x_{44}\}$ 和测试样本集 $TE_1\{x_{41} x_{42} x_{43} x_{44} x_{45}\}$, $TE_2\{x_{42} x_{43} x_{44} x_{45} x_{46}\}$, \cdots , $TE_{88}\{x_{128} x_{129} x_{130} x_{131} x_{132}\}$ 。为了验证集成本文所提的优化策略对模型预测的影响 ,验证实验设置两个对比方法分别为 LSTM 基模型和 BP 神经网络。具体参数设置如下:

- 1) 本文方法: LSTM 基模型组包含 3 个 LSTM 基模型 ,LSTM 结构设置分别为 [4 100 1] , [4 150 1] 和 [4 200 1] ,学习率 0.1 ,训练采用含动量的梯度下降算法 ,动量设置为 0.8 ,误差收敛门限为 0.01 ,最大迭代次数为 300 ,单元内各 Dropout 控制器的 Dropout 率为 0.5。
- 2) 集成基模型: LSTM 结构设置分别为 [4 150 1] ,训练样本为 3 个全寿命周期数据 ,其他训练参数与本文方法保持一致。
- 3) 经典 LSTM: LSTM 结构设置分别为 [4 150 1] ,单元内不包含 Dropout 控制器 ,其他训练参数与本文方法一致。
- 4) BP 神经网络: 神经网络结构为 [4 100 1] ,同样采用含动量的梯度下降算法 ,超参数设置与经典 LSTM 模型一致。

图 5~7 中分辨展示了本文方法与三种对比方法的预测效果 ,为了提升预测结果可视化效果 ,图中下半部为真实寿命和预测差值的 5 倍。本文分别对不同方法进行了 10 次随机试验 ,并对 10 次试验结果的均方根误差(Root Mean Squared Error ,RMSE) 、平均绝对误差(Mean Absolute Error ,MAE) 和平均绝对百分比误差(Mean Absolute Percentage Error ,MAPE) 进行平均计算 ,统计结果如表 1 所示。




图 5 本文方法预测结果

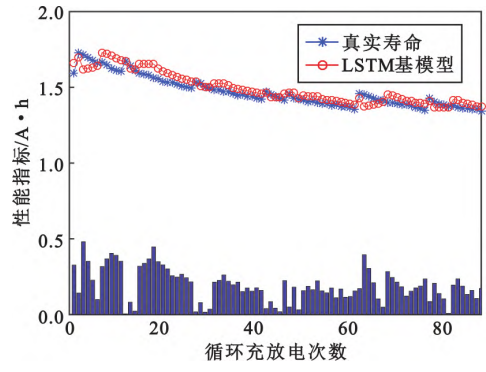


图 6 LSTM 基模型预测结果




图 7 经典 LSTM 预测结果




图 8 BP 神经网络预测结果

| 表 1 预测结果统计 | | | |
|------------|-------|-------|---------|
| 方法 | RMSE | MAE | MAPE |
| BP 神经网络 | 0.114 | 0.113 | 0.078 4 |
| 经典 LSTM 模型 | 0.062 | 0.059 | 0.042 5 |
| LSTM 基模型 | 0.032 | 0.038 | 0.025 7 |
| 本文方法 | 0.028 | 0.011 | 0.010 6 |

经过分析比较实验结果可得出以下两个结论: 本文方法的预测框架和增加了 Dropout 控制器 LSTM 基模型相较于经典 LSTM 和传统机器学习的 BP 神经网络有着更好地特征提取效果 ,预测趋势拟合效果明显提升; 采用 Adaboosting 算法对基模型进行集成 ,提高了预测的稳定性和精度 ,有效解决了在

几个全寿命周期这一小样本条件下模型训练的过拟合问题。

5 结 论

本文针对复杂机载环境应力条件下的航空电子产品故障预测问题,提出了结合 Dropout 策略的 LSTM 模型改进结构和基于 Adaboosting 算法的多模型融合预测框架,解决了故障预测时序信息记忆问题与小样本下的模型过拟合问题。通过仿真实验证明,相较于目前浅层的学习模型和经典 LSTM 模型,本文方法有着更好的稳定性、趋势拟合度和预测精度,可以为基于数据驱动的方法在航空电子产品故障预测方面的应用提供参考。

参考文献:

- [1] MOIR I, SEABRIDGE A G. Military avionics systems [M]. New Jersey: John Wiley & Sons Ltd. 2006.
- [2] 文佳. 基于多信号模型的综合化航电系统综合诊断算法设计[J]. 电讯技术, 2014, 54(3): 361-367.
- [3] 黄鹤, 卢海涛. 综合化航空电子系统 PHM 应用与设计[J]. 电讯技术, 2014, 54(3): 245-250.
- [4] VALIŠ D, ŽÁK L, POKORA O. Failure prediction of diesel engine based on occurrence of selected wear particles in oil[J]. Engineering Failure Analysis, 2015, 56: 501-511.
- [5] 吕琛, 马剑, 王自力. PHM 技术国内外发展情况综述[J]. 计算机测量与控制, 2016, 24(9): 1-4.
- [6] 卢海涛, 王自力. 综合航空电子系统故障诊断与健康管理技术发展[J]. 电光与控制, 2015, 22(8): 60-65.
- [7] 梁天辰. 基于多深度置信网络融合的航空电子设备故障预测[J]. 电讯技术, 2021, 61(2): 248-253.
- [8] 邓森, 景博. 基于测试性的电子系统综合诊断与故障预测方法综述[J]. 控制与决策, 2013, 28(5): 641-649.
- [9] ZHANG J, HUANG H W, ZHANG L M, et al. Probabilistic prediction of rainfall-induced slope failure using a mechanics-based model [J]. Engineering Geology, 2014, 168: 129-140.
- [10] TANG S, YU C, WANG X, et al. Remaining useful life prediction of lithium-ion batteries based on the Wiener process with measurement error [J]. Energies, 2014, 7(2): 520-547.
- [11] 姜洪开, 邵海东, 李兴球. 基于深度学习的飞行器智能故障诊断方法[J]. 机械工程学报, 2019, 55(7): 27-34.
- [12] 李奎, 李晓倍, 郑淑梅, 等. 基于 BP 神经网络的交流接触器剩余电寿命预测[J]. 电工技术学报, 2017, 32(15): 120-127.
- [13] 陈绍伟, 潘新, 刘涛. 基于遗传算法 SVM 的电子元件寿命预测[J]. 西北工业大学学报, 2014, 32(4): 637-641.
- [14] ORDÓÑEZ F J, ROGGEN D. Deep convolutional and LSTM recurrent neural networks for multimodal wearable activity recognition[J]. Sensors, 2016, 16(1): 115-139.
- [15] PENSADO-MARIÑO M, FEBRERO-GARRIDO L, PÉREZ-IRIBARREN E, et al. Estimation of heat loss coefficient and thermal demands of in-use building by capturing thermal inertia using LSTM neural networks [J]. Energies, 2021, 14(16): 1-14.
- [16] KWAK G H, LING L, HUI P. Predicting the need for vasopressors in the intensive care unit using an attention based deep learning model[J]. Shock, 2020, 56(1): 73-79.
- [17] YING W, ZHANG L, DENG H. Sichuan dialect speech recognition with deep LSTM network [J]. Frontiers of Computer Science, 2020, 14(2): 378-387.
- [18] CHI P, ZHANG Z, LIANG R, et al. A fault diagnosis method of double-layer LSTM for 10 kV single-core cable based on multiple observable electrical quantities [J]. Electrical Engineering, 2022, 104(2): 603-614.
- [19] CORNIA M, BARALDI L, SERRA G, et al. Predicting human eye fixations via an LSTM-based saliency attentive model [J]. IEEE Transactions on Image Processing, 2018, 27(10): 5142-5154.
- [20] 王鑫, 吴际, 刘超, 等. 基于 LSTM 循环神经网络的故障时间序列预测[J]. 北京航空航天大学学报, 2018, 44(4): 772-784.
- [21] LIU L, HUA Y, ZHAO Q, et al. Blind image quality assessment by relative gradient statistics and adaboosting neural network [J]. Signal Processing: Image Communication, 2016, 40: 1-15.
- [22] 范红军, 殷合香. 航空锌银蓄电池失效机理及延寿方法[J]. 电源技术, 2013, 37(10): 1805-1808.
- [23] NASA Prognostics Center of Excellence. Battery prognostics [EB/OL]. (2020-02-15) [2022-05-10]. <https://ti.arc.nasa.gov/tech/dash/pcoc/battery-prognostics/references/2007>.

作者简介:

文 佳 男, 1984 年生于湖南长沙, 2011 年获博士学位, 现为高级工程师, 主要研究方向为可靠性系统科学与工程。

梁天辰 男, 1993 年生于浙江温岭, 2019 年获硕士学位, 现为助理工程师, 主要研究方向为航空工程。

陈肇宙 男, 1996 年生于湖北咸宁, 2020 年获硕士学位, 现为助理工程师, 主要研究方向为安全科学与工程。

钱 东 男, 1985 年生于四川苍溪, 2011 年获博士学位, 现为高级工程师, 主要研究方向为航空电子系统。