

文章编号: 1001-9081(2016) S2-0099-04

基于时序分解的飞机平均故障间隔飞行时间组合预测

韩西龙^{1*}, 李青¹, 刘锋²

(1. 北京航空航天大学 机械工程及自动化学院, 北京 100191; 2. 成都飞机工业(集团)有限责任公司, 成都 610092)

(* 通信作者电子邮箱 976839166@qq.com)

摘要: 针对飞机平均故障间隔飞行时间(MFHB)指标值的预测问题, 提出一种基于时间序列分解的组合预测方法。首先利用 STL(Seasonal and Trend Decomposition using Loess) 方法分解出 MFHB 指标的长期趋势项和季节变动项, 然后以灰色模型预测指标的长期趋势, 以 BP 神经网络和支持向量机回归组合模型分别预测指标的季节变动, 根据误差权重计算季节变动的加权值, 最后以加法模型合并趋势和季节的预测值获得最终结果。利用服务点积累的指标数据对方法进行检验, 与单独使用支持向量机回归预测得到的结果相比, 平均绝对误差由 45% 减小至 21%, 证明该方法能够有效提高预测精度, 为保障人员提供可信的指标预测结果。

关键词: 时间序列; 灰色预测; 神经网络; 支持向量机回归; 组合预测

中图分类号: TP181 **文献标志码:** A

Combination forecasting of mean flying hours between failures for aircraft based on time series decomposition

HAN Xilong^{1*}, LI Qing¹, LIU Feng²

(1. School of Mechanical Engineering and Automation, Beihang University, Beijing 100191, China;

2. Chengdu Aircraft Industrial(Group) Co. Ltd., Chengdu Sichuan 610092, China)

Abstract: Concerning the prediction accuracy of aircraft's Mean Flying Hours between Failures (MFHB) index, a combination forecasting method based on time series decomposition was proposed. Firstly, the MFHB data was decomposed into the long term trend and seasonal variation by using the Seasonal and Trend Decomposition using Loess (STL). Secondly, the long-term trend of the index was predicted by the grey model, and the seasonal variation was separately predicted according to Back Propagation (BP) neural network and support vector machine regression model. The weighted value of seasonal variation was calculated according to error weight. Finally, the final result was calculated by combining the seasonal and trend prediction values under the addition model. The practical prediction effect of the method was verified by the measured data from the service point. The mean absolute error was reduced to 21% by using this method in contrast to 45% by using support vector machine regression model alone. This method can effectively improve the prediction accuracy, and provide credible index prediction results for security personnel.

Key words: time series; grey prediction; neural network; support vector machine regression; combination forecasting

0 引言

可靠性是产品的固有属性, 是军用飞机重要的设计指标。在装备保障过程中, 主机厂围绕保持和提高飞机使用阶段的可靠性, 进行维修排故、备件支持、技术服务等保障活动, 同时对不同服务点的可靠性指标进行分析, 根据数据的变化趋势和波动情况, 预测未来时段的指标水平, 其中平均无故障间隔时间 (Mean Flight Hours Between Failures, MFHB) 是使用阶段可靠性的重要指标。使用过程中收集的 MFHB 数据, 是对飞机整体质量和维修保障水平进行评价的重要依据, 因为它反映了真实的使用维护情况及环境因素影响。指标数据一般按月收集, 每个服务点机群组成一组等间隔的时间序列, 时间序列预测正是在已知的历史事件的基础上, 使用模型对未来事件进行预测的过程, 例如文献 [1] 中将飞机每月的故障率视为一个随机时间序列, 基于自回归滑动平均 (Auto-Regressive and Moving Average, ARMA) 模型对其进行预测, 通过对比多种算法的预测效果, 验证了时间序列分析方法在解

决飞机可靠性指标预测问题上的可行性, 但是由于它采用单一算法预测, 存在误差较大、可信度低的问题。

为提高时间序列预测的精度和实用性, 国内外学者从预测方式和预测算法等方向进行研究, 其中组合预测是目前比较有效的方法, 它能够降低各个模型的误差波动。如将组合预测运用到水质指标的预测中, 利用不同样本建立多个灰色预测模型, 并与神经网络模型进行组合, 预测效果优于单独使用这两种模型^[2]。由于时间序列数据经常是多种信息的叠加, 通过时间序列分解, 抽取不同分量进行单独研究非常必要, 例如通过小波变换提取备件消耗数据的不同频率信息, 用改进的灰色模型 (Grey Model, GM) 和 ARMA 模型分别对分解后的非线性低频趋势信息和相对平稳的高频信息进行预测, 叠加各子序列获得最终的预测结果, 其效果优于单一预测模型^[3]。本文研究的飞机平均故障间隔飞行时间, 具有趋势季节性明显、干扰因素较多的特点, 适合采用时序分解和组合预测进行研究。

本文从提高模型预测效果的角度出发, 建立飞机 MFHB

收稿日期: 2016-03-21; 修回日期: 2016-04-26。

作者简介: 韩西龙 (1990—), 男, 山东济宁人, 硕士研究生, 主要研究方向: 装备维修保障信息化; 李青 (1961—), 女, 湖北黄梅人, 教授, 博士, 主要研究方向: 装备维修保障管理、企业信息化; 刘锋 (1976—), 男, 四川成都人, 工程师, 硕士, 主要研究方向: 装备维修保障。

指标的时间序列分解模型和组合预测模型,时间序列分解模型可以提取数据的长期趋势和季节变动,利用组合预测模型,融合灰色预测、BP神经网络预测和支持向量机回归预测的优点,改进指标的预测效果。

1 平均故障间隔飞行时间预测方法

分析某外贸飞机的月平均故障间隔飞行时间,整体上指标数据呈上升趋势,5年内数据峰值集中在第一季度末和第二季度初,各年数据具有一定的季节性。由于受到飞机任务、异常环境、突发事件等干扰因素影响,部分月份的数据存在不规则变化。原始的指标序列是多种信息的叠加,如果直接采用常见的预测模型如ARMA、BP神经网络等,很难完全满足模型的适用条件。时间序列分解将不同影响因素作用的数据从时序中分离出去,可以更好地分析各数据的变化规律,选择最合适的方法进行预测^[4]。本文采用加法模型对MFHBF的影响因素进行建模,利用STL分解算法,得到MFHBF数据的长期趋势项和季节变动项,指标的长期趋势反映现有保障体系的整体效果,而季节变动反映每个保障周期内指标的规律性波动,对指标分解后进行预测,更具有现实意义。另一方面,不同的预测算法擅长解决不同的预测问题,为了最大限度利用各算法优势,可以采用组合预测模型对分解后的MFHBF进行预测。

组合预测即对同一个问题,采用两种以上不同预测方法进行预测。组合的主要目的是综合利用各种方法所提供的信息,尽可能地提高预测精度。汪同三等^[5]对组合预测进行了优性证明,概括地说,组合预测通过三种方式提高了预测的准确性:第一,降低了预测误差的偏差效应;第二,降低了预测误差的波动效应;第三,组合产生了抵消效应。指标经STL分解后得到的季节变动项具有复杂的非线性结构,因此组合预测选择BP神经网络和支持向量机回归两种方法,充分发挥BP神经网络强大的非线性映射能力,并通过支持向量机回归良好的泛化能力,减少BP神经网络过学习带来的误差影响,根据误差权重将两种方法的结果加权计算,获得季节变动项的组合预测值。灰色模型对中长期趋势的预测具有较高的精度,本文采用GM(1,1)模型对长期趋势项进行预测,最后利用加法模型合并两部分结果获得最终预测值。图1为MFHBF数据时序分解与组合预测的流程。




图1 MFHBF数据时序分解与组合预测流程

2 平均故障间隔飞行时间时序分解和组合预测

2.1 基于STL方法分解MFHBF指标

时间序列数据的变化是众多复杂因素共同作用的结果,影响因素主要包括长期趋势、季节变动、周期变动和不规则变动^[6],其中不规则变动又包含随机变动和突发变动,这一影响因素往往难以测定,一般作为干扰项处理。季节变动和周期变动的区别在于周期变动不具有固定周期,而季节变动具有固定周期,很多时候没必要区分长期趋势因素和周期变动因素,可以将二者统一为长期趋势。时间序列分解能够帮助分析者去除其他因素的影响,单纯分析某一确定性因素影响

下的序列分布规律。上文对平均故障间隔飞行时间数据进行了宏观分析,建立其分解模型,即 $Y = F(M_1, M_2, M_3)$,其中 Y, M_1, M_2, M_3 分别为MFHBF指标、长期趋势项、季节变动项、不规则变动项。目前常用的分解模型有加法模型和乘法模型,如果季节变动的幅度以及趋势周期的波动不随时间变化或者变化幅度不大,适合采用加法模型。根据对MFHBF指标的初步分析,加法模型满足分解要求,即:

$$Y = M_1 + M_2 + M_3 \quad (1)$$

经典的时间序列分解方法如移动平均法存在如下几个问题:1)无法估算最开始和最后的几个样本的趋势值(即移动平均法的局限性);2)假设季节因素每年都一样;3)无法很好地处理异常值。STL分解法适用于加法模型,是一个兼具通用性和鲁棒性的时间序列分解法^[7],它的分解过程基于Loess,即局部加权回归散点平滑法,具有以下优点:1)可以处理任何类型的季节变动因素的数据,而不仅仅是季度或是月份的数据;2)允许季度成分随着时间变化而变化,可以控制变化率;3)可以自行控制趋势-周期成分的平滑度;4)可以保留开始和最后的样本趋势值。

使用STL方法对平均故障间隔飞行时间进行分解,获得低频率的趋势项、高频率的季节项及不规则变化的残余项,即Trend、Seasonal、Remainder,根据式(1),对于MFHBF指标,Trend即为指标长期趋势,Seasonal即指标的季节变动,Remainder残余项可以认为是干扰因素造成的不规则变动。分解后指标的长期趋势和季节周期更具规律性,之后便可以对两个分解项分别进行预测。

2.2 长期趋势项灰色预测

灰色预测是一个应用非常普遍的预测模型,它克服了概率统计方法需要大量样本来研究分布规律的弊病,具有样本需求小、短期预测精度高的特点^[8]。MFHBF指标数据经STL方法分解,可以获得明显的长期趋势,对未来一年的数据进行预测,显然最新年份的历史数据比之前数据更具有参考价值,即以近期的小样本数据预测指标的未来趋势。本文采用经典的GM(1,1)模型,它的适用范围与发展系数 a 的取值情况有关,只有在 $1 - a < 2$ 的情况下预测才有意义,经计算MFHBF指标长期趋势项的发展系数 $-a < 0.1$,GM(1,1)模型可用于中长期预测。

建立长期趋势项的GM(1,1)模型,即单变量一阶灰色模型,实质是对趋势项作一次累加生成,使生成数列呈一定规律,通过建立微分方程模型,求得拟合曲线,用以对系统进行预测,其建模步骤如下:

设趋势项的时间序列为:

$$x^{(0)} = \{x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(n)\} \quad (2)$$

$x^{(1)}$ 为 $x^{(0)}$ 的累加序列:

$$x^{(1)} = \{x^{(1)}(1), x^{(1)}(2), \dots, x^{(1)}(n)\};$$

$$x^{(1)}(k) = \sum_{i=1}^k x^{(0)}(i); k = 1, 2, \dots, n \quad (3)$$

作 $x^{(1)}$ 的一阶均值生成:

$$x = \{x(2), x(3), \dots, x(n)\};$$

$$x(k) = \frac{1}{2}(x^{(1)}(k) + x^{(1)}(k-1)); k = 2, 3, \dots, n \quad (4)$$

构造一阶线性灰色微分方程:

$$\begin{cases} \alpha^{(1)}(x^{(1)}) + a \otimes (x^{(1)}) = u \\ \frac{dx^{(1)}}{dt} + ax^{(1)} = u \end{cases} \quad (5)$$

利用最小二乘法求得参数 a, u :

$$\hat{a} = \begin{bmatrix} a \\ u \end{bmatrix} = (B^T B)^{-1} B^T Y_N \quad (6)$$

$$Y_N = \begin{bmatrix} x^{(0)}(2) \\ x^{(0)}(3) \\ \vdots \\ x^{(0)}(n) \end{bmatrix}, B = \begin{bmatrix} -x(2) & 1 \\ -x(3) & 1 \\ \vdots & \vdots \\ -x(n) & 1 \end{bmatrix}$$

$x^{(1)}$ 的灰色预测模型:

$$\hat{x}^{(1)}(k+1) = (x^{(0)}(1) - u/a) e^{-ak} + u/a; k = 0, 1, \dots \quad (7)$$

$x^{(0)}$ 的灰色预测模型:

$$\hat{x}^{(0)}(k+1) = (1 - e^a)(x^{(0)}(1) - u/a) e^{-ak}; k = 1, 2, \dots \quad (8)$$

为了评价指标趋势项 GM(1,1) 模型的预测精度,针对分解后的 Trend 趋势,截取不同长度时间段样本,进行半年期和一年期预测,检验模型的后验差比值 C 和小误差频 P ,选取最佳的样本长度。表 1 为 GM(1,1) 预测趋势项的精度等级表。

表 1 GM(1,1) 预测趋势项的精度等级表

精度等级	P	C
好	>0.95	<0.35
合格	>0.8	<0.5
勉强合格	>0.7	<0.45
不合格	≤ 0.7	≥ 0.65

2.3 季节变动项组合预测

经过 STL 方法分解获得 MFHBF 指标的季节变动项 Seasonal, 该项反映了每一年指标的季节变动规律,且每年略有变化,显然季节项具有非常复杂的非线性结构。因为神经网络模型具有的良好非线性映射能力、较高的拟合精度、有效的学习方法以及层次性的模型结构,使其常用于非线性时间序列预测,如运用 BP 神经网络对交通运输量进行预测^[9]。BP 神经网络模型的运用非常广泛,但其缺点是预测精度依赖于网络结构和样本质量,训练后容易陷入局部最小点。而支持向量机(Support Vector Machine, SVM)通过结构风险最小化较好地解决了过学习和局部极小等问题,可以在一定程度上弥补 BP 神经网络模型的缺点。因此,为了提高预测精度,采用 BP 神经网络和支持向量机回归进行组合预测。

2.3.1 BP 神经网络模型

BP 神经网络模型具有良好的非线性组合特性,是一种全局逼近网络,具有很强的学习能力,能够实现输入和输出之间的高度非线性映射,理论上可以逼近任一连续函数^[10]。它是一种按误差逆传播算法训练的多层前馈网络,包括信号的正向传播和误差的反向传播,通过训练不断调整神经元连接权值和阈值,直至达到设定训练目标为止。目前在 BP 网络的应用中,多采用三层结构,三层的 BP 网络就可实现任意函数的逼近。通过对历史 MFHBF 数据的学习,可以找出不同时间指标之间的非线性关系,并将其储存在网络权值中,从而预测数据的未来趋势。

原始的季节变动项记录包含两个属性:日期和数值,为了建立二者之间的关联,常用做法是在构建网络结构时,对输入变量进行扩展,建立滞后变量和日期的派生变量。季节变动项各年度的波动规律具有延续性和相关性,滞后变量可以将序列的过去值与当前值进行关联,将过去值和当前值的映射关系保存到网络结构中,以便对未来值进行滚动预测。MFHBF 季节

变动数据以月为间隔,将滞后变量个数设置为 12 比较合理。设当前输出为 Out_MFHBF, 滞后变量为 Lag_MFHBF-1、Lag_MFHBF-2、...、Lag_MFHBF-12, 即从当前输出值的时间节点开始,将过去 12 个月的数值作为输入变量。其中 Lag_MFHBF-1 的含义为:创建一个滞后变量,将时刻 -1 的数值作为输入。日期派生变量包括月份、季度、样本中的月份编号,用来表示输出数值的日期属性,同时将月份编号和滞后变量的乘积纳入输入变量,增强近期滞后变量对网络权值的影响。图 2 为季节变动项的神经网络结构。BP 神经网络采取常用的三层结构,隐层节点根据经验公式^[11]确定,公式为:

$$j = \sqrt{n+m} + \alpha; \alpha \in [1, 10] \quad (9)$$

其中输入节点个数 n 为 27, 输出节点 m 为 1, 取 α 为 4, 则隐层节点个数 j 为 10。




图 2 BP 神经网络结构

2.3.2 支持向量机回归模型

支持向量机是一种监督式学习方法,广泛应用于统计分类以及回归分析,已成为机器学习领域的研究热点之一。针对具有非线性、随机性特征的数据,支持向量机回归通过引入核函数,把预测问题转化为高维空间中的线性回归问题^[12],可以获得良好的预测精度。本文利用支持向量机回归算法,对季节变动项进行预测,在一定程度上弥补 BP 神经网络容易过学习的缺点。

设预测的输出值为 Out_MFHBF , 其影响因素输入值为 V_i , 支持向量机回归模型同样需要通过学习样本数据来寻找二者之间的函数关系,因此可以利用 BP 神经网络模型中创建的变量映射关系,对向量机进行训练。

2.3.3 基于误差权重的季节项组合预测

为了得到更好的组合预测效果,需要对 BP 神经网络和支持向量机回归的预测结果进行加权合并,显然预测效果好的模型应该分配较大的权重^[13]。在训练数据的尾部截取测试样本,分别输入学习后的模型,计算预测误差,以便定量评估两种模型的预测效果。可采用平均绝对误差作为度量,误差越小表示训练效果越好,设预测的平均绝对误差分别是 e_1 、 e_2 , 组合预测结果为 N , 前面两类模型获得预测值为 N_1 和 N_2 , 权重分别为 w_1 和 w_2 , 则有季节变动项的组合预测公式:

$$N = w_1 * N_1 + w_2 * N_2 \quad (10)$$

其中 $w_1 = e_2 / (e_1 + e_2)$, $w_2 = e_1 / (e_1 + e_2)$ 。

3 实例分析

以主机厂收集的某外贸飞机平均故障间隔飞行时间数据为基础,分析数据的长期趋势和季节特点,对未来一年各月的 MFHBF 数值进行预测。从某服务点积累的 MFHBF 数据中选取 2004 年—2008 年的记录作为样本,该时间段记录没有缺失值和明显的异常值,适合作为验证数据,以 2004 年至 2007 年数据为样本进行学习和训练,以 2008 年 12 个月数据验证预测效果。对 MFHBF 数据进行初步分析,从图 3 可以观察到 MFHBF 指标比较明显的长期趋势和季节变动。

首先在 R 软件中采用 STL 算法分解 MFHBF 样本,分离出长期趋势项 trend 和季节变动项 seasonal。该方法需要将指标数据转换成向量模式,为了对季节项分解,需要设置频率 $frequency = 12$ 。在尽可能保留趋势信息和季节周期信息的同时,残余项的方差和均值越小越好。图4为对 MFHBF 指标进行 STL 分解后各项数据,整体符合指标不断增长和年度波动的客观规律。




图3 MFHBF 历史数据




图4 MFHBF 指标 STL 分解

STL 分解后获得趋势项,运用灰色预测计算未来 12 个月的指标趋势值。趋势变动项经平滑后,非常适合灰色模型预测,采用 12 个月或 24 个月趋势项作输入,发展系数 $-a$ 均小于 0.1,预测精度等级为“好”。对于分解出的季节变动项,借助数据挖掘软件 weka 中的算法工具,实现 BP 神经网络和支持向量机回归预测。BP 神经网络采用 weka 的多层感知器实现,它是一个使用反向传播的分类器,当用于 MFHBF 指标的季节变动项预测,其输出为连续值。支持向量机回归的核函数选择 PolyKernel,复杂度参数 C 为 1.0。原始样本包含日期和数值两个属性,训练前均需要创建滞后变量和派生变量并进行归一化处理。模型训练后选用平均绝对误差对其进行评估,截取 6 个测试样本,分别计算两个模型的平均绝对误差,根据式(10)获得两种方法的组合权重,计算后取 BP 神经网络预测权重 0.6,支持向量机预测权重 0.4。图5、图6为两

种方法预测下一年度季节变动项的实际效果,虚线为预测值。




图5 季节变动项 BP 神经网络预测




图6 季节变动项支持向量机预测

STL 分解满足加法模型,因此,将趋势项和季节变动项两部分预测结果相加,组合预测值 = 灰色预测 + 0.4 * 向量机预测 + 0.6 * BP 预测。为了与单一预测模型对比,使用相同历史数据,直接进行支持向量机回归预测,预测结果见图7和表2,组合预测和单独使用支持向量机回归预测的平均绝对误差分别为 21%、45%,效果更好。本文组合预测方法针对的是具有趋势和季节二重性的 MFHBF 指标,为了进一步验证算法的有效性,利用文献[14]中某航空设备 2000 年—2002 年故障率数据再次进行验证,结果如图8所示,可以看出本文组合预测方法对具有趋势和季节性的故障率指标同样有效。




图7 MFHBF 指标预测效果对比




图8 故障率指标预测效果对比

表2 MFHBF 指标预测实例

真实值	组合预测	组合预测误差	季节项向量机预测	季节项 BP 预测	趋势项灰色预测	单一向量机预测	向量机预测误差
7.52	9.48246	0.260965426	-3.7070	-3.1588	11.1715	4.6303	-0.384268617
11.03	11.94047	0.082544878	1.5623	1.1917	11.2705	9.8272	-0.109048051
14.44	13.39508	-0.072362881	4.2002	3.9488	11.3704	11.8365	-0.180297784
15.30	12.87236	-0.158669281	2.8828	2.7490	11.4711	12.0710	-0.211045752
12.47	14.07257	0.128514034	3.4201	6.0525	11.5728	17.0759	0.369358460
14.03	13.30926	-0.051371347	2.5131	3.7708	11.6754	17.4292	0.242280827
8.01	11.19381	0.397479401	-1.3363	-1.0591	11.7788	14.4493	0.803907615
9.26	11.85187	0.279899568	-0.1112	-0.0303	11.8832	17.4656	0.886133909
8.40	11.82616	0.407876190	-0.0605	-0.5008	11.9885	16.0261	0.907869048
7.24	9.65172	0.333110497	-4.7092	-5.0038	12.0947	12.0968	0.670828729
12.09	11.02977	-0.087694789	-1.6485	-2.8081	12.2019	14.1261	0.168411911

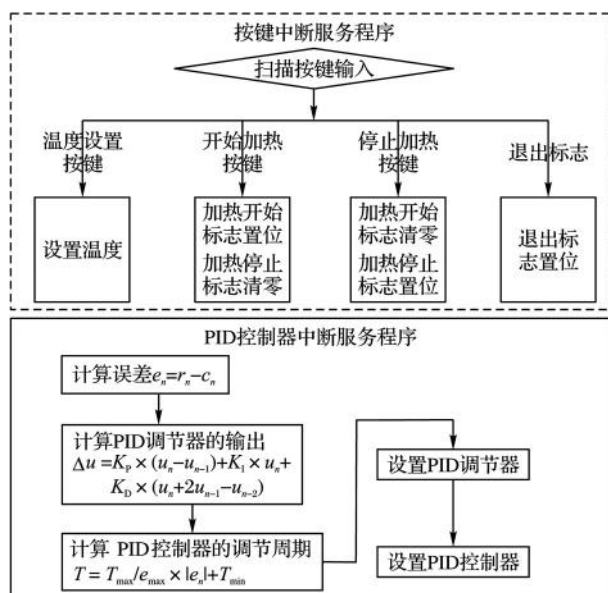


图6 软件中断程序流程




图7 温度—时间曲线

4 结语

本文研究了温度控制系统中响应时间和稳定性问题,改进了现有的温度控制策略,结合PID算法与参数整定的思想,提出了变调节周期的PID算法。结果表明,该算法克服了温度控制系统中响应滞后和稳定时间长的缺点,使系统温度在短时间内趋于稳定。实验表明在对温度调节过程中超调比例未超过2.2%,不会对操作人员造成危险。

参考文献:

- [1] 屈毅,宁铎,赖展翅,等. 温室温度控制系统的神经网络PID控制[J]. 农业工程学报,2011,27(2):307-311.
- [2] 殷华文. 程序控温算法研究[J]. 自动化仪表,2013,9(6):13-18.
- [3] 过润秋,解宝辉. 基于Fuzzy-PID的MOCVD温度控制方法[J]. 西安电子科技大学学报(自然科学版),2005,32(4):504-517.
- [4] 马占有,田俊忠,马泽玲. 温度控制系统模糊自适应PID控制器仿真研究[J]. 计算机仿真,2010,27(10):160-163.
- [5] 戴俊珂,姜海明,钟奇润,等. 基于自整定模糊PID算法的LD温度控制系统[J]. 红外与激光工程,2014,43(10):3287-3291.
- [6] 李建海. 数字PID控制器在温度控制系统中的应用[J]. 电子测量技术,2009,32(4):100-103.
- [7] 温显超,韩振宇. 基于温度控制系统的模糊自整定PID算法设计[J]. 铸造技术,2011,32(3):369-372.
- [8] SONG J L, CHENG W L, XU Z M, et al. Study on PID temperature control performance of a novel PTC material with room temperature Curie point[J]. International Journal of Heat and Mass Transfer, 2016,95(3):1038-1046.
- [9] 杨乐平. 一个基于变采样周期PID算法的实时控制软件[C]//1992年中国控制与决策学术年会论文集. 哈尔滨:中国自动化学会,1992:472-475.

(上接第102页)

4 结语

飞机平均故障间隔飞行时间作为一项重要的可靠性指标,根据其长期趋势和季节变化预测下一年度指标数值,对装备的维修保障具有重要意义。本文以加法模型研究MFHBF指标的影响因素,采用时间序列分解和组合预测方法对其进行预测。STL分解有效地去除了干扰因素,分解出长期趋势项和季节变动项,为组合预测提供基础;灰色预测发挥了小样本预测的优势,对指标趋势项的预测比较准确;BP神经网络和支持向量机回归组合预测比单一SVM模型预测更具有优势,最终的组合预测结果具有较好的精度,尤其是对前6个月的预测,精度较高,但是随着预测步长增加,精度也随之降低,长期预测的能力有待提高。另外,由于通过STL分解去除了不规则变动项,虽然降低了随机干扰但是容易丢失部分信息,因此预测精度受到一定影响。总体来说,基于时序分解的多模型组合预测方法达到了优化MFHBF指标预测精度的目的,可为飞机保障单位提供比较准确的数据支持。

参考文献:

- [1] 李瑞莹,康锐. 基于ARMA模型的故障率预测方法研究[J]. 系统工程与电子技术,2008,30(8):1588-1591.
- [2] 刘东君,邹志红. 灰色和神经网络组合模型在水质预测中的应用[J]. 系统工程,2011,29(9):105-109.
- [3] 赵建忠,徐廷学,葛先军,等. 基于小波变换和GM-ARMA的导弹备

件消耗预测[J]. 北京航空航天大学学报,2013,39(4):553-558.

- [4] 熊高峰,韩鹏,聂坤凯. 时间序列分解在短期电价分析与预测中的应用[J]. 电力系统及其自动化学报,2011,23(3):95-100.
- [5] 汪同三,张涛. 组合预测——理论、方法及应用[M]. 北京:社会科学文献出版社,2008.
- [6] 乔占俊. 基于Census X12-SARIMA模型的中长期负荷预测[J]. 电力系统及其自动化学报,2014,26(1):34-38.
- [7] 梁中耀,刘永,盛虎,等. 滇池水质时间序列变化趋势识别及特征分析[J]. 环境科学学报,2014,34(3):754-762.
- [8] 曾波,刘思峰,方志耕,等. 灰色组合预测模型及其应用[J]. 中国管理科学,2009,17(5):150-155.
- [9] 温胜强,周鹏飞,康海贵. 基于灰色理论与BP神经网络的交通运输组合预测研究[J]. 大连理工大学学报,2010,50(4):547-550.
- [10] KUNWAR P S, ANKITA B, AMRITA M, et al. Artificial neural network modeling of the river water quality — a case study[J]. Ecological Modelling, 2009, 220(6): 888-895.
- [11] 闻敬谦,李青,赵庆斌. 基于神经网络的维修保障流程影响度分析方法[J]. 北京航空航天大学学报,2011,37(6):690-694.
- [12] 傅贵,韩国强,逯峰,等. 基于支持向量机回归的短时交通流预测模型[J]. 华南理工大学学报(自然科学版),2013,41(9):71-76.
- [13] 周国雄,莫晓山. 基于灰色预测和BP的集气管压力集成预测方法[J]. 仪器仪表学报,2011,32(7):1648-1654.
- [14] 刘海燕,蒋泽军. 基于时间序列分析和ACO-LSSVM的故障预测技术研究[J]. 计算机与现代化,2013(5):219-226.