

基于神经网络技术的飞机舵面故障趋势预测研究

李 斌, 章卫国, 宁东方, 尹 伟

(西北工业大学 自动化学院, 西安 710072)



摘 要: 在飞机舵面故障诊断系统中, 及时准确的故障预报对提高飞机的安全性具有极其重要的意义, 针对飞机舵面故障预报系统的设计要求, 建立了神经网络故障预测模型以及训练算法, 该预测模型采用三层BP网络模型, 还对神经网络的预测精度给出了评价函数。最后, 为了验证所述方法的有效性, 结合风洞实验数据, 对某机舵面故障模式之一的方向舵卡死进行了预测和分析, 并与传统的ARMA方法进行了比较, 结果充分表明了该神经网络预测模型的有效性和优越性。

关键词: 神经网络; 故障预测; 故障诊断; 飞机舵面

中图分类号: TP206.3

文献标识码: A

文章编号: 1004-731X (2008) 21-5840-03

Fault Prediction System of Airplane Steering surface
Based on Neural Network Model

LIBin, ZHANG Wei-guo, NING Dong-fang, YIN Wei

(College of Automation Northwestern Polytechnical University, Xi'an 710072, China)

Abstract In the airplane steering surface fault diagnosis system, timely and accurate forecast of failure is of great significance to improve the safety of the airplane. According to the design requirements of the airplane steering surface fault forecast system, the neural network fault forecast model and training algorithm were established. The three-tier model BP network model was applied in the fault forecast model. The evaluation function of the forecast accuracy was proposed. Finally, in order to validate the effectiveness of the method described, combining with the wind tunnel test data, forecast and analysis upon a kind of airplane steering surface failure mode of rudder block were done. Compared to the traditional method of ARMA, the result shows that the neural network model is of effectiveness and superiority.

Key words: neural network; fault forecast; fault detection and diagnosis; airplane steering surface

引 言

随着现代工业及科学技术的迅速发展, 系统日趋大型化、自动化和智能化, 一旦发生故障, 将产生难以估计的损失, 为了避免产生很大的损失, 产生了故障诊断这门学科^[1,2], 但是它们都是在故障发生以后判断故障产生的原因, 继而对故障进行修复, 可在实际情况中总是希望能在故障发生之前就预测到它的存在, 采取措施避免故障的发生, 我们把它称之为故障预测^[3-5]。在一些复杂系统的结构分析中, 故障预测技术研究是个相当复杂的问题。

传统的故障预测方法是ARMA模型法, 它要求时间序列是平稳的, 且服从正态分布, 但是对于本文所研究的飞机舵面系统, 由于其本身具有很多非线性因素, 特别是舵面出现故障时, 飞机的飞行状态将产生很大的变化, 故障程度将发展的很快, 因此所表现出来的舵面线位移传感器信号也将出现非线性的变化, 因此在这种情况下, 传统的ARMA模型将不能有效, 所以有必要寻找其他的预测方法。根据神经网络^[6]技术具有大规模并行模拟处理、连续时间动力学和网络全局作用等特点, 并且有很强的泛化能力, 因此该技术进行非线性预测具有很大的潜力。文献[5]将神经网络预测方法

应用于航空发动机状态监控中滑油铁金属含量预测, 提高了其预测精度。

本文在文献[5]的基础上提出了基于BP神经网络舵面故障预测方法, 并对其进行了改进, 在多层前向过程神经网络的基础上增加了输入层与输出层的直接全互连接, 提高了网络收敛速度和精度。将该方法应用于飞机舵面故障预测中, 并根据风洞试验数据对神经网络预测算法和故障预测模型进行了仿真验证, 取得了满意的效果。

1 BP网络故障预测方法

应用传统方法进行时间序列预测在本质上就是根据时间序列 $\{X_n\}$ 的历史观测数据 X_m, X_{m-1}, \dots , 对 X_{m+h} ($h > 0$) 进行估计, 也就是认为 X_{m+h} 与其前面的数据 X_m, X_{m-1}, \dots 之间存在某种函数映射关系, 可用下式表示:

$$X_{m+h} = F(X_m, X_{m-1}, \dots) \quad (1)$$

此时, 时间序列预测问题就转化为对函数 $F(\cdot)$ 的逼近问题。当 $h=1$ 时称为单步预测, 当 $h>1$ 时称为多步预测。显然, 应用传统方法对 X_{m+h} 进行预测时, X_{m-1}, X_{m-2}, \dots 对 X_m 的影响难以表达, 即难以表达时间序列中实际存在的时间累积效应, 这必然会影响到预测精度。

将观测数据 X_m, X_{m-1}, \dots, X_1 进行函数拟合, 产生一个时变函数 $X_m(t)$ 。可以认为时间序列在 $m+1$ 时刻的取值 X_{m+1} 与函数 $X_m(t)$ 之间存在某种泛函映射关系, 可用下式描述:

收稿日期: 2007-05-21

修回日期: 2007-07-25

作者简介: 李斌(1980-), 男, 博士生, 研究方向为智能控制与故障诊断研究; 章卫国(1956-), 男, 教授, 博导, 研究方向为智能控制与飞行控制方法与应用。

$$X_{m+1} = F[X_m(t)] \quad (2)$$

此时, 时间序列预测问题就转为对泛函 $F[\cdot]$ 的逼近问题。Kolmogorov 定理^[7]已经证明: 一个三层或以上的 BP (Back Propagation) 神经网络可以以任意精度逼近任何非线性连续函数, 这为神经网络进行时间序列描述提供了数学上的保证。因此, 将 $X_m(t)$ 作为神经网络的输入, 可以把时间序列预测问题转化为神经网络对泛函 $F[\cdot]$ 的逼近问题。

1.1 BP 网络预测模型

BP (Back Propagation) 神经网络是目前应用最广泛的一种人工神经网络, 它是一种基于误差反向传播算法 (BP 算法) 的多层前馈神经网络, 由输入层、隐层和输出层等不同层次的神经元组成, 每一层神经元的输出经连接权值加权求和作为下一层神经元的输入, 层与层之间没有反馈。

本文采用的 BP 网络预测模型由 1 个输入层、 i 个隐层和一个输出层组成, 神经元的激励函数为 'Sigmoid', BP 网络时间序列预测模型如图 1 所示。




图1 BP 网络时间序列预测模型

其中, ω_{1i} 为 BP 网络输入层的神经元对隐层 i 个神经元的连接权值, V_{i1} 为第 i 个隐层神经元对输出层神经元的连接权值。由图 1 可以推出基于神经网络的时间序列预测模型对 X_{m+1} 的预测为:

$$y = \sum_{i=1}^n v_{i1} f \left(\int_0^T \omega_{1i}(t) x_m(t) dt - \theta_i \right) + \int_0^T u(t) x_m(t) dt - \theta \quad (3)$$

其中, θ_i 是隐层第 i 个神经元的阈值, $[0, T]$ 为采样区间, 在实际的飞机舵面系统中, $X_m(t)$, $\omega_{1i}(t)$ 均为 $L^p[0, T]$ 空间上的函数。由 Weierstrass 逼近定理在 $L^p[0, T]$ 空间上的推广^[8-10]可知, 对 $\forall \xi > 0$, 必存在多项式 $A_k(t)$, 使 $|A_k(t) - x_i(t)| < \xi$ 。即 $x_i(t)$ 可由 $C[0, T]$ 空间上的多项式函数系 $A_k(t)$ ($k=1, 2, \dots, K$) 以任意精度逼近, 从而 $X_m(t)$ 可表示为: $x_m(t) = \sum_{k=1}^K C_k A_k(t) \sqrt{a^2 + b^2}$,

$C_k \in \mathbb{R}$, 且多项式函数系 $A_k(t)$ 在 $C[0, T]$ 空间上是相互独立的, 则通过 Gram-Schmidt 正交化可以得到在 $C[0, T]$ 空间上的一组正交基函数 $B_k(t)$, 且 $X_m(t)$, $\omega_{1i}(t)$, $u(t)$ 可分别表示为:

$$x_m(t) = \sum_{k=1}^K x_{mk} B_k(t), \quad \omega_{1i}(t) = \sum_{k=1}^K \omega_{ki} B_k(t), \quad u(t) = \sum_{k=1}^K \omega_k B_k(t),$$

其中 $x_{mk}, \omega_{ki}, \omega_k$ 都 $\in \mathbb{R}$ 为展开式系数, 根据正交函数的性质有: $\int_0^T B_k(t) B_l(t) dt = \begin{cases} 1, & k=l \\ 0, & k \neq l \end{cases}$ 所以 (3) 式可以简化为:

$$y = \sum_{i=1}^n v_{i1} f \left(\sum_{k=1}^K \omega_{ki} x_k - \theta_i \right) + \sum_{k=1}^K u(k) x_k - \theta \quad (4)$$

1.2 神经网络的学习算法

给定 L 组学习样本 $\{x_l(t), d_l(t)\}, l=1, 2, \dots, L$, $d_l(t)$ 为对应学习样本 $x_l(t)$ 的网络期望输出, 设 $y_l(t)$ 为相应的网络实际输出, 将 $d_l(t)$ 展开为 $d_l(t) = \sum_{k=1}^K d_{kl} b_k(t)$, $y_{kl} = \sum_{i=1}^n v_{il}$, $f \left(\sum_{k=1}^K \omega_{ki} x_k - \theta_i \right) + \sum_{k=1}^K u(k) x_k - \theta_k$, 则网络模型的误差函数可定义为:

$$E = \frac{1}{2} \sum_{l=1}^L \sum_{k=1}^K (y_{kl} - d_{kl})^2 = \frac{1}{2} \sum_{l=1}^L \sum_{k=1}^K \sum_{i=1}^n v_{il} f \left(\sum_{k=1}^K \omega_{ki} x_k - \theta_i \right) + \sum_{k=1}^K u(k) x_k - \theta_k - d_{kl})^2 \quad (5)$$

根据最速梯度下降法, 网络模型的待训练参数调整规则为:

$$\begin{aligned} v_{ik}(s+1) &= v_{ik}(s) + \alpha \Delta v_{ik}(s), \\ \omega_k(s+1) &= \omega_k(s) + \beta \Delta \omega_k(s), \\ \theta_i(s+1) &= \theta_i(s) + \gamma \Delta \theta_i(s), \\ \theta_k(s+1) &= \theta_k(s) + \lambda \Delta \theta_k(s) \end{aligned} \quad (6)$$

其中: $\alpha, \beta, \gamma, \lambda$ 为学习速率; s 为学习迭代次数。

在每一次学习迭代中, $\Delta v_{il}, \Delta \omega_{ik}, \Delta \theta_i, \Delta \theta_k$ 可分别表示为:

$$\begin{aligned} \Delta v_{ik} &= -\frac{\partial E}{\partial v_{ik}} = -\sum_{l=1}^L \sum_{k=1}^K (y_{kl} - d_{kl}) f \left(\sum_{k=1}^K \omega_{ki} x_k - \theta_i \right) \\ \Delta \omega_{ki} &= -\frac{\partial E}{\partial \omega_{ki}} = -\sum_{l=1}^L \sum_{k=1}^K (y_{kl} - d_{kl}) v_{ik} f' \left(\sum_{k=1}^K \omega_{ki} x_k - \theta_i \right) \\ \Delta \theta_i &= -\frac{\partial E}{\partial \theta_i} = \sum_{l=1}^L \sum_{k=1}^K (y_{kl} - d_{kl}) v_{ik} f' \left(\sum_{k=1}^K \omega_{ki} x_k - \theta_i \right) \\ \Delta \theta_k &= -\frac{\partial E}{\partial \theta_k} = \sum_{l=1}^L \sum_{k=1}^K (y_{kl} - d_{kl}) \end{aligned} \quad (7)$$

学习过程可完整描述如下:

步骤 1 选取合适的正交基函数将网络模型的输入函数和连接权函数同时展开。

步骤 2 给定学习误差精度 ε ; 学习迭代次数 $s=0$, 最大学习迭代次数 M 和学习速率。

步骤 3 网络模型待训练参数的初始化。

步骤 4 根据式 (5) 计算误差函数 E , 如果 $E < \varepsilon$ 或 $s > M$, 则转至步骤 6, 否则转至步骤 5。

步骤 5 根据式 (6), (7) 的规则调整待训练参数, $s+1 \rightarrow s$ 转至步骤 4。

步骤 6 输出学习结果, 学习结束。

1.3 神经网络预测精度评价函数

在实际应用中, 对于实际测量的样本序列 $\{x_1, x_2, \dots\}$, 可以利用其一部分数据 (通常为前半) 来建模, 而用后一部分数据来对所建模型进行验证和预测, 预测值与实测值相差越小, 则预测模型越理想, 通常衡量预测值与实际值差别的评价函数采用平均相对变动值 (Average relative variance: ARV), 其定义为:

$$ARV = \frac{\sum_{i=1}^N [x(i) - \hat{x}(i)]^2}{\sum_{i=1}^N [x(i) - \bar{x}]^2} \quad (8)$$

其中 N 为样本数据个数, $x(i)$ 为实际测量值, $\hat{x}(i)$ 为实际测

量数据平均值, $\hat{x}(i)$ 为预测值, 可见平均相对变动值越小, 也表明预测效果越好, 当 $ARV=0$ 时表示达到了理想的预测效果, 当 $ARV=1$ 时, 表明模型仅达到平均值的预测效果。

为了分析神经网络的泛化能力, 设训练点数为 N_1 , 测试点数 N_2 , 根据 ARV 的定义, 再定义三个函数, 即综合 ARV 值 ARV_1 , 训练 ARV 值 ARV_2 , 预测 ARV 值 ARV_3 。

$$ARV_1 = \frac{\sum_{i=1}^{N_1+N_2} [x(i) - \hat{x}(i)]^2}{\sum_{i=1}^{N_1+N_2} [x(i) - \bar{x}]^2}; \quad ARV_2 = \frac{\sum_{i=1}^{N_1} [x(i) - \hat{x}(i)]^2}{\sum_{i=1}^{N_1} [x(i) - \bar{x}]^2};$$

$$ARV_3 = \frac{\sum_{i=1}^{N_2} [x(i) - \hat{x}(i)]^2}{\sum_{i=1}^{N_2} [x(i) - \bar{x}]^2};$$

显然, ARV_1 综合反映了网络对训练点和预测点的拟合程度; ARV_2 仅反映了网络对训练点的拟合程度; ARV_3 仅反映了网络对预测点的拟合程度。

1.4 基于 BP 网络的故障预测方法

根据前面分析的预测模型和训练算法, 基于 BP 神经网络的故障预测步骤^[11,12]分两步:

步骤 1 建立基于 BP 神经网络的时间序列预测模型。即以系统的历史运行数据构造神经网络预测模型的训练样本 (x_{k+1}, y) , 其中: $y = \sum_{i=1}^n v_{ii} f(\sum_{k=1}^K \omega_{ki} x_k - \theta_i) + \sum_{k=1}^K u(k) x_k - \theta$, 表示用前 k 个时间序列历史数据预测 $k+1$ 时刻的状态, 用所得样本训练 BP 神经网络, 从而得到基于 BP 神经网络的预测模型。

步骤 2 利用步骤 1 所得的预测模型进行故障预报, 选择残差 (实际值与预测值之差) 的平均相对误差 σ_i , ($\sigma_i = \frac{1}{n} \sum_{i=1}^N \frac{x(i) - \hat{x}(i)}{x(i)}$, 其中 N 为测量数据个数, $x(i)$ 为实测数据, $\hat{x}(i)$ 为预测值。), 作为判断系统是否发生故障的依据, 将其与故障报警控制限 σ_0 (σ_0 根据经验确定) 进行比较, 若 $\sigma_i < \sigma_0$ 认为系统正常; 若 $\sigma_i > \sigma_0$ 则认为系统存在故障趋势。

2 实例分析

基于神经网络预测模型的飞机舵面故障预测系统结构如图 2 所示。根据飞机舵面故障数据的具体特点, 由神经网络预测模块对历史数据作出预测, 并把数值预测得到的残差的平均相对误差结果与经验产生的残差的平均相对误差报警控制限比较, 形成诊断事件; 由诊断系统对预测值作出诊断, 从而得到检测点的故障趋势。




图 2 舵面故障趋势预测流程图

为了验证本文方法的有效性, 采用上述的神经网络模型, 对某飞机在风洞试验时的舵面信号进行故障预测。其中, 训练样本使用风洞实验得到的某时刻飞机方向舵卡死时的非线性、分段气动数据, 利用这些数据对上述 BP 网络进行训练, 每 6 个数据组成一个样本, 其前 5 个值作为输入数据, 后 1 个值是期望输出, 这样就一共得到 150 个样本, 用前 100 组样本构成训练样本用于建立神经网络预测模型, 用后 50 组样本构成检测样本用于故障趋势预测, BP 网络结构选取 1-9-1, 网络误差精度设定为 10^{-3} , 学习速率为 0.01, 最大迭代次数 2000 次, 网络经 127 次学习迭代后收敛, 为验证神经网络泛化能力, 用后 50 组非学习样本进行舵面趋势预测, 经过 MATLAB6.5 仿真得到舵面信号预测结果如图 3 所示, 由仿真结果可知, 测量的平均相对误差为 0.30%, 表明了神经网络预测满足实际舵面故障预测的要求, 能够达到飞机舵面趋势预测的目的。




图 3 基于神经网络的方向舵卡死时的预测结果

为了与传统 ARMA 模型进行比较, 采用穷举法得到最佳的 ARMA 预测模型为 ARMA (27, 8), 用相同的数据建模和验证后, 得到的实测值与预测值的比较如图 4 所示, 以均方误差以及平均相对变动值作为评价预测精度的指标, 对 2 种模型的预测性能进行比较如表 1, 从该表可以看出, BP 网络的 2 个误差指标值均比 ARMA 方法的小, 因此 BP 网络的预测精度比传统的 ARMA 要高。神经网络预测模型得到了更佳的预测效果。




图 4 基于 ARMA 模型的方向舵卡死时的预测结果

表 1 两种预测方法的性能比较

预测性能指标	BP 预测算法	ARMA 方法
ARV	0.0029	0.075
均方误差	0.00026	0.0676

根据采样的前 100 组故障样本和前述的训练算法对神经网络进行训练, 利用训练后的网络对后 50 组采样数据对飞机方向舵卡死故障进行趋势预测, 根据经验选择飞机舵面

(下转第 5847 页)

- [3] Deb K, Pratap A, Agarwal S. A Fast and Elitist Multiobjective genetic algorithm NSG-II [J]. IEEE Transaction on Evolutionary Computation (S1089-778X), 2002, 6(2): 82-197.
- [4] Zitzler E, Deb K, Thiele L. Comparison of Multiobjective Evolutionary Algorithms [J]. IEEE Transaction on Evolutionary Computation (S1089-778X), 2000, 8(2): 173-195.
- [5] Everson J E, Fieldsend J E, Singh S. Using Unconstrained Elite Archives for Multi-Objective Optimization [J]. IEEE Transaction on Evolutionary Computation (S1089-778X), 2003, 7(3): 305-323.
- [6] 陈华平, 谷峰, 卢冰原. 自适应多目标遗传算法在柔性工作车间调度中的应用[J]. 系统仿真学报, 2006, 18(8): 2271-2274. (Chen H P, Gu F, Lu B Y. Application of Self-adaptive Multi-objective Genetic Algorithm in Flexible Job Shop Scheduling [J]. Journal of System Simulation (S1004-731X), 2006, 18(8): 2271-2274.)
- [7] 马清亮, 胡昌华, 杨青. 一种用于多目标优化的混合遗传算法[J]. 系统仿真学报, 2004, 16(5): 1038-1040. (Ma Q L, Hu C H, Yang Q. Hybrid Genetic Algorithm for Multi-objective Optimization [J]. Journal of System Simulation (S1004-731X), 2004, 16(5): 1038-1040.)
- [8] 汪祖柱, 程家兴. 一种混合交叉策略的多目标演化算法及其性能分析[J]. 系统仿真学报, 2004, 17(10): 2383-2387. (Wang Z Z, Cheng J X. Multi-objective Evolutionary Algorithm Based on Double Crossover and Its Performances Analysis [J]. Journal of System Simulation (S1004-731X), 2004, 17(10): 2383-2387.)
- [9] 姚钦, 史仪凯, 夏锐. 多目标交互式遗传算法在测试点确定问题中的应用[J]. 系统仿真学报, 2007, 18(6): 1469-1472. (Yao Q, Shi Y K, Xia R. Application of multi-objective interaction genetic algorithm in determining test points problem [J]. Journal of System Simulation (S1004-731X), 2007, 18(6): 1469-1472.)
- [10] 张永, 吴晓蓓, 向峥嵘, 等. 基于多目标进化算法的高维模糊分类系统的设计[J]. 系统仿真学报, 2007, 19(1): 210-215. (Zhang Y, Wu X B, Xiang Z R, etc. Design of High-dimensional Fuzzy Classification Systems Based on Multi-objective Evolutionary Algorithm [J]. Journal of System Simulation (S1004-731X), 2007, 19(1): 210-215.)
- [11] 金欣磊, 马龙华, 刘波, 等. 基于动态交换策略的快速多目标粒子群优化算法研究[J]. 电路与系统学报, 2007, 12(2): 78-82.
- [12] 李宁, 邹彤, 孙德宝. 基于粒子群的多目标优化算法[J]. 计算机工程与应用, 2005, 23: 43-46.
- [13] Coello C A C, Pulido G T, Lechuga M S. Handling Multiple Objectives with Particle Swarm Optimization [J]. IEEE Transactions on Evolutionary Computation (S1089-778X), 2004, 8(3): 256-279.
- [14] Gies D, Samii Y R. Vector Evaluated Particle Swarm Optimization (VEPSO): Optimization of a Radiometer Array Antenna. [J]. Antennas and Propagation Society Symposium (S7803-8883), 2004, 3(20): 2297-2300.
- [15] 孙小强, 张求明. 一种基于粒子群优化的多目标优化算法[J]. 计算机工程与应用, 2006, 18: 40-42.
- [16] Mostaghim S, Teich J. Strategies for finding good local guides in multi-objective particle swarm optimization (MOPSO) [C]// IEEE 2003 Swarm Intelligence Symposium. USA: IEEE, 2003: 26-33.
- [17] 徐佳, 李绍军, 王惠. 基于最大最小适应度函数的多目标粒子群算法[J]. 计算机与数字工程, 2006, 34(8): 31-34.
- [18] Zitzler E, Laumanns M. Test Problems and Test Data for Multiobjective Optimizers [EB/OL]. (2008-6-30) [2006-12-10]. <http://www.tik.ee.ethz.ch/~zitzler/testdata.html>

(上接第5842页)

卡死时的故障报警控制限 $\sigma_0 = 3.2 \times 10^{-4}$, 由仿真结果得到的BP网络预测的平均相对误差值 $0.30\% > 3.2 \times 10^{-4}$, 超出了控制限, 满足预警条件, 说明该舵面存在卡死故障趋势, 从而证明了本方法的有效性。

3 结论

故障预测是预知维修的重要内容之一, 本文提出的基于神经网络技术的飞机舵面故障趋势预测方法, 能够实现对飞机作动器损伤的有效预测. 以某机舵面故障中的方向舵卡死为例对神经网络预测方法进行仿真验证, 并与传统的ARMA方法进行比较, 仿真和比较结果均表明, 神经网络预测效果较好, 预报结果的平均相对变动值为0.0029, 能够满足实际预测精度要求, 该方法提高了对飞机舵面运行故障的预知维修性, 保证了飞机的飞行安全。

参考文献:

- [1] 王江萍. 基于神经网络的信息融合诊断技术[J]. 机械科学与技术, 2002, 21: 127-128.
- [2] 肖本贤, 娄天玲, 郭福权, 等. 基于模糊神经网络的车用发电机故障诊断系统的研究[J]. 系统仿真学报, 2004, 16(5): 1001-1004.
- [3] 张怡哲, 邓建华. 舵面损伤在线故障模式预测及故障检测[J]. 西

北工业大学学报, 2003, 21: 299-300.

- [4] 曹立军, 马吉胜, 秦俊奇, 等. 基于正反向混合推理的故障仿真预测模型[J]. 系统仿真学报, 2006, 18(3): 742-746.
- [5] 程惠涛, 黄文虎, 姜兴渭, 等. 基于神经网络模型的故障预报技术研究[J]. 哈尔滨工业大学学报, 2001, 33: 162-163.
- [6] Doraiswami R, Stevenson M. A robust influence matrix approach to fault diagnosis [J]. IEEE Trans. Control Systems Technology (S1063-6536), 2005, 4(1): 29-39.
- [7] 丁刚, 钟诗胜. 基于过程神经网络的时间序列预测及其应用研究[J]. 控制与决策, 2006, 21: 1038-1039.
- [8] Zhang Q, Basseville M, Benveniste A. Fault detection and isolation in nonlinear dynamic systems: a combined input-output and local approach [J]. Automatic (S0254-4156), 2003, 34(11): 1359-1373.
- [9] Ganyun L V, Haozhong C, Haibao Z, Lixin D. Fault diagnosis of power transformer based on multi-layer SVM classifier [J]. Electric Power System Research (S0378-7796), 2005, 74(1): 5-6.
- [10] Frank P M. Fault diagnosis in dynamic systems using analytical and knowledge-based redundancy-A survey and some new results [J]. Automatic (S0254-4156), 2005, 26(3): 459-474.
- [11] 王源, 胡寿松. 基于支持向量机的非线性系统故障诊断[J]. 控制与决策, 2001, 16(5): 617-620.
- [12] 权太范. 信息融合神经网络-模糊推理理论与应用[M]. 北京: 国防工业出版社, 2002: 270-271.