

基于粗糙神经网络的 航空电子设备故障预测研究

文莹, 肖明清, 胡雷刚, 方甲永

(空军工程大学 自动测试系统实验室, 陕西 西安 710038)

摘要: 为降低装备全寿命周期费用、提高经济可承受性、预防灾难性事故的发生, 开展了航空电子设备故障预测技术研究; 采用粗糙集理论改进神经元结构, 以粗糙变量为神经元的输入, 每个神经元的上近似元和下近似元分别代表粗糙集的上下近似, 以交叉连接方式构造粗糙神经网络, 用以实际设备特征参数的跟踪预测; 研究表明, 粗糙神经网络可以较准确地预测故障发生的时间, 且较 BP 神经网络预测性能有较大改善; 该方法对于航空电子设备的维护保障具有一定的理论价值和现实意义。

关键词: 粗糙集; 粗糙神经网络; 故障预测

Research of Avionics Prognostics Based on Rough Neural Network

Wen Ying, Xiao Mingqing, Hu Leigang, Fang Jiayong

(Automatic Test System Lab., Air Force Engineering Univ., Xi'an 710038, China)

Abstract: In order to cut down the equipment life cycle cost, improve affordability and prevent serious accident, the research of avionics prognostics is carried out. The structure of neurons was ameliorated with the Rough Set Theory, and the Rough Neural Network (RNN) was got to track the degenerate trend of the characteristics parameters of practical equipment. The result of research shows that Rough Neural Network can forecast the fault in high veracity, and have a better predicting performance than BP neural network. This prognostics method contributes to the level of the avionics maintenance both in theory and activity.

Key words: rough set; rough neural network; prognostics

0 引言

随着武器系统性能的不断提升以及复杂性的不断增长, 系统的可靠性、故障诊断与预测以及维修保障等问题越来越受到重视。支持视情维修的故障预测最早是从美国军方发展起来的装备保障技术, 主要目的是提高武器系统的可靠性、降低装备的维修和保障费用^[1-2]。装备的故障预测就是在装备的使用过程中, 利用其历史数据、设备的当前信息以及当前的环境条件, 准确及时判断其运行状态并预测其运行状态的发展趋势, 为准备的使用和维护提供决策性依据^[3-4]。

粗糙集 (RS, Rough Set) 是一种关于数据分析和推理的理论, 擅于处理不精确、不完全信息, 但其只能处理离散数据, 得出定性的结论, 容错性与推广能力也较弱; 而神经网络具有可学习性和并行计算能力, 可以实现联想记忆、自组织聚类和非线性映射等功能。与粗糙集相比, 神经网络能够处理数值化信息, 得到更加精细的结果, 但不能优选数据。本文将粗糙集和神经网络有机结合, 构建粗糙神经网络 (rough neural network, RNN), 针对某型航空电子设备开展故障预测研究。

1 粗糙集理论简介

粗糙集理论是一种新型的处理模糊和不确定知识的数学工具, 是由波兰数学家 Pawlak Z. 院士于 1982 年首次提出, 在数据挖掘、决策分析、模式识别、故障检测等方面得到了较为成功的应用。粗糙集理论认为知识是有粒度的, 正是由于知识的粒度造成了使用已有知识不能精确表示某些概念, 从而形成了知识的不确定性。其基本思想就是应用一个等价关系把一个不确定的集合用两个确定的集合表示^[5]。

设 U 是对象集; $X_i (i \leq k)$ 为 U 的子集, 且 $X_i \neq \emptyset (i \leq k)$, $X_i \cap X_j = \emptyset (i \neq j)$, $\bigcup_{i=1}^k X_i = U$, 即 $\{X_i | i \leq k\}$ 为 U 的划分; R 是 U 上的等价关系。等价关系可以将对象集分类。从认知的角度来看, 人们需要通过分类去认识那些不能用精确分类表示的对象集, 这种集合称为粗糙集。粗糙集可以使用上近似集、下近似集和边界来近似地定义^[6]:

(1) 称 (U, R) 为近似空间, 由 (U, R) 产生的等价类为 $U/R = \{[x_i]_R | x_i \in U\}$, 其中 $[x_i]_R = \{x_j | (x_i, x_j) \in R\}$ 。

(2) 对于任意 $X \subseteq U$, 记 $B(X) = \{x_i | [x_i]_R \subseteq X\}$, $B(X) = \{x_i | [x_i]_R \cap X \neq \emptyset\}$, 称 $B(X)$ 为 X 的下近似, $B(X)$ 为 X 的上近似。

(3) 若 $B(X) = \overline{B(X)}$, 称 X 为可定义的集合, 否则称 X 为粗糙集。

(4) 对于 $X \subseteq U$, 称 $BN(X) = \overline{B(X)} - B(X)$ 为 X 的边界。

2 粗糙集改进神经元结构

粗糙集与神经网络的连接方法和作用形式可分为三类: 用粗糙集预处理神经网络的学习样本集^[7], 称为串联型; 粗糙集

收稿日期: 2009-11-04; 修回日期: 2009-12-02。

基金项目: “十一五”国防预研项目 (51317030105)。

作者简介: 文莹 (1987-), 男, 湖南永州人, 硕士研究生, 主要从事故障预测、寿命预测等研究。

肖明清 (1963-), 男, 湖南常德人, 教授, 博士生导师, 主要从事航空武器综合保障研究。

简约神经网络隐含层单元数目^[8], 称为混合型; 利用粗糙集改进神经元结构属于更高层次的结合^[9], 称为融合型。

本文采用融合型。每个神经元由上近似元和下近似元组成, 分别代表粗糙集的上下近似。定义一个粗糙变量输入值 x 满足 $x^- < x < x^+$, 其中 x^- 表示粗糙集的下近似元, x^+ 表示粗糙集的上近似元, 则粗糙神经元输入值的网络结构如图 1 所示。




图 1 粗糙神经元的输入网络结构

对于两个不同的粗糙神经元 R 和 S , 它们之间常见的连接方式有三种, 如图 2 所示。




图 2 粗糙神经元之间连接方式

本文选用第三种连接方式, 则神经元 S 的输入、输出可定义为^[10]:

粗糙神经元的输入:

$$Input_{s^-} = \sum_i (w_{R_i^-} \times Output_{R_i^-} + w_{R_i^+} \times Output_{R_i^+}) \quad (1)$$

$$Input_{s_+} = \sum_i (w_{R_i^-} \times Output_{R_i^-} + w_{R_i^+} \times Output_{R_i^+}) \quad (2)$$

粗糙神经元的输出:

$$Output_{s^-} = \max\{f^-(Input_{s^-} - \theta_{s^-}), f_-(Input_{s_+} - \theta_{s_+})\} \quad (3)$$

$$Output_{s_+} = \min\{f^-(Input_{s^-} - \theta_{s^-}), f_-(Input_{s_+} - \theta_{s_+})\} \quad (4)$$

式中, w 为两层神经元之间的连接权重, θ 为神经元阈值函数, f^- 、 f_- 为两层神经元的传递函数。

3 粗糙神经网络

若粗糙神经网络共 L 层, 输入信号为 $X = \{x_1, x_2, \dots, x_k\}^T$, 输出信号为 $Y = \{y_1, y_2, \dots, y_m\}^T$; 粗糙神经元 i 和 j 之间的连接权值为 w_{ij} ; 训练集为 $\{(X_1, Y_1), \dots, (X_p, Y_p), \dots, (X_N, Y_N)\}$, 其中 $X_p = (X_{p^-}, X_{p_+})$, $Y_p = (Y_{p^-}, Y_{p_+})$, N 为训练样本个数, p 为当前输入样本。

定义粗糙神经网络的第 j 个粗糙神经元的误差传递函数为:

$$E_p = \frac{1}{2} \sum_j (Y_{jp} - \bar{Y}_{jp})^2 = \frac{1}{2} \sum_j [K(Y_{jp} - \bar{Y}_{jp}) - K(Y_{jp_+} - \bar{Y}_{jp_+})]^2 \quad (5)$$

式中, Y_{jp} 、 Y_{jp_+} 分别表示粗糙神经元上下两层的理想输出, \bar{Y}_{jp} 、 \bar{Y}_{jp_+} 分别表示粗糙神经元上下两层的实际输出, K 为

粗糙神经元上下两层的加权系数, 若设:

$$O_{jp} = Y_{jp} - Y_{jp_+}, \bar{O}_{jp} = \bar{Y}_{jp} - \bar{Y}_{jp_+} \quad (6)$$

则有:

$$E_p = \frac{1}{2} K^2 \sum_j (O_{jp} - \bar{O}_{jp})^2 \quad (7)$$

综上, 可知对于一个多输入、单输出的粗糙神经网络其典型结构如图 3 所示。




图 3 粗糙神经网络结构

4 基于粗糙神经网络的故障预测

基于粗糙神经网络的故障预测原理是: 已知截止当前时刻的设备状态历史监测数据信息, 预测下一时刻或未来一段时间内设备状态趋势变化, 同时根据其状态趋势预计设备发生故障的时间。选用平均绝对误差 e_{MAE} 、均方误差 e_{MSE} 、平均绝对误差百分比 e_{MAPE} 、均方误差百分比 e_{MSPE} 和 Pearson 相关系数 e_{PR} 等指标对预测效果进行综合评价。

某型航空电子设备的故障趋势体现为某参数的递增性变化, 通过寿命试验, 获得了全寿命故障规律数据。跟踪该型设备实际工作环境中的使用状况, 监测到三套设备的实际特征参数随累积工作时间变化数据, 如表 1 所示。

表 1 正常应力下累积工作时间数据

参数值	1.00	1.01	1.02	1.03	1.04	1.05	1.06	1.08	1.10	1.12	1.14	1.16	1.18	1.20
寿命试验	0	586	923	1043	1167	1344	1427	1469	1591	1698	1848	1869	1957	2026
设备 1	0	576	852	1144	1228	1275	1514	1595	1691	1788	1891	1994	2048	2092
设备 2	0	570	882	1110	1157	1299	1312	1531	1554	1752	1876	2009	2117	2124
设备 3	0	585	865	1115	1279	1296	1474	1665	1787	1801	1877	1868	1971	2074

注: 数据已经过脱密处理, 时间单位为小时。

设特征参数从正常 (1.00) 到故障 (1.20) 的各标定值为 y_i , $i = 1, 2, \dots, 14$, 各标定值对应的累积工作时间为 t_i 。设计粗糙神经网络为三层网络、四变量输入、两步预测, 即以 t_{i-3}, \dots, t_i 为输入参数, 以 t_{i+1}, t_{i+2} 为输出参数。分别选用不同隐含层单元数, 采用全寿命故障规律数据训练网络, 将已训练好的神经网络针对设备 1 进行预测, 得到的效果指标如表 2 所示。

表 2 不同隐单元数时预测结果分析

隐单元	一步预测					两步预测				
	e_{MAE}	e_{MSE}	e_{MAPE}	e_{MSPE}	e_{PR}	e_{MAE}	e_{MSE}	e_{MAPE}	e_{MSPE}	e_{PR}
7	58.70	22.48	0.0356	0.0142	0.9994	59.47	21.00	0.3490	0.0127	0.9997
8	48.04	20.11	0.0298	0.0132	0.9995	56.89	22.36	0.0333	0.0136	0.9997
9	47.96	18.89	0.0276	0.0110	0.9997	63.90	23.51	0.0377	0.0144	0.9996
10	54.64	20.29	0.0334	0.0128	0.9995	61.07	21.74	0.0351	0.0128	0.9998

比较分析, 隐含层单元数为 9 的网络结构具有较好的性能。以该网络结构对设备 1 实际数据进行预测检验, 得到粗糙神经网络预测值如表 3, 与 BP 神经网络预测各项误差指标比较如表 4, 两者预测结果和误差百分比曲线如图 4、图 5 所示。

表 3 粗糙神经网络一步和两步预测值										
参数值	1. 04	1. 05	1. 06	1. 08	1. 10	1. 12	1. 14	1. 16	1. 18	1. 20
一步预测	1254	1274	1394	1651	1649	1752	1881	1942	1998	
两步预测		1353	1557	1697	1718	1827	1944	1999	2051	2083
实际监测	1228	1275	1514	1595	1691	1788	1891	1994	2048	2092

表 4 粗糙神经网络与 BP 神经网络预测结果比较										
网络	一步预测					两步预测				
	$eMAE$	$eMSE$	$eMAPE$	$eMSPE$	ePR	$eMAE$	$eMSE$	$eMAPE$	$eMSPE$	ePR
RNN	47.96	18.89	0.0276	0.0110	0.9997	63.90	23.51	0.0377	0.0144	0.9996
BP 网络	57.18	21.27	0.0319	0.0132	0.9994	64.32	24.25	0.0389	0.0154	0.9995

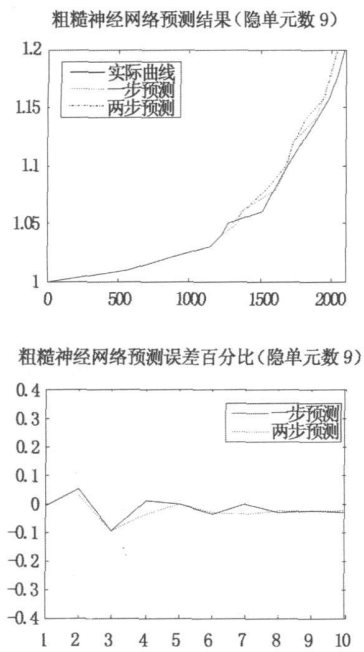


图 4 粗糙神经网络预测结果与误差百分比

表 3 数据说明, 粗糙神经网络预测结果与实际监测结果相吻合, 可以较准确地预测故障发生的时间。比较表 4 及图 4、图 5 知, 粗糙神经网络显著改善 BP 神经网络的性能, 预测精度提高较为明显。但粗糙神经网络训练速度较 BP 神经网络慢。在追求预测精度的故障预测领域, 认为粗糙神经网络较 BP 神经网络整体表现优异。将粗糙神经网络应用于设备 2 和设备 3 有类似的结果。

5 结论

粗糙集理论具有擅于处理不精确、不完全信息的特点, 本文采用粗糙集改进神经元结构, 设计了粗糙神经网络, 开展了




图 5 BP 神经网络预测结果与误差百分比

基于粗糙神经网络的某型航空电子设备故障预测研究。研究表明, 粗糙神经网络显著提高了预测的精度、改善了网络的预测性能, 可以实现较准确的故障预测。由于设备实际使用过程中的性能退化趋势可能会发生随机变动, 粗糙神经网络在处理这类不确定信息时具有一定优势, 但是本文介绍的方法不能实现自适应预测, 如何利用逐渐积累的实际使用信息实现自适应预测是下一步研究的重点。

参考文献:

[1] Walls, Michael, Thomas M. et al. Improving system maintenance decisions: a value of information framework [J]. The Engineering Economist, 1999, 44: 151-166.

[2] E Malley M. Methodology for Simulating the Joint Strike Fighter's (JSF) Prognostic and Health Management System [D]. Air Force Institute, 2001.

[3] 梁 旭, 李行善, 张 磊, 等. 支持视情维修的故障预测技术研究 [J]. 测控技术, 2007, 26 (6): 5-9.

[4] 胡雷刚, 肖明清. 基于 BP 神经网络的航空设备故障预测 [J]. 仪器仪表学报, 2008, 29 (4): 521-523.

[5] 张文修, 吴伟志, 梁吉业, 等. 粗糙集理论与方法 [M]. 北京: 科学出版社, 2003.

[6] 刘 清. Rough 集及 Rough 推理 [M]. 北京: 科学出版社, 2001.

[7] 郭小芸, 马小平. 基于粗糙集-神经网络集成的故障诊断 [J]. 控制工程, 2007, 14 (1): 53-56.

[8] 陈 恬. 粗糙集与神经网络在航空发动机气路故障诊断中的应用 [J]. 航空动力学报, 2006, 21 (1): 207-212.

[9] 王永茂, 高岩. 基于粗糙神经网络的燃煤发热量预测模型 [J]. 计算机测量与控制, 2009, 17 (4): 655-656.

[10] 魏建明. 基于集成计算智能的图像信息融合技术研究 [D]. 上海: 上海大学, 2005.