

文章编号: 1002-0640(2024)11-0015-09

基于融合知识图谱的航空柱塞泵故障预测诊断方法^{*}

钟维宇^{1,4}, 柳林燕², 唐启东^{1,4}, 易江义^{1,4}, 贺庆³

(1. 空军航空维修技术学院航空电子设备维修学院, 长沙 410129; 2. 南京理工大学机械工程学院, 南京 210094; 3. 中国兵器装备集团航空制导弹药研发中心, 长沙 410129;
4. 湖南省导弹维修工程技术研究中心, 长沙 410129)

摘要: 针对航空柱塞泵运行过程中存在故障频率高、故障种类多、故障溯源难度大、预测准确率低等问题, 提出了知识图谱和人工蜂群算法相融合的航空柱塞泵故障预测诊断方法。自顶向下定义知识图谱架构、实体类型和实体间关系, 自底向上构建图谱的知识网络, 数据层进行实体命名识别、抽取、融合、整合和推理; 建立了人工蜂群故障预测算法包含输入层、指派层、传播层、自注意力层、输出层, 采用故障特征提取、变邻域双向门控故障预测、注意力机制, 通过特征向量训练形成了航空柱塞泵故障预测模型; 通过实际维修案例, 构建了航空柱塞泵故障诊断的知识图谱, 实验证明了上述方法的有效性、可行性, 验证了算法高效的故障诊断能力。

关键词: 知识图谱; 人工蜂群; 故障预测; 故障诊断; 注意力机制

中图分类号: TJ08; V19 **文献标识码:** A **DOI:** 10.3969/j.issn.1002-0640.2024.11.003

引用格式: 钟维宇, 柳林燕, 唐启东, 等. 基于融合知识图谱的航空柱塞泵故障预测诊断方法[J]. 火力与指挥控制, 2024, 49(11): 15-23.

Aviation Plunger Pump Fault Prediction and Diagnosis Method Based on the Fusion of Knowledge Graph

ZHONG Weiyu^{1,4}, LIU Linyan², TANG Qidong^{1,4}, YI Jiangyi^{1,4}, HE Qing³

(1. Aviation Electronic Equipment Maintenance College, Air Force Aviation Maintenance Technology College, Changsha 410129, China;
2. School of Mechanical Engineering, Nanjing University of Technology, Nanjing 210094, China;
3. Aviation Guidance Ammunition Research and Development Center of CSGC, Changsha 410129, China;
4. Hunan Missile Maintenance Engineering Technology Research Center, Changsha 410129, China)

Abstract: Aiming at the problems of high fault frequency, many fault types, difficult fault traceability and low prediction accuracy in the operation of aviation plunger pump, a fault prediction and diagnosis method of aviation plunger pump based on the fusion of knowledge graph and artificial bee colony algorithm is proposed. Firstly, the knowledge graph architecture, entity types and inter-entity relationships are defined from top to bottom. The knowledge network of the graph is constructed from bottom to top, and entity naming recognition, extraction, fusion, integration and reasoning are performed for the data layer. Secondly, the artificial bee colony fault prediction algorithm is established, which includes input layer, assignment layer, propagation layer, self-attention layer and output layer. The fault feature extraction, variable neighborhood bidirectional gating fault prediction and attention mechanism are used to form the aviation plunger pump fault prediction model through feature vector training. Finally, through the actual maintenance cases, the knowledge graph of aviation plunger pump fault diagnosis is constructed. The experiment proves the effectiveness and feasibility of the above method, and verifies the efficient fault diagnosis ability of the proposed algorithm.

收稿日期: 2023-11-15

修回日期: 2023-12-30

^{*} 基金项目: 国家自然科学基金(51705256); 湖南省教育厅教育科学研究项目(21C1241、22C1028); 院级重点课题资助项目(YB2301)

作者简介: 钟维宇(1989—), 男, 湖南长沙人, 硕士, 高级工程师。

Key words: knowledge graph; artificial bee colony; fault prediction; fault diagnosis; attention mechanism

Citation format: ZHONG W Y, LIU L Y, TANG Q D, et al. Aviation plunger pump fault prediction and diagnosis method based on the fusion of knowledge graph[J]. Fire Control & Command Control, 2024, 49(11):15-23.

0 引言

航空柱塞泵是航空装备液压系统中核心动力元件,作为一个非线性复杂系统,其处于高速运转、高温、高压的工作状态,故障发生具有随机性和并发性,常出现旋转组件倾覆、吸空、气蚀、振动、噪声等问题^[1]。装备维护保障人员记录整理了典型航空柱塞泵故障案例,但大量的故障原因资料并没有充分利用,故障诊断随技术人员知识和经验的不同差异较大,故障预测难度大。所以,需要建立航空柱塞泵故障预测诊断模型,将故障现象与故障原因之间形成多对多的耦联关系,如何通过智能化故障预测手段,高效地定位故障部位,获取故障相关信息,降低航空柱塞泵使用风险和提高使用寿命,已成为当前研究热点和难点。

目前,针对航空柱塞泵故障预测鲜有研究,但国内外学者对复杂系统装备预测大多数基于数据驱动的预测方法开展研究,主要包括随机过程、时间序列分析及机器学习。刘小峰等针对航空发动机健康监测问题,采用灰色关联分析法,结合线性相关分析,利用灰色接近关联度对优化选择的特征进行加权融合,滑动窗欧氏距离比对法确定测试发动机的HI失效阈值,提出了预测模型FOTP-GM(1,1)方法^[2]。YANG等对飞机发动机的故障采用历史样本进行相似性匹配,并采用全阶时间幂灰色预测模型GM(1,1)预测未来退化轨迹^[3]。董青等利用正态分布描述随机冲击对设备退化量,通过考虑退化漂移可变性和随机冲击对退化率,提出了一种考虑随机冲击影响的非线性退化设备剩余寿命预测方法,构建出状态空间模型实现设备剩余寿命在线更新^[4]。ZHOU等采用一种新的基于隐马尔可夫模型(HMM)的方法,处理环境因素和故障过程之间的准确表达这个问题,将HMM与专家系统的置信规则库(BRB)相结合,提出了一种新的预测模型来预测实际的潜在故障^[5]。LIU等基于隐半马尔可夫模型开发了HOHSMM,使用了一个智能优化算法组来代替期望最大化(EM)算法,置换的HOHSMM降阶方法和复合节点机制,提出了一种新的基于高阶隐半马

尔可夫模型的剩余寿命故障预测模型^[6]。吴闯等采用双向长短期神经网络和条件随机场等深度学习技术实现知识自主抽取,并基于余弦距离和Jaccard相关系数法进行故障知识的融合,实现了润滑系统故障知识智能问答和故障归因分析应用^[7]。慈颖等深入分析三元组知识图谱构建方法的基础上,结合航天装备在役考核的实际应用,提出一种基于航天装备数据的知识图谱体系构建技术,有效地对航天装备故障知识体系进行组织挖掘和应用^[8]。

上述方法尚未涉及航空柱塞泵故障预测及故障维修,且需依赖大量的数据,对数据质量要求较高,增加了复杂装备故障预测的难度。本文旨在构建航空柱塞泵故障融合诊断框架,提出一种有效且具有实际应用价值的知识图谱及人工蜂群融合算法。提取故障特征,建立柱塞泵维修信息的一体化知识图谱;采用变邻域双向门控故障预测,注意力机制,从而实现故障现象到故障推理,故障预测的转换。通过实际维修案例验证方法的可行性、有效性及可靠性。

1 航空柱塞泵故障融合诊断框架

航空柱塞泵故障融合诊断框架包含故障基础数据的提取、知识图谱的提取及人工蜂群算法的故障预测3部分。1)故障基础数据来源于设计、生产、制造、维修等多部门,将故障数据进行结构化、非结构化处理。考虑到故障知识的复杂程度,处理难度大大提升,采用机器学习AI智能识别技术;2)知识图谱常用来描述知识实体及知识属性之间、知识实体与知识实体之间的关联关系。由于航空柱塞泵故障现象描述具有专业性,描述语义干扰大、易混淆,故采用专业领域图谱描述航空柱塞泵故障诊断图谱,包含知识实体构建、知识抽取与融合及知识整合与推理3个方面^[9];3)人工蜂群算法提取故障数据的特征向量与知识实体进行匹配,采用变邻域双向门控故障预测方法获取词义关联程度,输入到人工算法模型中训练和解码,输出相关的故障预测结果。航空柱塞泵故障融合诊断框架如下页图1所示。

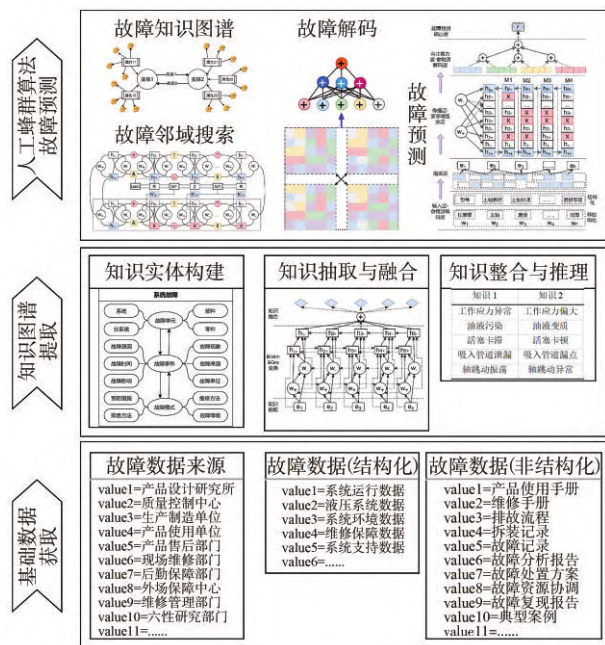


图1 航空柱塞泵故障融合诊断框架

Fig. 1 Framework of aviation plunger pump fault fusion diagnosis

2 关键理论技术

2.1 融合知识图谱

融合知识图谱技术作为人工智能最重要的研究方向之一,是一种用图形来描述知识实体之间关联程度的网络化建模方式,由实体节点、关联边组成,将抽象的知识具体化、网络化、关联化。根据知识种类及普及范围,可将知识图谱区分为通用知识图谱和专用知识图谱。知识图谱将“知识”以三元组形式进行网络化,即“实体 \longleftrightarrow 关系 \longleftrightarrow 实体”转换为“实体 \rightarrow 属性 \rightarrow 属性值”的链接关系,如图2所示。原始经验数据经过知识实体构建,知识属性抽取,知识融合加工,知识整合推理,将经验数据信息结构化、数据化,形成带有实体节点属性和关系的可视化数据库。有助于人工智能技术对原始经验数据的快速“理解”,使机器获取人类的相应的认知。




图2 融合知识图谱示意图

Fig. 2 Schematic diagram of fusion of knowledge graph

2.2 知识实体的构建

知识实体是指与航空柱塞泵系统故障知识、经验、数据相关的一组规范,能够准确地描述系统的故障原因、故障属性及故障间关系以及故障间关系属性,展现故障之间的内在关联,如图3所示。知识实体构建的常用方法有Fox评价法、EO工程法、七步法等,本文采用技术稳定性较高的Gruninger & Fox评价法,构建知识实体故障模型^[10]。

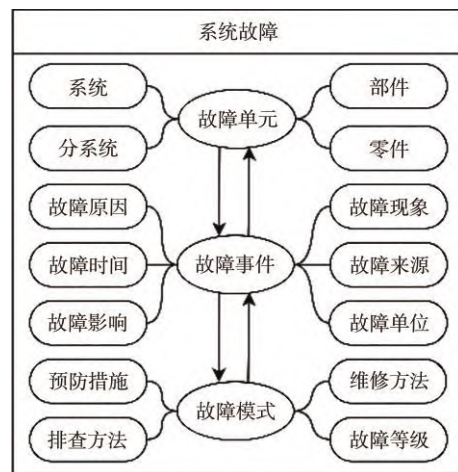


图3 故障系统知识实体构建图

Fig. 3 Construction diagram of fault system knowledge entity

Fox评价法是多伦多大学最先提出并应用,其具体流程包含以下步骤:1) 构建系统故障知识实体前,建立非形式化对象及关系,与航空业内专家学者、柱塞泵保障维修人员研究可能发生的故障及所有解决方案;2) 查询系统设置约束,寻找相关领域故障是否有可以复刻的知识实体;3) 航空柱塞泵故障术语形式化,充分提取形式化的术语。查阅航空柱塞泵系统的国标、国军标以及行标等,对故障专业术语形式化,对故障种类及概念进行规范处理。4) 航空柱塞泵故障系统能力形式化,系统能力就从非形式化能力变成形式化能力。构建故障领域知识核心体系,采用实体形式化定义和描述核心概念;5) 航空柱塞泵故障规则形式化为公理,并遵循特定逻辑来表示所遵循的公理;6) 收集领域专家、基层维修保障人员意见与建议,适时调整故障问题的解决方案,不断完善知识实体,对航空柱塞泵故障知识模型体系进行不断优化和改进升级。航空柱塞泵故障信息知识实体KE表示为:

$$KE = (E, R) \quad (1)$$

$$\left\{ \begin{array}{l} E = \{e_1, e_2, \dots, e_n\} \\ R = \{r_1, r_2, \dots, r_m\} \end{array} \right.$$

式中, E 为 n 个故障实体集合; R 为 m 个故障实体间关系集合。

故障实体可分为故障头实体及故障尾实体,知识图谱中三元组(故障头实体、故障关系、故障尾实体)表示为 $\langle h, r, t \rangle$ 。知识图谱中的故障规则链定义为 $S = \{(h, r, t) | h, t \in E, r \in R\}$ 。

2.3 知识抽取与融合

知识抽取过程最为关键步骤就是从非结构化故障数据信息中获取有效知识,主要方法包括故障实体识别与故障关系抽取。故障实体识别包含故障信息类、故障定量类及故障定性类三大类别,故障关系提取包括基于特征、远程监督、深度学习等方法。在航空柱塞泵故障领域,目前尚无相关故障数据库,需要自行搭建故障数据集^[11]。本文采用深度学习方方法中 BiLSTM-CRF&GRU 变换,对故障实体进行序列标注及识别,进行编码、解码操作,抽取故障关系,解决故障实体知识集容量不足、故障语义不清的问题,更加精准地表达故障语义。

知识融合过程通过将新的故障实体融合到现有故障库内,新老故障实体融合是故障知识图谱扩展的关键因素。知识融合主要包括3方面:1)故障自身实体与故障关系的结构、框架与内容差异化融合;2)故障间关系、模式与构型的模型融合;3)故障知识的对齐与匹配。知识融合主要采用实体消歧技术与共指消解技术,确保融合后知识图谱的统一性与唯一性。聚类法被广泛应用于实体消歧、共指消解技术中,解决词汇异构性及语义歧义,使故障知识完全融合。

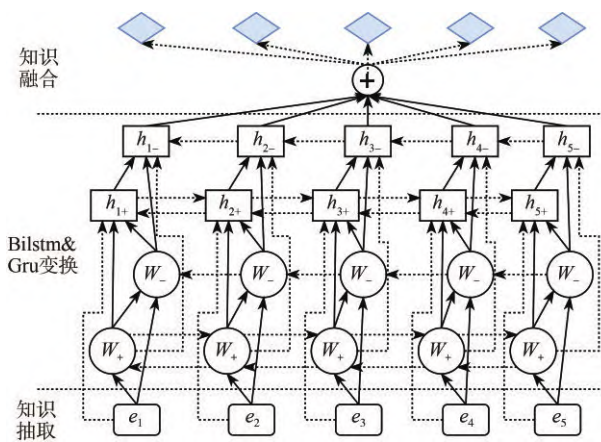


图4 柱塞泵故障系统知识抽取与融合模型

Fig. 4 Plunger pump fault system knowledge extraction and fusion model

采用 score 函数中皮尔逊距离计算柱塞泵故障系统知识融合,输出结果的相关性值,如式2所示:

$$\text{score}(h_-, w_+) = G \frac{(h_-, \bar{h}_+)(w_-, w_+)}{\sqrt{(h_-, \bar{h}_+^2)(w_-, \bar{w}_+^2)}} \quad (2)$$

式中, h_+ 为 BiLSTM-CRF 变换输出结果; w_+ 为 GRU 变换输出结果; G 为权重矩阵。

通过 score 函数计算出 BiLSTM-CRF&GRU 两部分特征权重后,进行噪声处理,向量值相乘得到新的特征,如式3所示:

$$\left\{ \begin{aligned} &st \sum_{k=1}^K h_k(t) = f(t) \\ &\min_{h_k, w_k} \left\{ \sum_{k=1}^K \left| \partial_i \left[\left(\delta(t) + \frac{1}{\pi t} \right) \times h_k(t) \right] e^{-j\omega_k t} \right| \right\} \end{aligned} \right. \quad (3)$$

式中, k 为新特征值数量; h_k 为新特征值分量; w_k 为新特征值的中心值频率。

2.4 知识整合与推理

知识整合及推理是对故障知识图谱的扩展补充方法,包含概念层(Tbox)方法、随机路径(Pra)方法、子图结构(Sfe)方法等^[12]。故障知识图谱的扩展主要通过扩展知识实体之间关系及知识实体特有属性值,提取相应知识特征,进行故障分类学习及故障预测分析。采用基于知识图谱嵌入式算法,将人工算法、神经算法等模型嵌入图谱,叠加随机路径(Pra)向量空间,实现故障知识图谱的扩展补充,非结构化数据推演应用。

非结构化的航空柱塞泵故障系统知识实体中抽取、融合大量模糊、重复、片段化的数据,进行知识整合与推理,提高故障知图谱数据库的数据质量。本文采用正、余弦距离、Jaccard 系数融合方式分别表示知识相似度、知识推理度、知识整合度,如式(4)所示。例如,故障系统中存在“工作压力异常”的文本描述,并未给出压力值范围,需要通过联系上下故障,推理判断“工作压力偏大”或“工作压力偏小”,明确知识实体的正确含义。融合计算方式计算航空柱塞泵故障系统间知识相似程度,通过设定阈值,分析知识的整合度及推理度。航空柱塞泵部分故障知识表达,如下页表1所示。

$$\left\{ \begin{aligned} \text{sim}_{\sin}(s_i, s_j) &= \frac{|K(s_i) \cup K(s_j)|}{\sqrt{|K(s_i)| \cdot |K(s_j)|}} \\ \text{sim}_{\cos}(s_i, s_j) &= \frac{|K(s_i) \cap K(s_j)|}{\sqrt{|K(s_i)| \cdot |K(s_j)|}} \\ \text{sim}_{jac}(s_i, s_j) &= \frac{|K(s_i) \cap K(s_j)|}{|K(s_i) \cup K(s_j)|} \end{aligned} \right. \quad (4)$$

式中, s_i 和 s_j 分别为航空柱塞泵故障实体; $K(s_i)$ 为实体 s_i 的属性特征; sim_{\sin} 、 sim_{\cos} 、 sim_{jac} 数值代表故障实

表1 航空柱塞泵故障知识表达

Table 1 Aviation plunger pump fault knowledge expression

序号	表达A	表达B	表达C	sim _{sin}	sim _{cos}	sim _{jac}
1	工作应力异常	工作应力偏大	工作应力偏小	0.57	0.82	0.80
2	油液污染	油液变质	油液浑浊	0.42	0.73	0.65
3	活塞卡滞	活塞卡顿	活塞磨损	0.23	0.15	0.22
4	吸入管道泄漏	吸入管道漏液	吸入管道腐蚀	0.07	0.23	0.19
5	轴跳动振荡	轴跳动异常	轴跳动疲劳	0.19	0.31	0.37

体之间的语义相似程度。数值越大,代表语义相似程度越高。

3 基于人工蜂群的故障预测方法

本研究以航空柱塞泵故障融合知识图谱为基础,引入人工蜂群算法对故障发生原因及故障定位进行精准预测。构建人工蜂群故障预测模型框架,进行故障特征提取、变邻域双向门控故障预测、注意力机制。模型框架包含食物源编码层、指派层、传播层、自注意力层及输出层,每一层可以利用航空柱塞泵故障数据的特点,实现最佳的预测效果。

3.1 人工蜂群故障预测模型架构

人工蜂群算法通过模拟自然界蜜蜂寻蜜、采蜜的全过程。蜂群寻找食物过程常认为是一种高级的深度自主学习网络,采蜜初期没有预先设定的规则、架构及方法,仅按工种将蜜蜂分为3类:采蜜蜂、观察蜂和侦察蜂,3种蜂群在不同环境下可以相互转换角色^[13]。人工蜂群算法拥有多个网络化结构隐藏层、相对权重较低,算法结构相对简易。运算的复杂度取决于提供的知识实体类型及属性。

航空柱塞泵故障诊断的应用中,食物源编码层为最底层,作为知识实体基本属性的过滤器,用于提取结构化与非结构化知识数据。指派层抽取故障数据特征,执行卷积运算,提炼更高阶的故障属性特征,相对复杂的故障属性特征,采用多层结构表示,即知识实体空间段。传播层进行双向门控故障预测,多次迭代求导训练后,求解可能存在的故障状态。自注意力层通过向量表现故障诊断核心关键语义信息。人工蜂群算法故障预测的框架结构,如图5所示。

3.2 故障特征提取

指派层作为一种前置反馈型的特征提取方式,指派层网络主要包含输入、词化、碎片、指派及输出几部分组成。通过指派层,提取结构化及非结构化食物源的相关特征。将人工蜂群中特征提取运用到航空柱塞泵故障预测中,有助于提高故障种类、

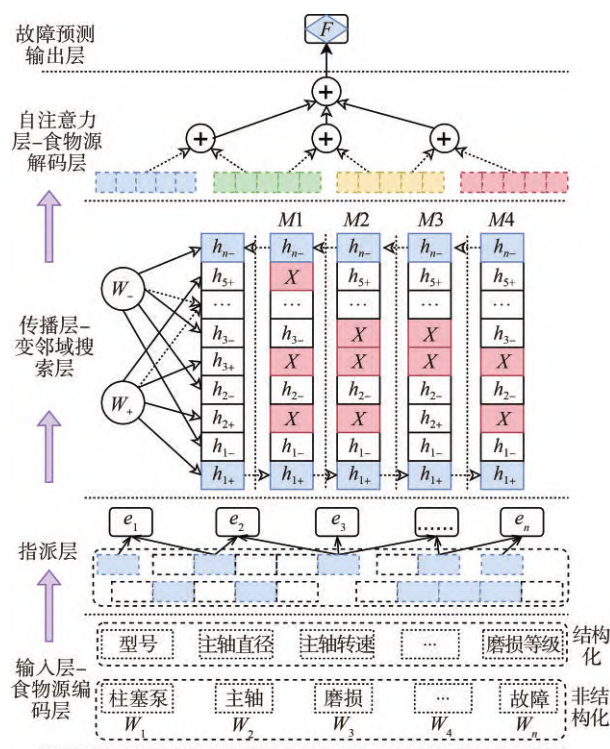


图5 人工蜂群故障预测模型

Fig. 5 Artificial bee colony fault prediction model

故障语义及故障现象之间的特征关联性,为变邻域搜索传播层作了更好的准备。人工蜂群算法在航空柱塞泵故障特征提取过程中,将结构化、非结构化故障数据转换成 $n \times l$ 的空间矩阵,其中, k 为故障数据中词化数量, l 为单个词碎片化数量。根据指派规则,满足知识抽取与融合的3方面要素,形成多维向量空间集合,如式(5)所示。

$$F_k = \left(\frac{1}{K} \sum_i K_i^2 \right)^2 \frac{1}{K} \sum_i |K_i| \quad (5)$$

式中,故障数据特征向量矩阵为 $\{F_1, F_2, F_3, \dots, F_k\}$,矩阵每列为 l 维的向量 $F_k = \{l_1, l_2, l_3, \dots, l_l\}$ 表示第 k 维向量分解的 l 个故障知识图谱节点词碎片化数据。

3.3 变邻域双向门控故障预测

传播层采用变邻域双向门控故障预测,结合Gru、Bilstm方法,变邻域蜂群网格化搜索,搜索迭代效率更高,算法逻辑清晰,算法架构简单,故障预测的精度大幅提升。考虑航空柱塞泵故障预测知识实体数量庞大、经验数据规格不一,利用迭代循环记忆功能更强的双向门控方法进行邻域搜索,加强知识实体间关联程度,有效进行故障预测训练。变邻域双向门控故障预测如图6所示。

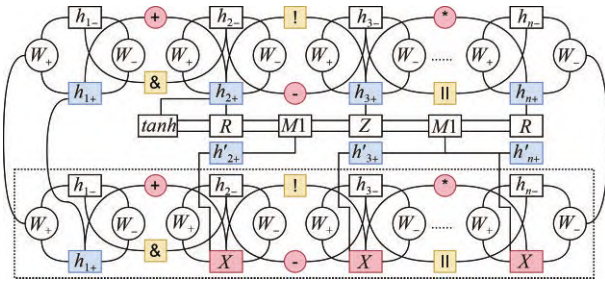


图6 变邻域双向门控故障预测

Fig. 6 Variable neighborhood bidirectional gating fault prediction

双向门为更新门逻辑、重置门逻辑,不同逻辑通过阈值进行控制,将指派层提取的空间向量代入双向门故障预测。更新门逻辑中阈值越大,变邻域搜索范围越大,更加容易推演出故障原因,故障间关联性不强;重置门逻辑中阈值越大,变邻域搜索范围越小,不易推演出故障原因,故障间关联性强。

在进行变邻域双向门控传输及向量输入时,不同时刻下相关性权重参数变换,如式(6)、式(7)所示。

$$\left\{ \begin{aligned} \tanh(x) &= \frac{e^x - e^{-x}}{e^x + e^{-x}} \\ \text{soft max}(f) &= \frac{\exp(f)}{\sum_{x=1}^n \exp(f_x)} \end{aligned} \right\} \quad (6)$$

式中, $\tanh(*)$ 为双曲正切函数; $\text{soft max}(*)$ 为归一化指数函数。

$$\left\{ \begin{aligned} \mathbf{H} &= (h_1^+, h_2^+, h_3^+, \dots, h_k^+)^T \\ \mathbf{W} &= (w_1^+, w_2^+, w_3^+, \dots, w_k^+)^T \\ \mathbf{R} &= \text{soft max}(\mathbf{v}_{att} \cdot [\tanh(\mathbf{H})]^T) \\ \mathbf{Z} &= \text{soft max}(\mathbf{G} \cdot [\tanh(\mathbf{R} \cdot \mathbf{W})]^T + \mathbf{b}^T) \end{aligned} \right\} \quad (7)$$

式中, \mathbf{H} 是 BiLSTM-CRF 变换的特征矩阵; \mathbf{W} 是 GRU 变换矩阵; \mathbf{v}_{att} 是维度为 $2l$ 的权重向量; l 是 BiLSTM-CRF 隐藏层的大小; \mathbf{G} 表示词义相关性的权重矩阵; \mathbf{b} 为 l 维度的偏置向量。

3.4 注意力机制

自注意力层采用注意力机制对食物源进行解码,主要目的用于捕捉变邻域双向门控过滤出来知识

信息,进行整合、推理、重排,更好地利用文本语义,提炼出权重值高、发生概率大的故障信息。注意力机制是利用人工智能技术,对故障数据的空间矩阵进行交变操作,剔除故障数据的干扰噪声,降低重要程度低的故障信息,有效突出重要故障识别度。注意力机制层如图7所示,注意力机制对故障概率分布进行解码,如式(8)所示。




图7 注意力机制层

Fig. 7 Attention mechanism layer

$$C = \sum_{i=1}^T \frac{\exp(v_{att} \cdot \tanh(\mathbf{w}h_k + \mathbf{u}h_i + b))}{\sum_{j=1}^T \exp(v_{att} \cdot \tanh(\mathbf{w}h_k + \mathbf{u}h_i + b))} h_i \quad (8)$$

式中, T 为故障输入序列的元素数目; \mathbf{w} 、 \mathbf{u} 为不同的权重矩阵; h_i 、 h_k 代表 BiLSTM-CRF 模型中 h^+ 的正反向输出。

3.5 故障模型预测评价指标

为了验证基于人工蜂群的故障预测模型的可靠程度,采用精确度、召回度及可靠度值3种指标进行模型性能的评价指标^[14]。精确度 P 代表了模型预测故障的准确程度, P 值越高,模型预测值的准确度越高;召回度 C 代表故障能否被预测程度, C 值越高,故障被预测出来概率越高;可靠度值 R 用于评价故障模型可靠性程度, R 值越高,故障预测模型的预测方面可靠性更高。指标相关计算如式(9)所示。

$$\left\{ \begin{aligned} P(Precision) &= \frac{TP}{TP + FP} \times 100\% \\ C(Recall) &= \frac{TP}{TP + FN} \times 100\% \\ R(Reliability) &= \frac{2 \times Precision \times Recall}{Precision + Recall} \times 100\% \end{aligned} \right\} \quad (9)$$

人工蜂群的故障预测中故障频率 FS 及故障的关联程度 FR 也是评价模型性能优劣的指标,如式(10)所示。

$$\left\{ \begin{array}{l} FS(h_{ij}, t_{ij}) = \frac{N(h_{ij}, t_{ij})}{\sum_{k=1}^{|H_i|} N(h_{ij}, t_{ik})} \\ FR(H_i, t_{ij}) = \log\left(\frac{N(H_i)}{| \{(h_{ik}, r_i, t_{ij}): h_{ik} \in H_i, \forall k \} |}\right) \end{array} \right\} \quad (10)$$

式中,三元组表示为 $\langle h, r, t \rangle$; $N(h_{ij}, t_{ij})$ 表示该条故障出现的次数; $\forall k$ 表示关联实体为 t_{ij} 的一种故障集合。

4 航空柱塞泵融合知识图谱实例及应用

为验证基于知识图谱航空柱塞泵故障预测方法具有准确可靠的预测性能,搭建运算仿真实验环境。运行环境为Intel Core I5-12400,内存为16 G的Windows10电脑系统,Python语言3.8版本进行编程,深度学习库PyTorch 1.8.1, GPU为NVIDIA RTX3090, GPU与CPU搭配使用能够提高重复的运算分析效率,在知识图谱和人工蜂群算法融合的基础上计算提高精准率。

4.1 柱塞泵故障诊断知识图谱构建

将从近年来不同渠道的近万条航空柱塞泵故

障数据进行处理,把故障数据的实体作为知识图谱的节点,实体之间的关系作为知识图谱的边,存储在Neo4j图数据库中,构成航空柱塞泵故障知识图谱。如图8所示,展示了部分航空柱塞泵系统故障知识图谱。知识图谱通过“组成”“原因”“检查”“属性”等关系将故障模式、故障部件、故障原因连接,将整个系统的故障知识串联起来,形成一个完整的航空柱塞泵知识体系。

4.2 基于知识图谱的故障诊断预测

航空柱塞泵运行状态数据包括正常运行、排油故障、吸油故障、缸体倾覆、摩擦损失等16种故障。依据不同故障综合故障特征,结合人工蜂群算法故障预测框架,提取结构化与非结构化知识数据、执行卷积运算提炼复杂的故障属性特征,在知识实体空间段进行双向门控故障预测,求解可能存在的故障状态。故障预测过程中定义故障知识数据标签为 $F-KE=(E, R)=\{F01, F02, \dots, Fnn\}$,不同故障知识特征分别对应 $E=\{e_1, e_2, \dots, e_n\}$ 及 $R=\{r_1, r_2, \dots, r_m\}$ 。将航空柱塞泵运行数据按正常数据(30%)和故障数据(70%)比例混合,并在知识图谱




图8 航空柱塞泵故障知识图谱(局部)

Fig. 8 Knowledge graph of aviation plunger pump fault knowledge (local)

基础上完成故障诊断任务。图 9 展示了航空柱塞泵故障预测图谱(局部)。图 10 展示故障数据节点的精确率和相似故障的样本检出率,在航空柱塞泵故

障预测图谱及人工蜂群算法基础上,相似故障样本检出率及相似故障命中值更高,有效辅助了设备故障诊断决策。




图 9 航空柱塞泵故障预测图谱(局部)

Fig. 9 Fault prediction graph of aviation plunger pump (local)




图 10 故障节点数据精度及相似度值

Fig. 10 Fault node data accuracy and similarity values

4.3 方法数据对比

为了验证人工蜂群算法对航空柱塞泵故障预测的效果,相同故障数据知集集合下,将本文中提出的知识图谱和人工蜂群算法相融合方法(ABC),与其他 3 种故障预测方法卷积神经网络模型(CNN)、单门控循环单元(Gru)、双向长短时记忆神经网络(Bilstm)进行算法数据对比。不同知识图谱迭代次数与精准度关系如图 11 所示,不同知识图谱故障预测效果指标对比如表 2 所示。

根据对比数据分析得知:CNN 模型的故障预测可靠性不佳,Gru 模型的故障预测准确度及被预测

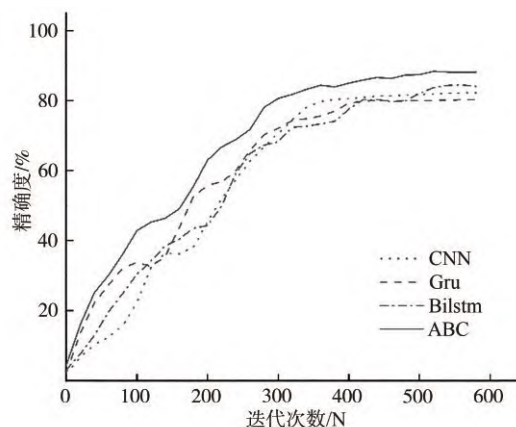


图 11 不同知识图谱迭代次数与精准度关系

Fig. 11 Relationship between iterations and accuracy of different knowledge graphs

表 2 不同知识图谱故障预测效果指标对比

Table 2 Fault prediction effect indicators of different knowledge graph comparisons

模型	$P/\%$	$C/\%$	$R/\%$	FS	FR
CNN	82.24	79.93	80.47	0.31	0.77
Gru	80.21	78.05	82.99	0.34	0.81
Bilstm	84.08	81.98	83.31	0.27	0.87
ABC	88.19	84.61	87.26	0.18	0.94

概率不佳;Bilstm 模型相对 CNN 模型,故障预测可靠性提升 3.53%;Bilstm 模型相对 Gru 模型,故障预测

精准度提升4.82%,故障可预测概率提升5.04%。本文中提出的ABC模型相比于其他模型在预测准确度、可预测概率及预测可靠性方面都有较大提升,预测准确性、可预测概率相比Gru模型分别提升9.95%、8.40%,预测可靠性相比CNN模型提升8.44%。ABC模型故障频率 FS 值最低,故障的关联程度 FR 值最高,充分说明该模型针对航空柱塞泵故障预测的可靠度及准确度更高,模型中变领域双向门控循环合理利用故障信息之间内在关系,注意力机制降低故障预测中噪声的影响,提升了模型的故障预测效果。

5 结论

针对航空柱塞泵进行故障诊断时,存在大量结构化、非结构化的故障数据知识,为了有效解决故障预测中数据质量一般,故障特征缺失等现状,提出了基于知识图谱及人工蜂群算法的融合故障预测方法,实验结果表明,该方法能够有效进行故障预测,有以下主要原因:1)该方法在故障数据知识质量一般的情况下,能精确地识别出故障知识中实体、属性,采用BiLSTM-CRF&GRU变换抽取故障关系,叠加随机路径(Pra)向量空间实现故障知识整合与推理,建立了航空柱塞泵故障原因领域知识图谱;2)人工蜂群算法编码、指派、传播、解码,变邻域双向门控故障预测、注意力机制等的融合,减少了故障预测中的噪声干扰,能够高效捕捉故障知识中多维序列特征,提高预测方法的预测效果及精准度;3)该方法相比其他模型在预测准确度、可预测概率及预测可靠性方面都有较大提升,提升幅度均值达9%左右,同时故障预测频率值最低,故障的关联程度值最高。在后续的工作中,将重点关注故障维修过程中不确定性问题,提取故障维修不确定性知识特征,进一步提升航空柱塞泵故障预测的效果。

参考文献:

- [1] 欧阳小平,王天照,方旭.高速航空柱塞泵研究现状[J].液压与气动,2018(2):1-8.
OUYANG X P, WANG T Z, FANG X. Research status of high-speed aviation plunger pumps [J]. Chinese Hydraulics & Pneumatics, 2018(2):1-8.
- [2] 刘小峰,叶榕婷,柏林,等.基于灰色理论的航空发动机剩余寿命预测[J].电子测量与仪器学报,2021,35(1):74-81.
LIU X F, YE R T, BO L, et al. Residual life prediction for aircraft engines based on grey theory [J]. Journal of Electronic Measurement and Instrumentation, 2021, 35(1):74-81.
- [3] YANG X Y, FANG Z G, LI X C, et al. Similarity-based information fusion grey model for remaining useful life prediction of aircraft engines [J]. Grey Systems: Theory & Application, 2020, 11(3):463-483.
- [4] 董青,郑建飞,胡昌华,等.考虑随机冲击影响的自适应Wiener过程剩余寿命预测方法[J].航空学报,2022,43(9):478-490.
DONG Q, ZHENG J F, HU C H, et al. Residual life prediction for adaptive Wiener process method in consideration of random shock impacts [J]. Acta Aeronautica et Astronautica Sinica, 2022, 43(9):478-490.
- [5] ZHOU Z J, HU C H, XU D L, et al. A model for realtime failure prognosis based on hidden Markov model and belief rule base [J]. European Journal of Operational Research, 2010, 207(1):269-283.
- [6] LIU Q M, CHEN X, DONG M, et al. A novel health prognosis method for system based on improved degenerated hidden Markov model [J]. Robotics and Computer-Integrated Manufacturing, 2022(78):102402.
- [7] 李聪,石义官,黄权,等.基于深度学习的小口径弹药装配设备故障诊断专家系统[J].兵工自动化,2023,42(6):20-26.
LI C, SHI Y G, HUANG Q, et al. Fault diagnosis expert system of small caliber ammunition assembly equipment based on deep learning [J]. Ordnance Industry Automation, 2023, 42(6):20-26.
- [8] 慈颖,秦留洋,韩惠婕.基于航天装备数据的知识图谱体系研究[J].计算机测量与控制,2023,31(5):249-254.
CI Y, QIN L Y, HAN H J. Research on the Knowledge graph system based on aerospace equipment data [J]. Computer Measurement and Control, 2023, 31(5):249-254.
- [9] 黄海金,季焱,刘晓佳,等.面向售后保障的导弹装备健康管理研究[J].现代防御技术,2023,51(1):75-85.
HUANG H J, JI H, LIU X J, et al. Research on missile equipment health management system for after-sales guarantee [J]. Modern Defense Technology, 2023, 51(1):75-85.
- [10] 陈昭明,邹劲松.智能制造领域的数字孪生技术研究可视化知识图谱分析[J].机械科学与技术,2023,42(8):1249-1260.
CHEN Z M, ZOU J S. Analysis of visual knowledge mapping in intelligent manufacturing via digital twin technology [J]. Mechanical Science and Technology for Aerospace Engineering, 2023, 42(8):1249-1260.

(下转第33页)

- [19] GUAN H, FU C, ZHANG G, et al. A lightweight model for efficient identification of plant diseases and pests based on deep learning[J]. *Frontiers in Plant Science*, 2023(14): 1227011.
- [20] LIU S, LU Q, QIN H F, et al. Path aggregation network for instance segmentation[C]// *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, Salt Lake City, 2018: 8759-8768.
- [21] CHEN J, KAO S, HE H, et al. Run, Don't walk: Chasing higher FLOPS for faster neural networks[C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023: 12021-12031.
- [22] MA X, GUO F M, NIU W, et al. Pconv: the missing but desirable sparsity in dnn weight pruning for real-time execution on mobile devices [C]// *Proceedings of the AAAI Conference on Artificial Intelligence*, 2020: 5117-5124.
- [23] JOCHER G, CHAURASIA A, QIU J. Ultralytics YOLO (version 8.0.0)[EB/OL]. (2023-03-10)[2024-06-14]. <https://github.com/ultralytics/ultralytics>.
- [24] PENG Y, WANG J, YU Z, et al. Camouflage soldier object detection network based on the attention mechanism and pyramidal feature shrinking [J]. *Multimedia Tools and Applications*, 2024(32), 1-22.
- [25] ZHAO Y, LYU W, XU S, et al. Detrs beat yolos on real-time object detection [C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024: 16965-16974.
- [26] CHU X, LI L, ZHANG B. Make repvgg greater again: a quantization-aware approach [C]// *Proceedings of the AAAI Conference on Artificial Intelligence*, 2024: 11624-11632.
- [27] WANG X, ZHANG S, YU Z, et al. Scale-equalizing pyramid convolution for object detection[C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020: 13359-13368.
- [28] 蔡伟,王鑫,蒋昕昊,等.基于解耦的小样本目标检测方法研究[J/OL]. *系统工程与电子技术*, (2023-10-25)[2024-06-14]. <http://kns.cnki.net/kcms/detail/11.2422.tn.20231103.1035.010.html>.
- CAI W, WANG X, JIANG X H, et al. Research on few shot target detection method based on decoupling[J/OL]. *Systems Engineering and Electronics*, (2023-10-25)[2024-06-14]. <http://kns.cnki.net/kcms/detail/11.2422.tn.20231103.1035.010.html>.
- [29] 张光华,李聪发,李钢硬,等.基于改进YOLOv7-tiny的无人机航拍图像小目标检测算法[J/OL]. *工程科学与技术*, (2024-01-14)[2024-06-14]. <https://doi.org/10.15961/j.jsuese.202300593>.
- ZHANG G H, LI C F, LI G Y, et al. Small target detection algorithm for UAV aerial images based on improved YOLOv7-tiny[J/OL]. *Advanced Engineering Sciences*, (2024-01-14)[2024-06-14]. <https://doi.org/10.15961/j.jsuese.202300593>.
- [30] ZHENG Z, WANG P, LIU W, et al. Distance-IoU loss: faster and better learning for bounding box regression [C]// *Proceedings of the AAAI conference on artificial intelligence*, 2020: 12993-13000.
- [31] ZHENG Y, ZHANG X, WANG F, et al. Detection of people with camouflage pattern via dense deconvolution network[J]. *IEEE Signal Processing Letters*, 2018, 26(1): 29-33.

(上接第23页)

- [11] 邱凌,张安思,张羽,等.面向无人机故障诊断的知识图谱构建应用方法[J]. *计算机工程与应用*, 2023, 59(9): 280-288.
- QIU L, ZHANG A S, ZHANG Y, et al. Application method of building Knowledge graph for UAV fault diagnosis[J]. *Computer Engineering and Applications*, 2023, 59(9): 280-288.
- [12] 马玉凤,豆亚杰,徐向前,等.知识图谱辅助的复杂装备需求感知开发研究[J]. *系统工程学报*, 2023, 38(2): 186-194.
- MA Y F, DOU Y J, XU X Q, et al. Knowledge graph-aided requirements-aware development of complex equipment[J]. *Journal of Systems Engineering*, 2023, 38(2): 186-194.
- [13] 黄英双,曹辉.改进人工蜂群算法优化支持向量机及应用[J]. *计算机应用与软件*, 2021, 38(2): 258-263, 277.
- HUANG Y S, CAO H. Improved artificial bee colony algorithm for optimizing support vector machines and their applications[J]. *Computer Applications and Software*, 2021, 38(2): 258-263, 277.
- [14] 战欣,刘卓娅.基于PSO-SES-BPNN算法的液压系统故障诊断模型[J]. *兵器装备工程学报*, 2023, 44(4): 172-178.
- ZHAN X, LIU Z Y. Hydraulic system fault diagnosis model based on PSO-SES-BPNN algorithm[J]. *Journal of Ordnance Equipment Engineering*, 2023, 44(4): 172-178.