

# 航空发动机的多参数快速故障诊断模型<sup>\*</sup>

牛 伟<sup>1</sup>, 王国庆<sup>1, 2</sup>, 翟正军<sup>1</sup>, 成 娟<sup>3</sup>, 郭阳明<sup>1</sup>

(1. 西北工业大学 计算机学院, 西安 710072; 2. 中国航空无线电电子研究所, 上海 200233; 3. 西安应用光学研究所, 西安 710065)

**摘 要:** 为了提高诊断效率, 降低故障诊断对人的过分依赖, 建立了一个航空发动机故障快速诊断模型。该模型结合粗糙集和灰色理论各自特点, 利用粗糙集去除特征信息中的冗余信息; 再通过多参数灰色模型对约简后的信息进行快速准确的预测。仿真对比表明, 该模型在不降低预测精度的情况下能显著减少计算时间, 有效提高故障预测的快速性和实时性。

**关键词:** 粗糙集; GM(1, 1) 模型; 多参数; 故障诊断; 航空发动机

**中图分类号:** TP301.6      **文献标志码:** A      **文章编号:** 1001-3695(2011)12-4564-03

**doi:** 10.3969/j.issn.1001-3695.2011.12.044

## Multi-parameter fast fault diagnosis model of aeroengine

NIU Wei<sup>1</sup>, WANG Guo-qing<sup>1, 2</sup>, ZHAI Zheng-jun<sup>1</sup>, CHENG Juan<sup>3</sup>, GUO Yang-ming<sup>1</sup>

(1. College of Computer, Northwestern Polytechnical University, Xi'an 710072, China; 2. Chinese Aeronautical Radio Electronics Research Institute, Shanghai 200233, China; 3. Xi'an Institute of Applied Optics, Xi'an 710065, China)

**Abstract:** For the sake of improving efficiency of diagnosis and lowering the dependency of manual labor, this paper proposed a fast fault diagnosis model of aeroengine. The model combined characteristics of rough sets and grey theory. Redundant information was eliminated from feature information by rough sets, and then the reduction information was quickly and accurately predicted by multi-parameter grey model. The simulation results show preliminarily that the model saves the computing time greatly and can effectively meet the requirements of fast and real-time fault prediction while precision is not reduced.

**Key words:** rough set; GM(1, 1) model; multi-parameter; faults diagnosis; aeroengine

## 0 引言

航空发动机是非常昂贵且复杂的设备, 因其复杂的结构及高速的恶劣工作环境, 可靠性很难保证, 发生故障后可能引发飞行事故, 后果严重。因此, 对于它进行及时的状态监测和故障诊断具有非常重大的实际意义。航空发动机快速故障诊断是保证发动机安全工作、延长发动机使用寿命的一种重要技术措施。

航空发动机故障诊断需要在发动机运行过程中连续监测多个参数, 参数本身的值及相对之间的变化关系分别对应着发动机的诸多状态。其对应关系非常复杂, 很难用函数关系描述, 可以用基于知识的方法来解决。对于航空发动机的多数故障而言, 故障样本的数目极其有限, 属于典型的小样本集问题。对故障诊断来说, 提取的故障特征信息越多, 对故障的诊断就越准确。然而提取的特征信息过多, 会产生冗余甚至相互矛盾, 这会对后续的诊断预测带来困难。

由于以上问题的存在, 故障树<sup>[1]</sup>、专家系统<sup>[2]</sup>、神经网络小波包<sup>[3, 4]</sup>等人工智能技术的故障预测方法虽然在航空发动

机故障诊断中发展较快, 但由于实际中各类故障样本难以获得等原因, 其应用往往受到限制。粗糙集是一种处理不精确、不确定与不完全的数学方法, 在数据约简、特征提取等方面功效显著<sup>[5]</sup>。灰色预测模型是以小样本不确定性系统为研究对象, 需求样本少、其计算量小、预测精度高, 是一种较为理想的状态预测模型<sup>[6]</sup>。

本文将粗糙集和灰色预测模型相结合, 建立了一种在小样本情况下的多参数故障预测模型。利用粗糙集进行特征信号约简, 再利用灰色模型对约简后的特征信号进行预测。通过以某型号发动机转子多特征信息的仿真数据为例, 该模型可以有效解决故障预测过程中计算负荷过大的问题, 在保证预测精度的情况下, 能较好地满足故障诊断的快速性要求。

## 1 基于粗糙集的属性约简

由于粗糙集理论只能对离散数据进行分析, 实际故障诊断中采集的特征信息多是连续的, 所以要对输入数据进行离散化处理<sup>[7, 8]</sup>。

对决策表的化简可通过决策表的条件属性构造可辨识矩

收稿日期: 2011-06-20; 修回日期: 2011-07-24      基金项目: 航空科学基金资助项目(2010ZD53039); 陕西省自然科学基金资助项目(2010HQ8005)

作者简介: 牛伟(1982-), 男, 河南洛阳人, 博士研究生, 主要研究方向为智能信息处理、可靠性和容错技术等(weiniu@126.com); 王国庆(1956-), 男, 陕西人, 博导, 双博士, 主要研究方向为 PHM、嵌入式系统; 翟正军(1965-), 男, 河南人, 教授, 主要研究方向为电子测试、虚拟现实及预测技术; 成娟(1982-), 女, 河南济源人, 工程师, 硕士, 主要研究方向为测控系统集成、半实物仿真等; 郭阳明(1978-), 男, 陕西人, 讲师, 博士, 主要研究方向为智能信息处理等。

阵  $S_D(i, j)$  来实现。可辨识  $n \times n$  矩阵  $S_D$  中的第  $i$  行第  $j$  列的元素定义为<sup>[9, 10]</sup>:

$$S_D(i, j) = \begin{cases} \{a_k | a_k \in C \wedge a_k(x_i) \neq a_k(x_j) & d(x_i) \neq d(x_j)\} \\ 0 & d(x_i) = d(x_j) \end{cases} \quad (1)$$

其中:  $a_k$ 、 $d$  是条件属性  $C$  和决策属性  $D$  子集中的元素。

用可辨识矩阵  $S_D$  中的所有非空集合元素  $S_{ij}$  建立相应的析取逻辑表达式  $Q_{ij}$ , 即

$$Q_{ij} = \bigcup_{a_i \in S_{ij}} a_i \quad (2)$$

将所有析取逻辑表达式  $Q_{ij}$  进行合取运算, 得到一个合取范式  $\delta$ , 即

$$\delta = \bigcap_{S_{ij} \neq \emptyset} Q_{ij} \quad (3)$$

每个合取项包含的属性组成约简后的条件属性集合, 从而获得决策表的核值表。

## 2 多参数预测模型

### 2.1 GM(1, 1) 模型

设有原始数据  $X^{(0)} = \{x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(m)\} (i = 1, 2, \dots, m)$ , 则  $X^{(0)}$  的 1-AGO 序列为

$$X^{(1)} = \{x^{(1)}(1), x^{(1)}(2), \dots, x^{(1)}(m)\}$$

其中:  $x^{(1)}(k) = \sum_{i=1}^k x^{(0)}(i)$ ,  $k = 1, 2, \dots, m$ ;  $X^{(1)}$  的紧邻均值生成序列为

$$Z^{(1)} = \{z^{(1)}(2), z^{(1)}(3), \dots, z^{(1)}(m)\}$$

其中:  $z^{(1)}(k) = (x^{(1)}(k) + x^{(1)}(k-1))/2$ ,  $k = 2, 3, \dots, m$ 。

GM(1, 1) 模型  $x^{(0)} + ax^{(1)} = b$  对应的白化方程为

$$\frac{dx^{(1)}}{dt} + ax^{(1)} = b \quad (4)$$

其中: 参数  $a$  和  $b$  的值可由最小二乘法辨识得到, 即

$$\hat{a} = [a \ b]^T = (B^T B)^{-1} B^T Y \quad (5)$$

$$\text{其中: } B = \begin{bmatrix} -z^{(1)}(2) & 1 \\ -z^{(1)}(3) & 1 \\ \vdots & \vdots \\ -z^{(1)}(m) & 1 \end{bmatrix}, Y = \begin{bmatrix} x^{(0)}(2) \\ x^{(0)}(3) \\ \vdots \\ x^{(0)}(m) \end{bmatrix}.$$

模型响应函数为

$$\hat{x}^{(1)}(k+1) = (x^{(0)}(1) - \frac{b}{a})e^{-ak} + \frac{b}{a} \quad k = 1, 2, \dots, m \quad (6)$$

利用  $\hat{x}^{(0)}(k+1) = \hat{x}^{(1)}(k+1) - \hat{x}^{(1)}(k)$  生成预测值

$$\hat{x}^{(0)}(k+1) = (1 - e^a)(x^{(0)}(1) - \frac{b}{a})e^{-ak} \quad k = 1, 2, \dots, m \quad (7)$$

### 2.2 多参数预测模型

GM(1, 1) 模型具有数据样本少、不考虑分布规律、不考虑变化趋势、运算方便、短期预测精度高、易于检验等优点, 因此得到广泛应用<sup>[11, 12]</sup>, 但它也存在一定的局限性。GM(1, 1) 模型的建模方法存在以下不足:

a) 初始条件选择历史数据中第 1 个数据, 在累加生成建模时, 没有起到加强精度预测作用。

b) GM(1, 1) 模型仅利用单一的时间序列数据, 无法反映多个参数间的相互影响等问题。

c) GM(1, 1) 模型的预测精度取决于参数  $a$  和  $b$ , 而  $a$  和  $b$  的值依赖于原始序列和背景值的构造形式。

针对以上问题, 参照 GM(1, 1) 预测建模的思想, 本文也采用生成数列的方法建立多参数预测模型, 并且重构了白化背景值和初始条件。

令  $\{x_i^{(0)}(k)\} (i = 1, 2, \dots, n)$  为粗糙集约简后的  $n$  个特征参数序列,  $x_i^{(1)}(k)$  为相应的一次累加生成序列, 构造  $n$  元一阶常微分方程组:

$$\begin{cases} \frac{dx_1^{(1)}}{dt} = a_{11}x_1^{(1)} + a_{12}x_2^{(1)} + \dots + a_{1n}x_n^{(1)} + b_1 \\ \frac{dx_2^{(1)}}{dt} = a_{21}x_1^{(1)} + a_{22}x_2^{(1)} + \dots + a_{2n}x_n^{(1)} + b_2 \\ \vdots \\ \frac{dx_n^{(1)}}{dt} = a_{n1}x_1^{(1)} + a_{n2}x_2^{(1)} + \dots + a_{nn}x_n^{(1)} + b_n \end{cases} \quad (8)$$

记

$$X^{(0)}(k) = (x_1^{(0)}(k), x_2^{(0)}(k), \dots, x_n^{(0)}(k))^T$$

$$X^{(1)}(k) = (x_1^{(1)}(k), x_2^{(1)}(k), \dots, x_n^{(1)}(k))^T$$

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}, B = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

目前, 针对背景值改进有很多方法, 预测精度也得到了不同程度的提高<sup>[13-15]</sup>。本文参考文献[14]将背景值  $z^{(1)}(k) = (x^{(1)}(k) + x^{(1)}(k-1))/2$  优化为

$$z_i^{(1)}(k) = (x_i^{(1)}(k) + x_i^{(1)}(k-1)) / (\ln x_i^{(1)}(k) - \ln x_i^{(1)}(k-1)) \quad (9)$$

其中:  $x_i^{(1)}(k) = x_i^{(1)}(k-1)$  时,  $z_i^{(1)}(k) = x_i^{(1)}(k-1) (i = 1, 2, \dots, n; k = 2, 3, \dots, m)$ 。

记  $a_i = (a_{i1}, a_{i2}, \dots, a_{in}, b_i)^T (i = 1, 2, \dots, n)$ , 则由最小二乘法得到  $a_i$  的辨识值  $\hat{a}_i$  为

$$\hat{a}_i = [\hat{a}_{i1}, \hat{a}_{i2}, \dots, \hat{a}_{in}, \hat{b}_i]^T = (L^T L)^{-1} L^T Y_i \quad i = 1, 2, \dots, n \quad (10)$$

其中

$$L = \begin{bmatrix} z_1^{(1)}(2) & z_2^{(1)}(2) & \dots & z_n^{(1)}(2) & 1 \\ z_1^{(1)}(3) & z_2^{(1)}(3) & \dots & z_n^{(1)}(3) & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ z_1^{(1)}(m) & z_2^{(1)}(m) & \dots & z_n^{(1)}(m) & 1 \end{bmatrix}, Y_i = \begin{bmatrix} x_i^{(0)}(2) \\ x_i^{(0)}(3) \\ \vdots \\ x_i^{(0)}(m) \end{bmatrix}$$

将  $\hat{a}_i$  代入  $A$  和  $B$ , 可得到  $A$  和  $B$  的辨识值。

从故障诊断以往的经验可知, 赋予新信息较大的权重可以提高预测的精确度。因此, 本文将终点  $x_i^{(0)}(m)$  作为初始条件, 则多参数预测模型的计算值 ( $k = 2, 3, \dots, m$ ) 为

$$\begin{cases} \hat{X}^{(1)}(k) = e^{\hat{A}(k-m)} X^{(1)}(m) + \hat{A}^{-1}(e^{\hat{A}(k-m)} - m) \hat{B} \\ \hat{X}^{(0)}(k) = \hat{X}^{(1)}(k) - \hat{X}^{(1)}(k-1) \end{cases} \quad (11)$$

### 2.3 模型精度检验

以模型的预测平均相对误差作为模型精度检验的标准, 即

$$\sigma = \frac{\sum_{i=1}^n \sum_{k=1}^m |(X_i^{(0)}(k) - \hat{X}_i^{(0)}(k)) / X_i^{(0)}(k)|}{nm} \quad (12)$$

### 2.4 预测步骤

由此得到本文多参数快速预测模型的预测步骤描述如下:

a) 样本数据离散化计算可辨识矩阵  $M$ , 基于粗糙集属性约简, 获得最小属性集。

b) 利用历史数据分别构建最小属性集中元素  $x_i^{(0)}(k) (i =$

- 1 2 ,⋯) 进行累加生成 ,得到  $x_i^{(1)}(k)$  。
- c) 根据式 (9) 和 (10) 计算背景值  $z_i^{(1)}(k)$ 、参数  $A$  和  $B$  的值。
- d) 选取初始条件 ,由式 (11) 建立预测公式 ,得到多参数预测模型。
- e) 再根据式 (12) 计算模型的拟合精度  $\sigma$ 。

3 仿真分析

本文以某型号飞机地面定检状态下发动机数据为例 ,分两种情况验证本文模型的有效性。

地面定检状态下的发动机故障诊断模型可用下列非线性方程描述<sup>[16]</sup>：

$$y=f(T,N,P,B) \tag{13}$$

其中:  $T$  为进口总温;  $N$  为高压转子转速;  $P$  为滑油压力;  $B$  为发动机机匣振动值。令输出  $y=1$  表示发动机工作状况正常 , $y=0$  表示发动机存在故障。数据样本如表 1 所示。

表 1 某型号发动机诊断数据

No	$T$	$N$	$P$	$B$	$Y$
1	-2.000	105.2	3.65	35.00	0
2	4.000	86.0	2.80	10.00	0
3	14.740	98.9	2.75	6.86	1
4	14.000	97.0	2.9	25.00	0
5	15.000	100.0	3.8	10.00	0
6	18.000	78.5	2.80	23.00	0
7	19.270	99.2	3.02	16.57	1
8	19.707	99.2	3.02	15.30	1
9	6.000	98.5	2.68	9.42	1
10	23.530	99.9	2.82	18.02	1
11	24.00	102.9	2.40	3.20	0
12	18.76	98.7	2.84	16.54	1
13	25.00	73.0	2.60	22.00	0
14	28.00	97.0	1.40	50.00	0
15	30.00	99.0	2.56	10.00	0
16	40.00	87.5	3.56	25.00	0
17	5.600	98.5	2.70	8.85	1
18	16.080	100.9	2.97	16.17	1
19	15.220	101.0	3.05	16.26	1
20	6.000	86.5	2.60	50.00	0

表 1 中每个属性都是连续化的 ,因此需要离散化处理 ,利用 SOM 神经网络对连续变化的数据进行离散化处理 ,并合并具有相同属性值的对象 ,如表 2 所示。

表 2 离散后数据样本

No	$T(a)$	$N(b)$	$P(c)$	$B(d)$	$Y$
1(2)	0	2	2	1	0
2(2)	0	0	1	1	0
3(1)	0	1	1	0	1
4(1)	1	0	1	1	1
5(2)	1	1	1	1	0
6(1)	1	2	0	0	0
7(2)	1	0	0	1	0
8(4)	1	0	2	1	1
9(2)	1	1	0	1	0
10(3)	1	2	1	1	1

根据可辨识矩阵的属性约简算法 ,计算出可辨识矩阵

$$M_{10 \times 10} = \begin{bmatrix} - & bcd & - & abc & - & - & - & - & ac & - \\ - & bd & - & ab & - & - & - & - & ab & - \\ - & - & abd & - & abc & abcd & acd & abcd & - & bcd \\ - & - & - & - & - & - & - & - & b & - \\ - & - & - & b & bcd & bc & c & bc & - & abc \\ - & - & - & - & - & - & - & - & cd & - \\ - & - & - & - & - & - & - & - & bc & - \\ - & - & - & - & - & - & - & - & bc & - \\ - & - & - & - & - & - & - & - & bc & abc \\ - & - & - & - & - & - & - & - & - & - \end{bmatrix}$$

通过计算得出 $\{N,P\}$  为诊断决策表的最小属性集。因此 ,采用粗糙集约简后 ,删除了进口总温、发动机机匣振动值两个属性 ,只需对高压转子转速、滑油压力进行预测 ,减少了建模复杂度。因此 ,本文选取采样时间间隔、进口总温、高压转子转速、滑油压力和发动机机匣振动值 10 组连续仿真数据 ,分别从预测精度和预测时间两方面验证模型的有效性。原始数据如表 3 所示。

表 3 原始数据

No	$t$	$T$	$N$	$P$	$B$
	$x_1^{(0)}(k)$	$x_2^{(0)}(k)$	$x_3^{(0)}(k)$	$x_4^{(0)}(k)$	$x_5^{(0)}(k)$
1	6.07	18.81	100.09	5.69	20.99
2	6.53	19.18	99.99	6.05	20.65
3	7.56	20.28	98.77	4.53	19.51
4	7.03	19.63	98.26	4.96	18.52
5	8.76	21.75	97.51	3.59	18.44
6	8.14	23.75	97.06	4.07	18.19
7	9.43	22.89	95.76	2.96	17.91
8	10.15	24.50	96.17	2.87	16.96
9	9.91	25.75	94.91	2.34	16.82
10	10.52	25.27	93.72	2.55	15.58

仿真 1 比较 GM(1,1) 模型和本文模型的预测精度。利用表 3 中前 8 组数据建立原 GM(1,1) 模型和本文模型 ,后两组数据用于预测检验 ,拟合和预测情况如表 4 所示 ,表中  $\hat{t}$ 、 $\hat{N}$ 、 $\hat{P}$  表示  $t$ 、 $N$ 、 $P$  的估计值;  $\varepsilon$  表示相对误差(%)。

表 4 GM(1,1)模型与本文模型的拟合值及相对误差

No	GM(1,1)模型						本文模型					
	$\hat{t}$	$\varepsilon$	$\hat{N}$	$\varepsilon$	$\hat{P}$	$\varepsilon$	$\hat{t}$	$\varepsilon$	$\hat{N}$	$\varepsilon$	$\hat{P}$	$\varepsilon$
1	6.07	0	100.09	0	5.69	0	6.2837	3.52	100.6005	0.51	5.8089	2.09
2	6.6265	1.48	99.6616	0.33	5.7560	4.86	6.5875	0.88	102.1098	2.12	6.2714	3.66
3	7.0985	6.10	98.9818	0.21	5.1102	12.81	7.8382	3.68	102.1084	3.38	4.7080	3.93
4	7.6042	8.17	98.3067	0.05	4.5368	8.53	7.2184	2.68	102.7505	4.57	5.1123	3.07
5	8.1460	7.01	97.6362	0.13	4.0277	12.19	9.0500	3.31	99.5967	2.14	3.6758	2.39
6	8.7263	7.20	96.9702	0.09	3.5758	12.14	8.4770	4.14	100.3406	3.38	4.2963	5.56
7	9.348	0.87	96.3088	0.57	3.1746	7.25	9.8402	4.35	97.9912	2.33	3.0766	3.94
8	10.0139	1.34	95.6519	0.54	2.8184	1.80	10.5002	3.45	98.2857	2.20	2.9380	2.37
9	10.7273	8.25	94.9995	0.09	2.5022	6.93	10.1607	2.53	98.2888	3.56	2.3903	2.15
10	11.4915	9.23	94.3516	0.67	2.2214	12.89	10.7430	2.12	96.7940	3.28	2.6293	3.11

从表 4 中可以看出 ,GM(1,1) 模型三个参数的平均相对误差为 4.39%; 而本文模型的平均相对误差仅为 3.01%。因此 ,本文所提出的多参数模型相对 GM(1,1) 模型具有更高的拟合和预测精度。

仿真 2 比较 GM(1,1) 模型和本文模型的故障预测时间。GM(1,1) 模型直接对所有特征参数集进行预测; 本文模型对经粗糙集约简后的特征参数集进行预测 ,比较两者的计算占用时间和平均相对误差 ,结果如表 5 所示。

表 5 计算占用时间和诊断正确率

模型	计算占用时间/s	诊断正确率/%
GM(1,1) 模型	1.56	91.39
本文模型	0.97	93.01

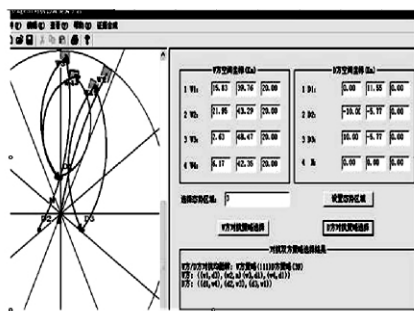


图6 多agent群体对抗策略选择的仿真实验平台

#### 4 结束语

针对多 agent 群体对抗场景的动态性和对抗策略选择的复杂性,本文提出了多 agent 群体对抗场景划分识别的新方法,构建了多 agent 群体对抗的相关规则和模型,根据对抗态势和对抗规则,运用证据理论对 agent 个体的空间位置参数、传感器与执行器进行证据合成,形成 agent 个体对抗有效性的证据。利用多属性决策综合对抗双方证据选取最佳对抗策略对,执行双方对抗动作任务并在 Visual C++6.0 环境下进行了仿真实验。至于考虑 agent 传感器和执行器的重要程度及单个 agent 有效性的权重反馈对策略选择和对抗效能的影响是今后进一步研究的课题。

##### 参考文献:

- [1] 刘大有,杨鲲,陈建中. Agent 研究现状和发展趋势[J]. 软件学报 2000, 11(3): 315-321.
- [2] 姚宏亮,王秀芳,胡大伟,等. 多 agent 动态影响图的一种混合近似推理算法[J]. 计算机研究与发展 2011, 48(4): 584-591.
- [3] LESSER V, ORTIZ C L, TAMBE M *et al.* Distributed sensor & networks: a multi agent perspective[M]. [S. l.]: Kluwer Academic Publishers 2003.
- [4] PARUCHURI P, TAMBE M, ORDONEZ F *et al.* Towards a formalization of teamwork with resource constraints[C]//Proc of the 3rd International Joint Conference on Autonomous Agents and Multi-Agent Systems. 2004: 596-603.
- [5] 王璐,陆筱霞,蔡自兴. 基于局部显著区域的自然场景识别[J]. 中国图象图形学报 2008, 13(8): 1594-1600.
- [6] 李桂芝,安成万,杨国胜,等. 基于场景识别的移动机器人定位方法研究[J]. 机器人 2005, 27(3): 123-127.
- [7] YANG Wen, DAI Deng-xin, TRIGGS B *et al.* Fast semantic scene segmentation with conditional random field [C]//Proc of the 17th IEEE International Symposium on Image Processing. 2010: 229-232.
- [8] YAN Song, OGAWA T, HASEYAMA M. MCMC-based scene segmentation method using structure of video[C]//Proc of International Symposium on Communications and Information Technologies. 2010: 862-866.
- [9] QIN Hong-wu, JASNI M Z, MA Xiu-qin *et al.* Scene segmentation based on seeded region growing for foreground detection[C]//Proc of the 6th International Conference on Natural Computation. 2010: 3619-3623.
- [10] 杨善林,罗贺,胡小建. 基于焦元相似度的证据理论合成规则[J]. 模式识别与人工智能 2009, 22(2): 169-175.
- [11] 付超,杨善林,罗贺. 异源证据间的一致度分析[J]. 系统工程理论与实践 2009, 29(5): 166-174.
- [12] 周迪民,段国云. 证据理论在不确定性推理中的应用研究[J]. 计算机应用研究 2010, 27(12): 4433-4435.
- [6] LIU Si-feng, LIN Y. Grey information theory and practical applications [M]. London: Springer-Verlag, 2006.
- [7] 梅检民,周斌,司爱威,等. 基于变精度粗糙集理论提取发动机振动故障特征[J]. 军事交通学院学报 2009, 11(3): 43-47.
- [8] FRABCI S E, SHEN Li-xiang. Fault diagnosis based on rough set theory[J]. Engineering Applications of Artificial Intelligence 2003, 16(1): 39-43.
- [9] SWINIARSKI R W, SKOWRON A. Rough set methods in feature selection and recognition[J]. Pattern Recognition Letters 2003, 24(6): 833-849.
- [10] 张喜斌,成立,余江民. 基于一种新型粗糙集神经网络的故障诊断[J]. 计算机应用研究 2006, 23(5): 156-158.
- [11] LI Guo-dong, WANG Chen-hong, MASUDA S *et al.* A research on short term load forecasting problem applying improved grey dynamic model[J]. International Journal of Electrical Power & Energy Systems 2011, 33(4): 809-816.
- [12] LI D C, YE H C W, CHANG C J. An improved grey-based approach for early manufacturing data forecasting[J]. Computers and Industrial Engineering 2009, 57(4): 1161-1167.
- [13] 李福琴,刘建国. 数据变换提高灰色预测模型精度的研究[J]. 统计与决策, 2008, 6(6): 15-17.
- [14] 罗党,刘思峰,党耀国. 灰色模型 GM(1,1) 优化[J]. 中国工程科学 2003, 15(18): 50-54.
- [15] LIN Yong-huang, LEE P C. Novel high-precision grey forecasting model[J]. Automation in Construction 2007, 16(6): 771-777.
- [16] 王广,李军. 基于粗糙集理论的航空发动机故障诊断[J]. 航空发动机 2005, 31(4): 51-53.

(上接第4566页)

由表 5 可以看出,在相同的仿真条件下,本文模型不但保证了故障诊断正确率,而且在快速性和实时性方面明显优于 GM(1,1) 模型。

#### 4 结束语

本文结合粗糙集和灰色理论的各自特点,提出了一种小样本情况下的多参数故障快速预测模型。通过实验对比证明,该模型在保证预测准确度的前提下,能较有效地解决故障预测过程中计算负荷过大的问题,大大提高了故障诊断的快速性。

##### 参考文献:

- [1] 柳爱利,施建洪,寇昆湖. 诊断反舰导弹故障模式的故障诊断法运用[J]. 海军航空工程学院学报 2008, 23(2): 231-233.
- [2] XU Dong, WU Mei, AN Jin-wen. Design of an expert system based on neural network ensembles for missile fault diagnosis [C]//Proc of IEEE International Conference on Robotics, Intelligent Systems and Signal Processing. 2003: 903-908.
- [3] 梁瑞胜,孙有田,周希亚. 小波包变换和神经网络的某型导弹故障诊断方法研究[J]. 海军航空工程学院学报 2008, 23(2): 217-220.
- [4] WU Jian-da, LIU Chiu-hong. Investigation of engine fault diagnosis using discrete wavelet transform and neural network[J]. Expert Systems with Applications 2008, 35(3): 1200-1213.
- [5] 王国胤. Rough 集理论与知识获取[M]. 西安: 西安交通大学出版社 2001.