

通航飞机起落架系统故障频率预测研究*

丰世林¹, 张中波¹, 杜仲²

(1. 中国民航飞行学院 航空工程学院, 四川 广汉 618307; 2. 中国民航飞行学院 遂宁分院, 四川 遂宁 629000)

摘要: 文章研究起落架系统发生故障的频率, 变事后维修为预防维修, 尽可能保证飞行安全。因此提出一种采用模糊信息粒化和支持向量机相融合的时序回归预测技术来预测起落架系统故障发生频率。以某型通航飞机2012年1月至2016年12月的起落架故障数据为基础, 根据该模型输入数据并进行故障频率预测。预测结果表明, 采用该方法预测起落架故障频率合理有效, 根据该预测结果可得到起落架故障频率的变化趋势和变化空间, 并为机务维修提供技术支持。

关键词: 支持向量机; 信息粒化; 起落架系统; 故障频率预测

中图分类号: TH165; TG506

文献标识码: A

The Failure Frequency Prediction Research of the General Aviation Aircraft's Landing Gear System

FENG Shi-lin¹, ZHANG Zhong-bo¹, DU Zhong²

(1. Aviation Engineer Institute, The Civil Aviation Flight University of China, Guanghan Sichuan 618307, China; 2. Suining Subcollege, The Civil Aviation Flight University of China, Suining Sichuan 629000, China)

Abstract: This paper research on the failure frequency prediction of the general aviation aircraft's landing system. Change the break down maintenance to preventive maintenance. As far as possible to ensure flight safety. So, based on the information granulation and the Support Vector Machine's method, put forward a time series regression forecasting technology to predict the landing gear's failure frequency. Based on the landing gear failure frequency data from Jan 2012 to Dec 2016, according to the model input data and forecast in real time. According the prediction results, show that using the technology to predict the landing gear's failure frequency is reasonable and effective. According to the prediction results, come out the trends and space of the failure frequency of the landing gear, provide technical support to the aircraft maintenance.

Key words: the support vector machine; information granulation; the landing gear system; failure frequency forecast

0 引言

在民航界, 据统计 70% 的重大事故发生在起飞 (3min) 着陆 (8min) 阶段, 所以被称为危险的 11min^[1]。在这 11min 内, 起飞和着陆都主要取决于起落架的工作状态, 所以起落架的正常工作显得尤为重要。如果起落架系统工作不良, 就会严重影响飞机的安全。

要准确预测起落架故障的发生, 难点在于获得传感器采集的基础数据。民航干线运输机如波音空客飞机传感器多, 类型多, 但波音空客公司都没有把基础数据公开; 通航飞机传感器很少, 类型少, 能够采集并用于故障分析的数据更少。即使获得一定的基础数据, 在后续数据处理过程中比如起落架故障特征参数提取、故障诊断算法、故障预测技术等都具有很强的模糊性和不确定性。

国外比如波音公司和空客公司都有针对各自飞机起落架的健康监测系统。但在国内的研究比较滞后。王红等在 172R 型飞机前起落架减震支柱故障诊断方面提出改进设计^[1], 郑永安等采用鲁棒故障诊断方法对国产某型飞机起落架防滑刹车系统进行分析^[2]。陈新霞等采用基于贝叶斯网络推理的方法进行起落架系统故障诊断技术研究^[3]。常浩等在某型飞机起落架故障诊断专家系统设计方面做了一定研究^[4]。综合上述研究成果发现国内针对整个飞机起落架系统的故障诊断和故障预测系统的研究还比较薄弱。

近年来, 基于人工智能技术的故障诊断和故障预测方法发展迅猛, 支持向量机技术最初应用于模式识别领域。后发现支持向量机在解决小样本、非线性及高维模式识别问题中表现出许多特有的优势。它根据有限的样本信息在模型的复杂性和学习能力之间寻

收稿日期: 2017-12-07; 修回日期: 2018-01-19

* 基金项目: 民航局科技创新引导资金项目 (C2013064); 民航局民航教育人才类项目 (J166); 2016 年中央高校教育教学改革专项基金 (E20160402); 四川省教育厅重点项目 (16ZA0020); 中国民航飞行学院项目 (J2015-21); 中国民航飞行学院创新团队计划项目 (XM2732)

作者简介: 丰世林 (1976—), 男, 四川泸州人, 中国民航飞行学院副教授, 研究方向为民用飞机系统故障诊断技术, (E-mail) fengshilin95@sohu.com。

求最佳折衷,以获得最好的推广能力。如应用于给水泵等机电设备的故障预测中^[5-6]。

综上所述,本文提出一种采用模糊信息粒化和支持向量机相融合的时序回归预测技术来预测起落架系统故障发生频率。以某型通航飞机 2012 年 1 月至 2016 年 12 月起落架故障数据为基础,根据该模型输入数据并进行故障频率预测。预测结果表明,采用该方法预测起落架故障频率合理有效,根据该预测结果可得到起落架故障频率的变化趋势和变化空间,并为该机型机务维修提供技术支持。

2 民航飞机起落架系统故障频率预测模型

根据波音公司和空客公司的健康管理相关资料分析^[7-8],完整的起落架故障频率预测主要步骤为:

(1) 数据采集:多种传感器、据采集卡植入飞机的起落架系统完成数据采集、转换及传输。

(2) 数据预处理:根据传感器和数据采集卡提供的的数据,重新过滤筛选。

(3) 状态监测:将预处理后的数据同期望的数据值进行比较进而判断系统的状态。

(4) 故障诊断:根据预处理后的数据完成评估被监测系统/分系统/部件的健康状态。

(5) 故障预测:综合利用前述各部分的数据信息,评估预测被监测系统的未来健康状态。

(6) 保障支持:根据健康评估和预测模块的数据产生更换、维修活动的建议措施等,可在被监测系统发生故障前采取维修措施。

(7) 数据综合显示及传输:对前述各模块的数据信息的显示;并传递给其它相关系统。

要进行民航飞机起落架故障频率,难点在于先要获得传感器采集的基础数据,这些数据都汇集到波音公司和空客公司没有公开。另一难点是后续数据处理过程中如健康状态特征参数提取、故障诊断算法、故障预测技术、健康管理决策等都具有很强的模糊性和不确定性。

因此本文提出一种采用模糊信息粒化和支持向量机相融合的时序回归预测技术来预测起落架系统故障发生频率。模糊信息粒化技术可以根据预测的需要把相应的时间段的数据作为一个信息粒来进行研究。通过信息粒化技术来提取各个信息粒的有效信息;民用飞机起落架系统故障频率预测有时不仅需要预测系统下一个时刻的状态,还需要预测未来一段时期内的状态。信息粒恰好在处理模糊的、不完整的、不精确的和不确定性的数据挖掘等方面具有突出的优势,它可忽略掉一个区间内无关紧要的细节,同时能够很好地表征区间的特性,从而掌握系统未来状态的发展趋势和变化空间^[7-11]。利用支持向量机技术在解决小样本、非线性及高维模式识别问题中表现出许多特有的优势。

3 模糊信息粒化和支持向量机相融合的时序回归预测技术

3.1 模糊信息粒化

模糊信息粒化由美国数学家 L A Zadeh 于 1979 年

提出并给出命题描述^[9-10]。

$$g \triangleq (x \text{ is } G) \text{ is } \lambda$$

模糊信息粒就是用模糊集方法对时间序列进行模糊化来表示信息粒,包括划分窗口和模糊化。

常用的模糊粒子有三角型、梯形、高斯型、抛物型等。本文采用三角型,其隶属度函数为:

$$A(x, a, m, b) = \begin{cases} 0, & x < a \\ \frac{x-a}{m-a}, & a \leq x \leq m \\ \frac{b-x}{b-m}, & m \leq x \leq b \\ 0, & x > b \end{cases} \quad (1)$$

本文采用 W Predrycz 模糊粒化方法,模糊粒子能够合理地代表原始数据,同时要有一定的特殊性^[11-12]。其计算公式如下:

$$Q_A = \frac{M_A}{N_A} = \frac{\sum_{x \in X} A(x)}{\text{measure}(\text{supp}(A))} \quad (2)$$

(1) 求解三角形模糊集的核 C_2

将时间序列 $X = \{x_1, x_2, \dots, x_n\}$ 按照升序的顺序重新排列为: $X' = \{x'_1, x'_2, \dots, x'_N\}$ 。求序列的中值 C_2 。

(2) 求解三角形模糊集的支撑下界 C_1 。

$$\max Q(C_1) = \frac{\sum_{x_i \leq C_2} A(X_k)}{C_2 - C_1} \quad (3)$$

(3) 求解三角形模糊集的支撑上界 C_3 。

$$\max Q(C_3) = \frac{\sum_{x_i \geq C_2} A(X_k)}{C_3 - C_2} \quad (4)$$

(4) 给出三角形模糊粒子

$$P = \{c_1, c_2, c_3\} \quad (5)$$

其中 C_1 代表下界值, C_2 代表平均值, C_3 代表上界值。分别为支持向量机中的 Low, R, Up 。

3.2 支持向量机模型建立

支持向量机技术的主要思想是建立一个分类超平面作为决策曲面,使得正例和反例之间的间隔边缘被最大化^[7-8]。支持向量机能较好地实现小样本数据的模式识别和故障预测,结构图见图 1。




图 1 支持向量机的体系结构

根据参考文献 [15], 径向基核函数 RBF 相对于其他核函数, 有可调参数少使得模型复杂性减小、学习能力较强等优点, 所以本文采用 RBF 作为核函数。计算公式如下:

$$K(x, x_i) = \exp\left\{-\frac{|x - x_i|^2}{\delta^2}\right\}$$
 (6)

采用径向基核函数后,其对应的支持向量机决策函数为:

$$f(x) = \operatorname{sgn}\left\{\sum_{i=1}^n \alpha_i y_i \exp\left\{-\frac{|x - x_i|^2}{\delta^2}\right\} + b\right\}$$
 (7)

VC 维数可以通过尺度参数 δ 改变。

相比于人工神经网络,支持向量机在运算时涉及到相关数据的优化。主要是影响它的模型两个参数:一个是参数 c ,它是风险与模型泛化性平衡的一个判断依据;另一个是控制径向基核函数的参数 g 。本文选择 K-fold Cross Validation (K-CV) 法在预测模型建模过程中对罚函数 c 与核函数参数 g 进行优化选择。

K-CV 方法是 Hold-Out Method 的衍生改进,它将数据分为 K 组,任取一组来验证,余下的 $K-1$ 组用来训练模型。同样的过程进行 K 次,每次记录下相应的 c 和 g ,最后对所记录的 c 和 g 取平均值作为支持向量机优化的参数。其优点是:K-CV 法能够很有说服力的确定 c 和 g 。其缺点是:K 的取值不能很好的确定,只有依靠经验选择。

4 运算实例

由于计算过程复杂,要采用 MATLAB 技术编程实现,编程过程中,要用到台湾大学林智仁教授等人开发设计的 LIBSVM 工具箱函数。采用 MATLAB 编程的算法流程图 2 所示。

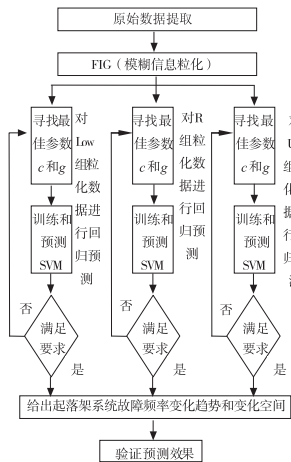


图 2 起落架系统故障频率预测流程图

4.1 原始数据提取

本文以某单位某通航飞机为研究对象,收集了该机型 16 架飞机从 2012 年 1 月至 2016 年 12 月的所有系统故障频率统计数据^[13-14]。根据该统计数据发现,起落架故障频率占该机型整机故障率的 20% 左右,所以本文以该机型起落架系统为研究对象,包括刹车系统、前轮转弯系统、机轮、减震系统、收放系统等,共收集起落架故障数据共 1994 例,得到原始统计表 1。根据表 1 可以看出故障部位、故障原因、发生故障频数等信息。发生故障频数就是从 2012 年 1 月到 2016 年 12 月这 5 年时间内,该故障部位由于该故障原因发生的故障次数。

本文要得到基于时间序列的基础数据,所以根据

表 1 的原始数据,得到按时间序列排序的基础数据见表 2。由于单架飞机故障次数少,统计时间太短数据也少,所以本文中以全部 16 架飞机在每一个月中发生的故障次数作为每一个基础数据,这样就得到 5 年整个机队起落架系统发生的故障频率基础数据共 60 个,这 60 个基础数据的总和刚好就是 1994。这里只列出基础数据的一部分。

表 1 起落架常见故障类型及频数

故障部位	故障原因	频数	故障部位	故障原因	频数
轮速传感器	电气故障	5	前轮转弯	卡阻	53
轮轴	过热	6	转弯作动筒	漏油	7
防滞刹车	电气故障	36	机轮	刺伤	986
刹车计量活门	漏油	12	轮舱	太脏	8
刹车组件	磨损到限	258	机轮	漏气	15
刹车组件	过热	83	减摆器	漏油	25
刹车油路	漏油	35	减震支柱	支柱软	113
自动刹车	电气故障	95	减震支柱	漏油漏气	38
停留刹车	电气故障	18	收放系统	振动	20
前轮滑行	侧偏	128	收放指示灯	电气故障	8
前轮	摆振	30	收放作动筒	漏油	15

表 2 按照时间序列排序的故障频率

2012. 1	2012. 2	2012. 3	...	2016. 12
27	31	35	...	46

4.2 模糊信息粒化

根据 3.1 介绍的三角形模糊粒子的隶属函数和 W. Pedrycz 模糊粒化模型对原始数据进行模糊信息粒化,本文中由于基础数据个数不是太多,所以将 3 个月时间作为一个窗口的大小,则窗口数目是 20。

根据公式(3)~公式(5)求得模糊信息粒化后的数据如表 3 所示。在本文中 a 取 0.2, m 取 0.5, b 取 0.8。

表 3 模糊信息粒化后的数据

Low	23	22	26	19	17	21	15	...	35
R	31	28	38	31	23	25	25	...	41
Up	35	40	42	36	35	27	30	...	45

4.3 利用 SVM 对粒化数据进行回归预测

根据粒化函数得到 Low, R, Up 三组数据,分别利用这三组数据进行回归预测和验证。

为了使预测的精度更高,需要对样本统一进行归一化处理。将用于预测的原始数据按照缩放的规律将数据规划到 $[-1, 1]$ 之间,这样可以消去数据之间的量级,使得数据之间的量级误差变小,为后面预测提供更好的精度。

本文采用最大最小法。函数形式如下:

$$X_K = \frac{X_K - X_{\min}}{X_{\max} - X_{\min}}$$
 (8)

本文将数据归一化到 $[-1, 1]$ 。

4.3.1 寻找最佳参数 c 和 g

关于 SVM 参数的优化选取,国际上并没有公认统一的最好的方法,目前常用的方法就是让 c 和 g 在一定的范围内取值,

使用 SVM 做分类预测时需要调节相关的参数,主要是惩罚参数 c 和核函数参数 g 。目前常用的方法就

是让 c 和 g 在一定的范围内取值,对于取定的 c 和 g ,把训练集作为原始数据并利用 K-CV 方法得到在此组 c 和 g 下训练集验证分类准确率,最终取得使训练集验证分类准确率最高的那组 c 和 g 作为最佳的参数。由于必须将 c 和 g 的值进行离散化查找,这里将 c 和 g 在 2 的指数范围网格内进行查找。常用的方法有:

Hold-Out Method 法;K-fold Cross Validation (K-CV) 法;Leave-One-Out Cross Validation (LOO-CV);通过对比,可以看出 Hold-Out Method 相对于 K-CV 法与 LOO-VC 法来说,计算量小,但是参数的计算过于简单,缺乏可信度。而 LOO-VC 法计算量较大,需要较长的计算时间,所以 K-CV 则更容易实现。因此本文选择 K-CV 法在预测模型建模过程中对罚函数 c 与核函数参数 g 进行优化选择。

本文利用 SVMcgForRegress 函数来寻找最佳的参数 c 和 g 。建立支持向量机模型,通过交叉验证优化参数。使用 K-CV 交叉验证,步长 K 取 3。首先参数 C 和 r 的步进均取 1,在较大范围进行粗略选择。确定大致范围后缩小搜索范围后,将步进调整为 0.2,进行精细选择。得到选择结果如表 4 所示。

表 4 c 和 g 的选择结果

	粗略选择结果		精细选择结果	
	c	g	c	g
Low	1024	0.00781	64	0.0009765
R	2	1	2	0.707107
Up	0.5	0.003906	1	0.02209

4.3.2 训练和预测 SVM

本文采用 LIBSVM 工具箱函数进行训练和预测支持向量机。LIBSVM 工具箱函数它有效、快速地完成支持向量机的模式识别。在该工具箱中主要使用训练函数 *svmtrain* 和预测函数 *svmpredict* [15-17]。利用上面得到的最佳参数,可以对 SVM 进行训练和预测,结果如表 5 所示。

表 5 训练结果和预测结果对比

Low			R			Up		
实际	预测	误差	实际	预测	误差	实际	预测	误差
23	23.84	-0.84	31	34.15	-3.15	35	39.48	-4.48
22	22.50	-0.50	28	33.21	-5.21	40	38.45	1.55
26	21.34	4.66	38	32.39	5.61	42	37.00	5.00
19	20.35	-1.35	31	31.69	-0.69	36	35.30	0.70
17	19.56	-2.56	23	31.14	-8.14	35	33.62	1.38
21	18.98	2.02	25	30.73	-5.73	27	32.27	-5.27
15	18.61	-3.61	25	30.47	-5.47	30	31.56	-1.56
...
35	33.64	1.36	41	41.04	-0.04	45	43.46	1.54

4.4 回归预测结果分析

根据表 5 可以得到每一个模糊粒子的 Low, R, Up 预测值,分别对应每一个时期故障频率的下界值,平均值,上界值。比如最后一个模糊粒子。

$$[Low, R, Up] = [33.64, 41.04, 43.46]$$

表示从 2016 年 10 月到 2016 年 12 月,起落架实际故障次数在 33.64 ~ 43.46 之间,平均值为 41.04 次。

以时间作为横坐标,发生的故障次数作为纵坐标,把实际故障次数和预测的下界值,平均值,上界值画成




图 3 实际值与预测值对比图

一副折线图如图 3 所示。

当实际发生的故障次数超出预测上限或者低于预测值下限,系统发出预警/报警。提醒机务维护人员此时起落架系统故障频率超标,根据故障频率的变化趋势及时采取相关维护措施。

根据图 3 还可以看出,该故障预测模型具有实时性,可以根据输入的数据进行实时预测,实时指导机务维护人员的维护工作。

4.5 Matlab 仿真误差分析

本文中,采用数理统计里面提供的方法进行误差分析,首先计算实际故障频率和预测故障频率的相关系数 r^2 ,然后计算实际故障频率和预测故障频率平均平方误差 MSE [15-16]。

平均平方误差用下式计算, n 为样本数目。

$$MSE = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2 \quad (9)$$

平方相关系数用下式计算, n 为样本数目。

$$r^2 = \frac{\left(n \sum_{i=1}^n f(x_i) y_i - \sum_{i=1}^n f(x_i) \sum_{i=1}^n y_i \right)^2}{\left(n \sum_{i=1}^n f(x_i)^2 - \left(\sum_{i=1}^n f(x_i) \right)^2 \right) \left(n \sum_{i=1}^n y_i^2 - \left(\sum_{i=1}^n y_i \right)^2 \right)} \quad (10)$$

在实际计算过程中,采用不同的支持向量机类型和不同的核函数,也可以按照上述思路进行计算并得出最终的训练和预测结果。在支持向量机类型方面,分别采用 epsilon_SVR 和 nu_SVR 模型,在核函数方面分别采用线性核函数、多项式核函数、RBF 核函数、Sigmoid 核函数进行训练和预测。得到最终各个支持向量机模式下各个核函数的误差如表 6 和表 7 所示。

表 6 epsilon_SVR 模式下误差

核函数	LOW		R		UP	
	r^2	MSE	r^2	MSE	r^2	MSE
线性	0.144	0.217	0.215	0.311	0.123	0.220
多项式	0.269	0.188	0.227	0.303	0.117	0.227
RBF	0.324	0.171	0.191	0.308	0.209	0.205
Sigmoid	0.002	0.351	0.0529	0.368	0.128	0.162

表 7 nu_SVR 模式下误差

核函数	LOW		R		UP	
	r^2	MSE	r^2	MSE	r^2	MSE
线性	0.144	0.218	0.215	0.314	0.123	0.228
多项式	0.269	0.183	0.227	0.293	0.117	0.222
RBF	0.323	0.169	0.179	0.311	0.222	0.203
Sigmoid	0.004	0.334	0.047	0.405	0.130	1.065

根据表 6 和表 7 可以看出,针对小样本,贫信息预测,采用 epsilon_SVR 类型和 RBF 核函数,相关系数大同时总体误差要小一些。故本文选用的方法是合理有效的。

本文采用 epsilon_SVR 类型和 RBF 核函数,分别采用 36 组、42 组、48 组、54 组、60 组数据进行训练,研究不同训练数据情况下的误差(表 8)。

表 8 不同训练样本下的误差分析

	LOW		R		UP	
	r^2	MSE	r^2	MSE	r^2	MSE
36 组	0.057	0.228	0.147	0.258	0.209	0.205
42 组	0.324	0.201	0.191	0.308	0.368	0.225
48 组	0.756	0.167	0.305	0.344	0.353	0.181
54 组	0.650	0.171	0.383	0.369	0.354	0.168
60 组	0.987	0.008	0.554	0.137	0.991	0.009

根据表 8 得出:训练数据越多,训练数据和训练结果之间的相关系数就越大,同时平均平方误差越小。训练结果越接近于实际工作情况。所以本文建立的通航飞机起落架系统故障频率预测模型可以用于实际的机务维护工作。

5 结论

本文采用基于信息粒化和支持向量机相融合的时序回归预测技术预测某型通航飞机起落架故障频率。采用 epsilon_SVR 类型和 RBF 核函数,分别采用 36 组、42 组、48 组、54 组、60 组数据进行训练和预测,根据预测结果和误差分析,表明采用该方法预测起落架故障频率合理有效,根据预测结果可得到起落架故障频率的变化趋势和变化空间,为该机型机务维修中变事后维修为预防维修提供技术支持,尽可能保证飞行安全。

[参考文献]

[1] 王红,凌云,何超. 对 172R 型飞机前起落架减震支柱渗油故障诊断及解决方法的研究 [J]. 机床与液压,2016,44(4):142-144.

[2] 郑永安,史忠科. 飞机起落架防滑刹车系统鲁棒故障诊断方法 [J]. 飞行力学,2008,2(2):16-19.

[3] 陈新霞,刘煜原,黄加阳,等. 基于贝叶斯网络推理的起落架系统故障诊断技术研究 [J]. 计算机测量与控制,2016,24(10):24-27.

[4] 常浩,金大玮,邢国平,等. 某型飞机起落架故障诊断专家系统设计研究 [J]. 飞机设计,2009,29(5):24-28.

[5] Lo C S, Wang C M. Support vector machine for breast MR image classification [J]. Computers and Mathematics with Applications,2012,64(5):1153-1162.

[6] Li Boyan, Wang Qiangwei, Hu Jinglu. Fast SVM training using edge detection on very large datasets [J]. IEEE Transactions on Electrical and Electronic Engineering, 2013, 8(3):229-237.

[7] Maldonado S, Weber R, Basak J. Simultaneous feature selection and classification using kernel penalized support vector machines [J]. Information Sciences,2011,181(1):115-128.

[8] 朱旻辰,宦飞. 基于加权 SVM 与信息粒化的时序波动范围预测 [J]. 信息安全与通信保密,2014(5):76-81.

[9] 孔平,陈亮,马晶. 基于模糊信息粒化支持向量机的短期电力负荷预测 [J]. 电力信息与通信技术,2016,14(1):11-14.

[10] 彭勇,陈俞强. 基于信息粒化的 SVM 时序回归预测 [J]. 计算机系统应用,2013,22(5):163-167.

[11] 王国胤,张清华,胡军. 粒计算研究综述 [J]. 智能系统学报,2007,2(6):8-20.

[12] Guo X C, Yang J H, Wu C G. A Novel LS-SVM Hyperparameter selection based on particle Swarm Optimization [J]. Neuro computing, 2008,71(32):3211-3215.

[13] 龙江,周斌,庞杰. 飞机系统 [M]. 成都:西南交通大学出版社,2017.

[14] 丰世林. B737NG 航线维护故障模式影响及危害性分析 [J]. 中国民航飞行学院学报,2011,22(5):19-21.

[15] 王小川,史峰,郁磊,等. MATLAB 神经网络 43 个案例分析 [M]. 北京:北京航空航天大学出版社,2013.

[16] 胡良谋,曹克强,徐浩民,等. 支持向量机故障诊断及控制技术 [M]. 北京:国防工业出版社,2011.

(编辑 李秀敏)

(上接第 50 页)

[13] Xiong H L, Swamy M N S, Ahmad M O. Optimizing the Kernel in the Empirical FeatureSpace [J]. IEEE Trans on Neural Networks,2005,16(2):460-474.

[14] 邵信光,杨慧中,陈刚,等. 基于粒子群优化算法的支持向量机参数选择及其应用 [J]. 控制理论与应用,2006,23(5):740-743,748.

[15] Pawlak Z. Rough sets - theoretical aspects of reasoning about data [M]. Dordrecht: KluwerAcademic Publishers, 1991.

[16] Yang X S, Deb S. Cuckoo Search via Levy flights [C]. Proc. World Congress on Nature & Biologically Inspired Computing. IEEE Publications, India, 2009: 210-214.

[17] 蒋瑜. 基于集合枚举树的最小属性约简算法 [J]. 计算机工程与应用,2013,49(11):101-104.

[18] 马宪民,张兴,张永强. 基于支持向量机与粗糙集的隔爆电动机故障诊断 [J]. 工矿自动化,2017,43(2):35-40.

[19] 郑巧燕,莫愿斌,刘付永,等. 一种小规模多种群布谷鸟算法 [J]. 计算机应用软件,2014,31(10):278-280,317.

[20] 赵佳莉. 四足机器人液压系统故障诊断方法研究 [D]. 北京:北京理工大学,2016.

[21] 王旭红,何怡刚. 基于小波包分析和支持向量机的异步电机转子断条故障诊断 [J]. 微特电机,2010,38(5):34-36.

[22] 张柯,陆剑. 小波包分析和最小二乘支持向量机的电机故障诊断 [J]. 微型电脑应用,2015,31(6):6-8.

[23] 林茂,李孝全,张兴. 小波包分解法与粗糙集神经网络在电机故障诊断中的应用 [J]. 大电机技术,2012(5):31-34.

(编辑 李秀敏)